

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

ในปัจจุบันเทคโนโลยีได้เข้ามามีบทบาทสำคัญอย่างยิ่งในการยกระดับคุณภาพชีวิตของผู้พิการทางร่างกาย โดยเฉพาะผู้ที่สูญเสียอวัยวะส่วนบน ซึ่งส่งผลกระทบโดยตรงต่อการดำเนินชีวิตและการประกอบอาชีพ จากสถิติงานวิจัยเกี่ยวกับอุบัติเหตุในอุตสาหกรรมผลิตชิ้นส่วนรถยนต์ พบว่าอวัยวะส่วนบนเป็นส่วนที่ได้รับบาดเจ็บสูงสุด โดยคิดเป็นสัดส่วนสูงถึงร้อยละ 76.7 ของการบาดเจ็บทั้งหมด สาเหตุหลักเกิดจากการถูกชิ้นงานตัดหรือบาดในขั้นตอนการผลิตซึ่งความรุนแรงอาจนำไปสู่ภาวะทุพพลภาพถาวรที่สร้างภาระทางเศรษฐกิจอย่างมหาศาล

นอกจากผลกระทบต่อตัวผู้พิการแล้วปัญหานี้ยังส่งผลถึงระบบสาธารณสุขในวงกว้าง โดยมีการคาดการณ์ว่าในปี พ.ศ. 2569 ประเทศไทยจะมีปริมาณความต้องการใช้บริการฟื้นฟูสมรรถภาพในระบบบริการสุขภาพระดับทุติยภูมิเพิ่มสูงขึ้นอย่างมากภาระงานด้านการฟื้นฟูที่สะสมนี้เน้นย้ำถึงความจำเป็นเร่งด่วนในการพัฒนาเทคโนโลยีกายอุปกรณ์ที่ทันสมัยเพื่อช่วยให้ผู้ป่วยสามารถฟื้นฟูและฝึกใช้งานอุปกรณ์ได้ด้วยตนเองอย่างมีประสิทธิภาพ ลดการพึ่งพากระบวนการในโรงพยาบาลที่มีความหนาแน่น

ในบรรดากายอุปกรณ์สำหรับส่วนบน มือเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อ (Myoelectric Prosthesis) ได้รับความสนใจมากกว่าแบบดั้งเดิมเนื่องจากมีการควบคุมได้เป็นธรรมชาติมากกว่า แต่ปัญหาหลักที่พบคือความยากในการควบคุม เนื่องจากระบบปัจจุบันมักเป็นแบบวงจรเปิด (Open loop) ที่ขาดข้อมูลตอบกลับ และต้องอาศัยสมาธิในการควบคุมสูงจนนำไปสู่ความล้าทางจิตใจและเลิกใช้งานในที่สุด เพื่อแก้ปัญหานี้งานวิจัยยุคใหม่จึงได้นำเทคโนโลยีการเรียนรู้ของเครื่องแบบเรียลไทม์ (Real-time Machine Learning) มาช่วยในการทำนายเจตนาของผู้ใช้ เพื่อลดเวลาและภาระทางสมอง (Cognitive load) ในการสั่งการเคลื่อนไหว ทำให้การเปลี่ยนท่าทางของมือเทียมมีความฉลาดและตอบสนองได้แม่นยำยิ่งขึ้น

อย่างไรก็ตามอุปกรณ์ที่มีเทคโนโลยีขั้นสูงดังกล่าวมักมีราคาแพงและเข้าถึงได้ยากสำหรับผู้พิการที่มีรายได้น้อย โครงการนี้จึงมีวัตถุประสงค์เพื่อออกแบบและพัฒนามือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อโดยประยุกต์ใช้เทคโนโลยีการพิมพ์ 3 มิติ (3D Printing) เพื่อลดต้นทุนการผลิตและปรับแต่งให้เข้ากับสรีระเฉพาะบุคคล ร่วมกับการพัฒนาระบบควบคุมที่ช่วยลดภาระของผู้ใช้ เพื่อสร้างต้นแบบที่มีต้นทุนต่ำ (Low-cost) ใช้งานได้จริง และยกระดับคุณภาพชีวิตของผู้พิการให้สามารถกลับมาใช้ชีวิตได้อย่างยั่งยืน

1.2 วัตถุประสงค์ของโครงการวิศวกรรม

1.2.1 เพื่อออกแบบและพัฒนาต้นแบบมือเทียมที่สามารถควบคุมการทำงานด้วยสัญญาณกล้ามเนื้อ (Myoelectric Signal)

1.2.2 เพื่อศึกษาการทำงานของเซนเซอร์ตรวจจับสัญญาณกล้ามเนื้อและการประมวลผลสัญญาณ

1.2.3 เพื่อประยุกต์ใช้ไมโครคอนโทรลเลอร์ในการควบคุมการเคลื่อนไหวของมือเทียม

1.2.4 เพื่อสร้างต้นแบบมือเทียมที่มีต้นทุนต่ำและสามารถใช้งานได้จริง

1.2.5 เพื่อพัฒนาระบบสนับสนุนการปรับแต่งอุปกรณ์ (Calibration Tool) ที่ช่วยให้ผู้ใช้งานสามารถตั้งค่าและบันทึกรูปแบบสัญญาณกล้ามเนื้อเฉพาะบุคคล (User-specific Profile) ลงในฐานข้อมูล

1.2.6 เพื่อสร้างฐานข้อมูลหรือระบบจัดเก็บข้อมูลผู้ใช้งาน สำหรับจัดการข้อมูลการปรับเทียบและรูปแบบสัญญาณกล้ามเนื้อ เพื่อเพิ่มความแม่นยำในการควบคุมอุปกรณ์

1.3 ขอบเขตของโครงการวิศวกรรม

1.3.1 โครงการนี้พัฒนาระบบในระดับต้นแบบ (Prototype) เพื่อทดสอบแนวคิดการควบคุมด้วยสัญญาณกล้ามเนื้อ ยังไม่ผ่านกระบวนการรับรองมาตรฐานอุปกรณ์การแพทย์สำหรับใช้งานเชิงพาณิชย์

1.3.2 โครงการนี้มุ่งเน้นการพัฒนามือเทียมสำหรับผู้พิการที่สูญเสียอวัยวะในระดับใต้ศอก (Below Elbow)

1.3.3 การทำงานของมือเทียมจำกัดอยู่ในรูปแบบการเคลื่อนไหวพื้นฐาน เช่น การกำและการคลายมือ

1.3.4 การทดสอบการทำงานของโครงการจะดำเนินการกับบุคคลทั่วไปที่ไม่มีความพิการทางร่างกาย ทั้งนี้เพื่อประเมินประสิทธิภาพการทำงานของแขนเทียมในขั้นต้น

1.4 สมมติฐานของโครงการวิศวกรรม

1.4.1 ระบบตรวจวัดสัญญาณกล้ามเนื้อ (EMG Sensor)

1.4.1.1 ใช้เซนเซอร์ตรวจจับค่าสัญญาณกล้ามเนื้อ (EMG) เพื่อตรวจวัดคุณภาพสัญญาณทั้งภายในและภายนอกระบบ

1.4.1.2 สามารถวัดค่าสัญญาณได้แบบเรียลไทม์ และนำค่าที่ได้มาใช้ในการปรับการทำงานของระบบควบคุม

1.4.2 ระบบประมวลผลด้วยปัญญาประดิษฐ์ (Machine Learning)

1.4.2.1 ใช้อัลกอริทึม Machine Learning หลายรูปแบบ ได้แก่ Decision Tree, Random Forest, SVM, Neural Network, XGBoost, CatBoost, k-Nearest Neighbor และ Linear Model รวมถึงเทคนิคการรวมกลุ่มแบบจำลอง (Ensemble) ด้วยวิธี Bagging และ AdaBoost เพื่อจำแนกสัญญาณ EMG แบบเรียลไทม์

1.4.2.2 สามารถปรับตัวตามลักษณะสัญญาณเฉพาะบุคคลผ่านระบบ Calibration เพื่อเพิ่มความแม่นยำในการควบคุม

1.4.3 การประมวลผลและจัดเก็บข้อมูล

1.4.3.1 Raspberry Pi 5 ทำหน้าที่เป็นตัวกลางประมวลผลข้อมูลทั้งหมดที่ได้รับจากเซนเซอร์ต่าง ๆ

1.4.3.2 ข้อมูลที่ได้จะถูกบันทึกลงใน Firebase เพื่อนำมาใช้วิเคราะห์แนวโน้มและปรับปรุงโมเดลในระยะยาว

1.4.4 การแสดงผลและรายงานข้อมูล

1.4.4.1 ข้อมูลที่วัดได้จะแสดงผลผ่านแอปพลิเคชัน Calibration Tool เพื่อให้ผู้ใช้งานสามารถดูข้อมูลได้แบบเรียลไทม์

1.4.4.2 ระบบสามารถส่งข้อมูลไปยังฐานข้อมูลเพื่อให้สามารถติดตามข้อมูลย้อนหลัง และใช้ในการวิเคราะห์แนวโน้มของค่าสัญญาณในพื้นที่

1.4.5 การควบคุมการเคลื่อนไหวของมือเทียม

1.4.5.1 ใช้ Servo Motor รุ่น MG996R ร่วมกับ PCA9685 Driver ในการควบคุมการเคลื่อนไหวของมือเทียมอย่างแม่นยำ

1.4.5.2 กลไก Debounce ป้องกันการสั่งงานเซอร์โวมอเตอร์ที่ถี่เกินไปเมื่อสัญญาณหรือผลทำนายกว้างใกล้จุดตัดสินใจ เพื่อเพิ่มความเสถียรในการควบคุม

1.4.5.3 การจัดวางสายสัญญาณและสายส่งกำลังของเซอร์โวมอเตอร์แยกออกจากกัน เพื่อลดสัญญาณรบกวนจากการเหนี่ยวนำทางแม่เหล็กไฟฟ้าที่อาจเข้ามาปะปนกับสัญญาณกล้ามเนื้อ

1.4.5.4 การตรวจวัดค่าสัญญาณแบบต่อเนื่อง ระบบจะตรวจจับค่า EMG ภายในมือเทียมและปรับระบบควบคุมให้ทำงานตามค่าที่วัดได้ เพื่อให้มีประสิทธิภาพสูงสุด

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1.5.1 ก่อนการพัฒนาโครงการวิศวกรรมนี้ มือเทียมที่มีเทคโนโลยีขั้นสูงส่วนใหญ่ต้องนำเข้าจากต่างประเทศ มีราคาสูงตั้งแต่หลักแสนถึงหลักล้านบาทต่อชิ้น เมื่อมีการพัฒนามือเทียมต้นแบบจากโครงการนี้ คาดว่าจะสามารถลดต้นทุนการผลิตลงอย่างมีนัยสำคัญ โดยใช้อุปกรณ์อิเล็กทรอนิกส์ทั่วไป และการพิมพ์สามมิติ ส่งผลให้เกิดโอกาสในการผลิตและพัฒนาอุปกรณ์ภายในประเทศ ลดการนำเข้า และเพิ่มศักยภาพการแข่งขันของอุตสาหกรรมกายอุปกรณ์ทางการแพทย์ของไทยในระยะยาว

1.5.2 โครงการวิศวกรรมนี้มีส่วนช่วยให้ผู้พิการทางร่างกายสามารถกลับมาดำรงชีวิตประจำวันได้ใกล้เคียงปกติมากขึ้น ลดการพึ่งพาผู้อื่น และเพิ่มโอกาสในการกลับเข้าสู่ตลาดแรงงาน นอกจากนี้ การเข้าถึงมือเทียมที่มีต้นทุนต่ำและปรับแต่งได้เฉพาะบุคคล ยังช่วยลดความเหลื่อมล้ำทางสังคม และสนับสนุนการพัฒนาสังคมที่ให้โอกาสอย่างเท่าเทียม

1.5.3 โครงการนี้เป็นผลงานนวัตกรรมที่บูรณาการเทคโนโลยีการประมวลผลสัญญาณกล้ามเนื้อ (EMG) ร่วมกับเทคนิค Machine Learning แบบเรียลไทม์ ซึ่งสะท้อนศักยภาพของนักศึกษาวิศวกรรมศาสตร์ในการพัฒนาเทคโนโลยีที่ตอบโจทย์สังคมไทยและสามารถต่อยอดสู่การผลิตเชิงพาณิชย์หรือขยายผลในระดับประเทศต่อไป

1.6 สถานที่จัดทำโครงการ

1.6.1 มูลนิธิขาเทียมในสมเด็จพระศรีนครินทราบรมราชชนนี 199 หมู่ 4 ตำบล ดอนแก้ว อำเภอมะรุริม เชียงใหม่ 50180

1.7 ตารางแผนการดำเนินงาน

ตารางที่ 1.1 แผนการดำเนินงาน

กิจกรรม	เดือน/ปี 2569					
	มี.ค.69	เม.ย.69	พ.ค.69	มิ.ย.69	ก.ค.69	ก.ย.69
1. วิเคราะห์ความต้องการ						
2. การออกแบบระบบ						
3. การพัฒนาระบบเบื้องต้น						
4. การติดตั้งระบบ						
5. การบำรุงรักษา						

ตารางแผนการดำเนินงานนี้แสดงให้เห็นว่าโครงการมีการวางแผนดำเนินงานอย่างเป็นขั้นตอน ตั้งแต่การวิเคราะห์ความต้องการจนถึงการบำรุงรักษา ครอบคลุมช่วงเวลา มีนาคมไปจนถึงกันยายน 2569 ซึ่งช่วยให้ทีมงานสามารถติดตามความก้าวหน้าและควบคุมการทำงานของโครงการได้อย่างมีระบบ

บทที่ 2

ทฤษฎี และงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้องกับระบบงาน

โครงการวิศวกรรมนี้มุ่งเน้นการพัฒนา"มือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อ"เพื่อช่วยลดผลกระทบด้านคุณภาพชีวิตของผู้พิการทางร่างกายที่สูญเสียอวัยวะส่วนบน โดยเฉพาะผู้ที่สูญเสียมือในระดับใต้ข้อศอก (Below Elbow Amputation) ซึ่งเป็นกลุ่มที่ต้องการความช่วยเหลือด้านกายอุปกรณ์สูง วัตถุประสงค์ของโครงการคือการออกแบบและสร้างต้นแบบมือเทียมที่สามารถลดต้นทุนการผลิตด้วยเทคโนโลยีการพิมพ์สามมิติและควบคุมการเคลื่อนไหวด้วยสัญญาณกล้ามเนื้อ(Electromyography : EMG) ร่วมกับการประมวลผลแบบเรียลไทม์ได้อย่างมีประสิทธิภาพ

2.1.1 ชีวกลศาสตร์และการทำงานของกล้ามเนื้อ (Biomechanics & Muscle Physiology)

2.1.1.1 กล้ามเนื้อมนุษย์ทำงานโดยอาศัยกระแสไฟฟ้าที่เกิดจากการหดตัวของเส้นใยกล้ามเนื้อเรียกว่าสัญญาณกล้ามเนื้อ ซึ่งมีแอมพลิจูดอยู่ในช่วงไมโครโวลต์ถึงมิลลิโวลต์ และมีช่วงความถี่หลักอยู่ที่ 20–500 Hz สัญญาณเหล่านี้สามารถตรวจจับได้จากผิวหนังโดยไม่ต้องผ่าตัด ทำให้เหมาะสำหรับการนำมาใช้ควบคุมอุปกรณ์กายอุปกรณ์แบบไม่รุกราน โครงการนี้อ้างอิงแนวคิดดังกล่าวโดยใช้เซนเซอร์ เพื่อตรวจจับสัญญาณจากกล้ามเนื้อส่วนแขนที่เหลืออยู่ แล้วนำมาประมวลผลเพื่อสั่งให้มือเทียมเคลื่อนไหวตามเจตนาของผู้ใช้

2.1.2 การวัดและเซนเซอร์ (Sensing Theory)

2.1.2.1 ตลอดทศวรรษที่ผ่านมา เซนเซอร์วัดสัญญาณกล้ามเนื้อแบบพื้นผิวราคาประหยัดได้รับการพัฒนาอย่างต่อเนื่องเพื่อให้มีขนาดเล็กลง น้ำหนักเบา และสามารถส่งข้อมูลแบบไร้สายได้ อย่างไรก็ตาม ความแม่นยำของเซนเซอร์ยังขึ้นอยู่กับสภาพแวดล้อม เช่น ความชื้น อุณหภูมิ และตำแหน่งการติดตั้ง ทำให้ต้องมีกระบวนการสอบเทียบ เพื่อให้ได้ข้อมูลที่ถูกต้องและเชื่อถือได้ โครงการนี้จึงพัฒนาเครื่องมือสอบเทียบที่ช่วยให้ผู้ใช้สามารถบันทึกรูปแบบสัญญาณกล้ามเนื้อเฉพาะบุคคล เพื่อเพิ่มความแม่นยำในการสั่งการ

2.1.3 การประมวลผลสัญญาณ (Signal Processing Theory)

2.1.3.1 สัญญาณที่ได้จากเซนเซอร์มักมีสัญญาณรบกวน และค่าผิดปกติปะปนอยู่ ซึ่งอาจทำให้ระบบตัดสินใจผิดพลาดได้ วิธีการทางคณิตศาสตร์ที่นิยมใช้เพื่อลดสัญญาณรบกวน ได้แก่ ค่าเฉลี่ยเคลื่อนที่และค่าเฉลี่ยเคลื่อนที่แบบเอ็กซ์โปเนนเชียล ซึ่งช่วยปรับสัญญาณให้ราบเรียบมากขึ้น นอกจากนี้ยังมีเทคนิคการตรวจจับค่าผิดปกติโดยใช้พิสัยระหว่างควอไทล์ หรือค่ามัธยฐานของส่วนเบี่ยงเบนสัมบูรณ์ เพื่อตัดค่าที่อยู่นอกช่วงปกติออกไป การประมวลผลเหล่านี้ช่วยเพิ่มความเสถียรของระบบควบคุม และทำให้ผลการวิเคราะห์สอดคล้องกับแนวโน้มจริงมากกว่าการตอบสนองต่อค่าแบบเฉพาะหน้า ซึ่งสำคัญอย่างยิ่งต่อโครงการที่ต้องตัดสินใจแบบอัตโนมัติ

2.1.4 ระบบควบคุมและอัตโนมัติ (Control System Theory)

2.1.4.1 ระบบควบคุมแบ่งออกเป็นสองกลุ่มหลักคือ ระบบควบคุมแบบวงเปิด และระบบควบคุมแบบวงปิด โครงงานนี้ใช้รูปแบบระบบควบคุมแบบวงปิด เนื่องจากการตัดสินใจขึ้นอยู่กับค่าที่วัดได้จากเซนเซอร์แบบต่อเนื่อง ระบบควบคุมพื้นฐานที่พบมากคือ การควบคุมแบบเปิด-ปิด ซึ่งเป็นการทำงานแบบสองสถานะ เช่น เปิดมอเตอร์เมื่อค่าสัญญาณสูงกว่าค่าที่กำหนด และหยุดเมื่อสัญญาณต่ำกว่าค่าที่กำหนด อย่างไรก็ตาม หากต้องการความละเอียดสูงขึ้น สามารถนำการควบคุมแบบสัดส่วน-อินทิกรัล-อนุพันธ์มาใช้ได้ ซึ่งช่วยควบคุมความเร็วรอบมอเตอร์หรือการปรับระดับแรงดันอากาศได้อย่างต่อเนื่อง นอกจากนี้ระบบควบคุมยังควรมีกลไกความปลอดภัย เช่น หากไม่มีสัญญาณภายใน 1 วินาที ระบบจะหยุดการทำงานอัตโนมัติเพื่อความปลอดภัย

2.1.5 ฮาร์ดแวร์และอิเล็กทรอนิกส์พื้นฐาน (Electronics Theory)

2.1.5.1 ฮาร์ดแวร์ในโครงงานใช้ Raspberry Pi 5 เป็นหน่วยประมวลผลกลางที่เชื่อมต่อกับเซนเซอร์และโมดูลไมโครคอนโทรลเลอร์ควบคุมมอเตอร์ TB6600 สำหรับควบคุมมอเตอร์สเต็ปเปอร์ที่ใช้ขับเคลื่อนการเคลื่อนไหวยของนิวมีโอเทียม การทำงานของระบบอ้างอิงการส่งสัญญาณผ่านพอร์ตอินพุต-เอาต์พุต อเนกประสงค์ และโปรโตคอลสื่อสาร เช่น ไอทียูซี และยูอาร์ที สำหรับการรับ-ส่งข้อมูลระหว่างชิ้นส่วนระบบยังถูกออกแบบให้ปิดตัวอัตโนมัติเมื่อปิดโปรแกรม เพื่อยืดอายุการใช้งานของอุปกรณ์

2.1.6 สถาปัตยกรรมซอฟต์แวร์และการสื่อสารข้อมูล (Software & Communication Theory)

2.1.6.1 ระบบซอฟต์แวร์มักใช้แนวทางการเขียนโปรแกรมที่ขับเคลื่อนด้วยเหตุการณ์ เช่น การออกแบบโปรแกรมให้แยกชิ้นการทำงาน ได้แก่ การอ่านเซนเซอร์ การตัดสินใจควบคุม การแสดงผล และการจัดเก็บข้อมูล เพื่อเพิ่มความยืดหยุ่นและลดข้อผิดพลาด โครงงานนี้ยังออกแบบการสื่อสารแบบอนุกรมให้ทนต่อความผิดพลาด เช่น การตรวจสอบส่วนหัวของข้อมูล การตรวจสอบเวลารอคอย และการป้องกันข้อมูลล้นบัฟเฟอร์

2.1.7 ข้อมูลและฐานข้อมูล (Data & Database Theory)

2.1.7.1 การจัดเก็บข้อมูลสัญญาณกล่ามเนื้อและโปรไฟล์ผู้ใช้ใช้ Firebase Realtime Database ซึ่งเป็นฐานข้อมูลบนระบบคลาวด์ที่รองรับการชิงโครไนซ์ข้อมูลแบบเรียลไทม์และสามารถเข้าถึงได้จากทุกที่ผ่านอินเทอร์เน็ต ข้อมูลโปรไฟล์การสอบเทียบของผู้ใช้แต่ละคนจะถูกบันทึกขึ้นระบบคลาวด์และเรียกใช้ในรอบต่อไปได้ทันที เพื่อลดเวลาในการตั้งค่าซ้ำ เพิ่มความแม่นยำในการควบคุมระยะยาว และเปิดโอกาสให้ผู้ดูแลระบบสามารถติดตามและอัปเดตข้อมูลจากระยะไกลได้

2.1.8 ความปลอดภัยและการจัดการสิทธิ์ (Security & IAM Theory)

2.1.8.1 ในระบบที่มีการบันทึกข้อมูลผู้ใช้ การออกแบบสิทธิ์การเข้าถึงและการเข้ารหัสข้อมูลเป็นสิ่งสำคัญ โดยเฉพาะข้อมูลส่วนบุคคลของผู้ใช้การที่เป็นข้อมูลอ่อนไหว ระบบควรอาศัยโปรโตคอลปรับเวลาเครือข่ายเพื่อชิงโครไนซ์เวลาให้ตรงกัน ซึ่งส่งผลโดยตรงต่อการประทับเวลาของข้อมูลการปรับเทียบ

2.1.9 การออกแบบประสบการณ์ผู้ใช้ (User Experience & HCI Theory)

2.1.9.1 การออกแบบเครื่องมือสอบเทียบต้องยึดหลักปฏิสัมพันธ์ระหว่างมนุษย์กับคอมพิวเตอร์ โดยเน้นให้ข้อมูลเข้าใจง่าย แสดงสถานะของสัญญาณกลั่นเนื้อแบบเรียลไทม์ผ่านกราฟ และมีปุ่มควบคุมที่มีการยืนยันก่อนสลับโหมด เพื่อความปลอดภัยและประสิทธิภาพในการใช้งาน

2.1.10 การทดสอบและรับรองคุณภาพ (Quality Assurance Theory)

2.1.10.1 การประเมินคุณภาพระบบต้องทำทั้งในสภาพแวดล้อมจริงและในห้องปฏิบัติการ โดยวัดประสิทธิภาพการจดจำสัญญาณกลั่นเนื้อได้ตามเกณฑ์หรือไม่ รวมถึงทดสอบกรณีพิเศษ เช่น เซนเซอร์ไม่ตอบสนอง การเชื่อมต่อขาดหาย หรือการสั่งงานถี่ ๆ เพื่อดูเสถียรภาพของระบบ นอกจากนี้ยังต้องวัดตัวชี้วัดด้านประสิทธิภาพ เช่น เวลาตอบสนอง ความถูกต้องแม่นยำ และความพร้อมใช้งานของระบบ เพื่อยืนยันความน่าเชื่อถือของระบบ

2.2 เทคโนโลยีและเครื่องมือที่ใช้พัฒนาระบบ (Technologies and Tools)

2.2.1 วิวีสตูดิโอโค้ด (Visual Studio Code: VS Code)



รูปที่ 2.1 โลโก้โปรแกรมวิวีสตูดิโอโค้ด
ที่มา (<https://code.visualstudio.com>)

จากรูปที่ 2.1 โปรแกรม Visual Studio Code เป็นเครื่องมือสำหรับการพัฒนาโปรแกรม ดังแสดงในรูปที่ 2.1 จุดเด่นของโปรแกรมนี้นี้เกิดจากแนวคิดและทฤษฎีทางวิศวกรรมซอฟต์แวร์และวิทยาการคอมพิวเตอร์ที่ถูกนำมาประยุกต์ใช้อย่างมีประสิทธิภาพ หลักการสำคัญประการแรกคือการออกแบบให้เป็นโปรแกรมแก้ไขซอร์สโค้ด ที่มีความคล่องตัว แต่ยังคงมีความสามารถเทียบเท่ากับสภาพแวดล้อมการพัฒนาแบบครบวงจรกล่าวคือ ผู้ใช้สามารถเปิดใช้งานได้อย่างรวดเร็วเช่นเดียวกับโปรแกรมแก้ไขข้อความทั่วไป ขณะเดียวกันก็มีเครื่องมือสนับสนุนการเขียนโปรแกรม เช่น การตรวจสอบรหัสคำสั่ง การเติมคำสั่งอัตโนมัติ และการจัดการไฟล์โครงการอย่างเป็นระบบ

Visual Studio Code ใช้สถาปัตยกรรมแบบแยกส่วนโดยแต่ละส่วนของโปรแกรมสามารถทำงานได้อย่างอิสระ และสามารถเพิ่มขยายความสามารถใหม่ ๆ ผ่านส่วนขยาย (Extension) ได้อย่างไม่จำกัด แนวคิดดังกล่าวสอดคล้องกับการออกแบบโปรแกรมเชิงวัตถุ (Object-Oriented Design) ที่มุ่งเน้นการห่อหุ้มข้อมูล (Encapsulation) การนำกลับมาใช้ซ้ำ และการแยกความรับผิดชอบ เพื่อให้ระบบมีความยืดหยุ่น ง่ายต่อการบำรุงรักษา และสามารถพัฒนาต่อยอดได้ในอนาคต

ในโครงการนี้ใช้ Visual Studio Code ในการพัฒนาชุดคำสั่งภาษา Python สำหรับการประมวลผลสัญญาณกลั่นเนื้อ และพัฒนาเครื่องมือสอบเทียบเพื่อใช้ในการบันทึกและวิเคราะห์ข้อมูลสัญญาณกลั่นเนื้อสำหรับควบคุมการทำงานของมือเทียมอัจฉริยะ

2.2.2 Python



รูปที่ 2.2 ภาษาโปรแกรมคอมพิวเตอร์ระดับสูงไพทอน
ที่มา (<https://www.python.org/>)


ภาษาไพทอน (Python) เป็นภาษาโปรแกรม (Programming Language) ที่ได้รับความนิยมอย่างแพร่หลายทั่วโลก เนื่องจากได้รับการออกแบบให้เรียนรู้ได้ง่ายและสามารถประยุกต์ใช้ได้หลากหลายสาขา หัวใจสำคัญของภาษาไพทอนคือความสามารถในการอ่านและทำความเข้าใจรหัสต้นฉบับ (Source Code) ได้ง่าย โดยผู้พัฒนาภาษาได้ยึดแนวคิดที่ว่ารหัสคำสั่งควรมีลักษณะใกล้เคียงกับการอ่านภาษาอังกฤษ ทำให้ทั้งผู้เริ่มต้นและผู้เชี่ยวชาญสามารถทำความเข้าใจโครงสร้างโปรแกรมได้โดยไม่ซับซ้อน

ภาษาไพทอนรองรับการเขียนโปรแกรมเชิงวัตถุ (Object-Oriented Programming: OOP) โดยใช้คลาส (Class) และวัตถุ (Object) เป็นตัวแทนขององค์ประกอบต่าง ๆ ภายในระบบ นอกจากนี้ยังรองรับการเขียนโปรแกรมเชิงฟังก์ชัน และการเขียนโปรแกรมแบบคำสั่ง อีกด้วย ส่งผลให้สามารถเลือกใช้รูปแบบการพัฒนาโปรแกรมได้อย่างยืดหยุ่นตามลักษณะของงาน

ในโครงการนี้ ภาษาไพทอนถูกใช้เป็นภาษาหลักในการพัฒนาระบบทั้งหมด ไม่ว่าจะเป็นการอ่านสัญญาณกลั่นเนื้อจากเซนเซอร์ การประมวลผลข้อมูลด้วยการเรียนรู้ของเครื่อง (Machine Learning) การควบคุมมอเตอร์ ผ่านพอร์ตอินพุต-เอาต์พุตเนกประสงค์ และการพัฒนาเครื่องมือสอบเทียบ

สาเหตุที่เลือกใช้ภาษาไพทอนในโครงการนี้ เนื่องจากมีคลังโปรแกรม (Library) จำนวนมากที่รองรับงานด้านการประมวลผลสัญญาณและปัญญาประดิษฐ์ เช่น NumPy, SciPy และ scikit-learn ซึ่งช่วยลดเวลาในการพัฒนาและเพิ่มประสิทธิภาพของระบบ นอกจากนี้ยังสามารถทำงานร่วมกับ Raspberry Pi 5 ได้โดยตรง ทำให้ลดความซับซ้อนในการพัฒนาระบบฮาร์ดแวร์และซอฟต์แวร์ให้ทำงานร่วมกันได้อย่างมีประสิทธิภาพ

2.2.3 Tkinter



รูปที่ 2.3 เครื่องมือสร้างส่วนติดต่อผู้ใช้แบบกราฟิกทวินเคอร์

ทวินเคอร์ (Tkinter) เป็นส่วนประกอบมาตรฐานที่มาพร้อมกับภาษาไพทอน ใช้สำหรับสร้างส่วนติดต่อผู้ใช้แบบกราฟิก (Graphical User Interface: GUI) เพื่อให้ผู้ใช้สามารถโต้ตอบกับโปรแกรมผ่านหน้าต่าง ปุ่มกด กล่องข้อความ และองค์ประกอบกราฟิกอื่น ๆ ได้อย่างสะดวก การพัฒนาทวินเคอร์มีพื้นฐานมาจากแนวคิดทางวิศวกรรมซอฟต์แวร์และการออกแบบปฏิสัมพันธ์ระหว่างมนุษย์กับคอมพิวเตอร์ ซึ่งมุ่งเน้นให้โปรแกรมสามารถสื่อสารกับผู้ใช้ได้อย่างเป็นมิตร เข้าใจง่าย และลดความซับซ้อนของการใช้งานเมื่อเทียบกับการสั่งงานผ่านบรรทัดคำสั่ง

ทวินเคอร์ทำงานตามแนวคิดการเขียนโปรแกรมที่ขับเคลื่อนด้วยเหตุการณ์ โดยโปรแกรมจะรอการกระทำจากผู้ใช้ เช่น การคลิกปุ่ม การกรอกข้อมูล หรือการเลือกคำสั่ง จากนั้นจึงดำเนินการตามเหตุการณ์ที่เกิดขึ้น แนวคิดดังกล่าวช่วยให้สามารถพัฒนาโปรแกรมที่มีการตอบสนองต่อผู้ใช้ได้อย่างมีประสิทธิภาพ และเหมาะสำหรับการสร้างโปรแกรมที่ต้องมีการโต้ตอบกับผู้ใช้งานอยู่ตลอดเวลา

ในโครงงานนี้ใช้ Tkinter ในการพัฒนาเครื่องมือสอบเทียบ (Calibration Tool) ซึ่งเป็นเครื่องมือสำหรับบันทึกรูปแบบสัญญาณกล้ามเนื้อเฉพาะบุคคล แสดงผลสัญญาณกล้ามเนื้อแบบเรียลไทม์ผ่านกราฟ และเลือกแบบจำลองการเรียนรู้ของเครื่องที่ต้องการใช้งาน การออกแบบส่วนติดต่อผู้ใช้นั้นความเรียบง่าย ชัดเจน และใช้งานได้สะดวก เพื่อให้ผู้ใช้งานสามารถเรียนรู้และใช้งานระบบได้อย่างรวดเร็ว แม้ไม่มีความรู้ด้านเทคโนโลยีหรือการเขียนโปรแกรมมาก่อน

2.2.4 Scikit-learn (Machine Learning Library)



รูปที่ 2.4 คลังโปรแกรม Machine Learning สำหรับภาษาไพทอน
ที่มา (<https://scikit-learn.org/>)

ช่ายคิทีเลิร์น (scikit-learn) เป็นคลังโปรแกรมสำหรับการเรียนรู้ของเครื่อง (Machine Learning Library) ที่ได้รับความนิยมอย่างแพร่หลายในภาษาไพทอน (Python) โดยรวบรวมอัลกอริธึมการเรียนรู้ของเครื่องหลากหลายประเภทไว้ในชุดเดียว ซึ่งสามารถนำมาใช้ในการวิเคราะห์และจำแนกสัญญาณกล้ำเนื้อ เพื่อทำนายเจตนาของผู้ใช้งานว่าต้องการกำมือหรือคลายมือได้อย่างมีประสิทธิภาพ

ช่ายคิทีเลิร์นได้รับการออกแบบให้ใช้งานง่าย มีโครงสร้างการทำงานที่เป็นมาตรฐาน และสามารถทำงานร่วมกับคลังโปรแกรมด้านวิทยาการข้อมูลอื่น ๆ ได้เป็นอย่างดี จึงเหมาะสำหรับการพัฒนาระบบวิเคราะห์ข้อมูลและระบบปัญญาประดิษฐ์ นอกจากนี้ยังมีเครื่องมือสำหรับการเตรียมข้อมูล การฝึกโมเดล การประเมินผล และการปรับแต่งประสิทธิภาพของโมเดลอย่างครบถ้วน

ในโครงการนี้ใช้ช่ายคิทีเลิร์นในการฝึกโมเดล (Train Model) จากข้อมูลการสอบเทียบของผู้ใช้แต่ละคน โดยระบบจะนำข้อมูลสัญญาณกล้ำเนื้อมาวิเคราะห์และสร้างโมเดลสำหรับจำแนกรูปแบบการเคลื่อนไหว จากนั้นจึงเปรียบเทียบประสิทธิภาพของอัลกอริธึมแต่ละประเภท และเลือกโมเดลที่ให้ค่าความถูกต้องสูงที่สุดมาใช้ในการควบคุมมือเทียมแบบเรียลไทม์ เพื่อเพิ่มความแม่นยำและความน่าเชื่อถือของระบบในการใช้งานจริง

2.2.5 ต้นไม้ตัดสินใจ (Decision Tree)



รูปที่ 2.4.1 โครงสร้างโมเดลต้นไม้ตัดสินใจ

ที่มา (<https://scikit-learn.org/stable/modules/tree.html>)


ต้นไม้ตัดสินใจเป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบมีผู้สอน (Supervised Learning) ที่จำลองกระบวนการตัดสินใจในรูปแบบโครงสร้างต้นไม้ โดยแบ่งข้อมูลออกเป็นกลุ่มย่อยตามเงื่อนไขของคุณลักษณะ (Feature) ต่าง ๆ ภายในข้อมูล แต่ละจุดตัดสินใจจะเรียกว่าโหนด (Node) และจะมีการแตก

แขนงไปยังโหนดย่อยจนกระทั่งถึงใบ (Leaf) ซึ่งเป็นผลลัพธ์สุดท้ายของการจำแนกประเภทหรือการพยากรณ์ข้อมูล

หลักการทำงานของต้นไม้ตัดสินใจอาศัยแนวคิดของค่าการเพิ่มขึ้นของสารสนเทศ (Information Gain) หรือค่าความไม่บริสุทธิ์ของจินี (Gini Impurity) ในการเลือกเงื่อนไขที่เหมาะสมที่สุดสำหรับการแบ่งข้อมูลในแต่ละขั้นตอน โดยมีเป้าหมายเพื่อให้ข้อมูลภายในแต่ละกลุ่มมีความบริสุทธิ์ (Purity) หรือมีลักษณะใกล้เคียงกันมากที่สุด ส่งผลให้โมเดลสามารถตัดสินใจได้อย่างมีประสิทธิภาพ อีกทั้งยังเป็นโมเดลที่สามารถอธิบายผลการตัดสินใจได้ง่าย เนื่องจากสามารถติดตามเส้นทางการตัดสินใจจากรากของต้นไม้ไปยังผลลัพธ์ได้อย่างชัดเจน

ในโครงงานนี้ใช้ต้นไม้ตัดสินใจเป็นหนึ่งในโมเดลพื้นฐานสำหรับการเปรียบเทียบประสิทธิภาพในการจำแนกสัญญาณกล้ำเนื้อของผู้ใช้งาน โดยโมเดลจะเรียนรู้รูปแบบของสัญญาณจากข้อมูลการสอบเทียบและนำมาใช้ในการทำนายการเคลื่อนไหวที่ต้องการ ข้อดีที่สำคัญของต้นไม้ตัดสินใจคือมีความรวดเร็วในการทำนายผล สามารถทำงานได้แบบเรียลไทม์ และมีความสามารถในการอธิบายเหตุผลของการตัดสินใจได้อย่างชัดเจน ซึ่งช่วยให้สามารถตรวจสอบ ปรับปรุง และพัฒนาระบบควบคุมมือเทียมได้อย่างมีประสิทธิภาพ

2.2.6 ป่าสุ่ม (Random Forest)



รูปที่ 2.4.2 โครงสร้างโมเดล Random Forest

ที่มา (<https://lengyi.medium.com/random-forest-regression-double-declining-balance-residual-value-model-6af8fd0c8709>)


ป่าสุ่มเป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบรวมผลหลายโมเดล (Ensemble Learning) ที่พัฒนาขึ้นจากแนวคิดของต้นไม้ตัดสินใจ โดยสร้างต้นไม้ตัดสินใจจำนวนมากรวมกันเป็นกลุ่มหรือป่า แต่ละต้นจะถูกฝึกด้วยข้อมูลชุดย่อยที่ได้จากการสุ่มตัวอย่างแบบบูตสแตรป (Bootstrap Sampling) จากชุด

ข้อมูลเดิม และมีการสุ่มเลือกคุณลักษณะบางส่วนเพื่อใช้ในการแบ่งข้อมูลในแต่ละโหนด ส่งผลให้ต้นไม้แต่ละต้นมีความแตกต่างกันและสามารถเรียนรู้ข้อมูลได้หลากหลายมุมมอง

ผลลัพธ์สุดท้ายของป่าสุ่มจะได้จากการลงคะแนนเสียงข้างมาก (Majority Voting) ของต้นไม้ทั้งหมดในกรณีการจำแนกประเภท หรือการหาค่าเฉลี่ยของผลลัพธ์จากต้นไม้ทั้งหมดในกรณีการพยากรณ์ค่า วิธีการดังกล่าวช่วยลดปัญหาการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป (Overfitting) ที่มักเกิดขึ้นกับต้นไม้ตัดสินใจเพียงต้นเดียว ส่งผลให้โมเดลมีความสามารถในการทำนายข้อมูลใหม่ได้ดียิ่งขึ้น นอกจากนี้ยังสามารถวิเคราะห์ความสำคัญของฟีเจอร์ว่าข้อมูลใดมีอิทธิพลต่อการตัดสินใจของโมเดลมากที่สุด

ในโครงการนี้ใช้ป่าสุ่มเป็นโมเดลหลักสำหรับการจำแนกสัญญาณกล้ำเนื้อ เนื่องจากมีความสามารถในการจัดการกับข้อมูลที่มีความซับซ้อนสูง ทนทานต่อสัญญาณรบกวนและค่าผิดปกติที่มักพบในสัญญาณกล้ำเนื้อ อีกทั้งยังสามารถรองรับข้อมูลที่มีคุณลักษณะจำนวนมากได้อย่างมีประสิทธิภาพ ส่งผลให้มีความเหมาะสมต่อการวิเคราะห์สัญญาณกล้ำเนื้อของผู้ใช้งานแต่ละบุคคล ซึ่งมีรูปแบบสัญญาณที่แตกต่างกัน และช่วยเพิ่มความแม่นยำในการควบคุมการทำงานของมือเทียมแบบเรียลไทม์

2.2.7 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)



รูปที่ 2.4.3 หลักการทำงานของ Support Vector Machine

ที่มา (<https://scikit-learn.org/stable/modules/svm.html>)

เครื่องเวกเตอร์สนับสนุนเป็นอัลกอริธึมการเรียนรู้ของเครื่องที่ใช้สำหรับการจำแนกประเภทและการพยากรณ์ข้อมูล โดยมีหลักการสำคัญคือการหาระนาบแบ่งประเภท (Hyperplane) ที่สามารถแยกข้อมูลแต่ละกลุ่มออกจากกันได้อย่างมีประสิทธิภาพที่สุด ระนาบดังกล่าวจะถูกเลือกให้มีระยะห่างจากข้อมูลของแต่ละกลุ่มมากที่สุด หรือที่เรียกว่า ระยะขอบสูงสุด (Maximum Margin) ซึ่งช่วยเพิ่มความสามารถในการจำแนกข้อมูลใหม่ได้อย่างถูกต้อง


การกำหนดระนาบแบ่งประเภทจะอาศัยจุดข้อมูลที่อยู่ใกล้ขอบเขตการแบ่งมากที่สุด ซึ่งเรียกว่า เวกเตอร์สนับสนุน (Support Vectors) โดยจุดข้อมูลเหล่านี้มีบทบาทสำคัญต่อการตัดสินใจของโมเดล ในกรณีที่ข้อมูลไม่สามารถแบ่งแยกได้ด้วยเส้นตรง เครื่องเวกเตอร์สนับสนุนสามารถใช้เทคนิคเคอร์เนล (Kernel Trick) เพื่อแปลงข้อมูลไปยังมิติที่สูงขึ้น ทำให้สามารถสร้างขอบเขตการแบ่งที่ซับซ้อนมากขึ้น

ขึ้นได้ ตัวอย่างเคอร์เนลที่นิยมใช้งาน ได้แก่ เคอร์เนลฐานรัศมี (RBF Kernel) และเคอร์เนลพหุนาม (Polynomial Kernel)

เครื่องเวกเตอร์สนับสนุนมีจุดเด่นด้านความสามารถในการจัดการข้อมูลที่มีมิติสูง และสามารถให้ผลลัพธ์ที่ดีแม้มีจำนวนข้อมูลไม่มากนัก นอกจากนี้ยังมีความสามารถในการลดผลกระทบจากค่าผิดปกติ (Outlier) ได้ในหลายกรณี จึงได้รับความนิยมในการแก้ปัญหาการจำแนกประเภทข้อมูลในงานด้านการเรียนรู้ของเครื่อง

ในโครงการนี้ใช้เครื่องเวกเตอร์สนับสนุนเป็นหนึ่งในโมเดลที่นำมาทดสอบสำหรับการจำแนกสัญญาณกล้ำเนื้อ เนื่องจากมีประสิทธิภาพสูงกับชุดข้อมูลขนาดเล็กถึงขนาดกลาง ซึ่งสอดคล้องกับข้อมูลการสอบเทียบที่เก็บจากผู้ในแต่ละคน อีกทั้งยังสามารถจำแนกรูปแบบสัญญาณที่มีความซับซ้อนได้อย่างมีประสิทธิภาพ จึงเป็นอีกทางเลือกหนึ่งที่เหมาะสมสำหรับการนำมาใช้ควบคุมการทำงานของมือเทียมแบบเรียลไทม์

2.2.8 โครงข่ายประสาทเทียม (Neural Network)



รูปที่ 2.4.4 โครงสร้างโครงข่ายประสาทเทียม

ที่มา (https://scikit-learn.org/stable/modules/neural_networks_supervised.html)


โครงข่ายประสาทเทียม เป็นอัลกอริธึมการเรียนรู้ของเครื่องที่ได้รับแรงบันดาลใจจากการทำงานของระบบประสาทในสมองมนุษย์ โดยประกอบด้วยชั้นอินพุต (Input Layer) ชั้นซ่อน (Hidden Layer) และชั้นเอาต์พุต (Output Layer) ซึ่งแต่ละชั้นประกอบด้วยโหนดจำนวนมากที่เชื่อมต่อถึงกันผ่านค่าน้ำหนัก (Weight) การส่งผ่านข้อมูลระหว่างโหนดจะถูกควบคุมด้วยฟังก์ชันกระตุ้น (Activation Function) เพื่อกำหนดว่าข้อมูลจะถูกส่งต่อไปยังชั้นถัดไปหรือไม่ ตัวอย่างฟังก์ชันกระตุ้นที่นิยมใช้ ได้แก่ เรลู (ReLU) และซิกมอยด์ (Sigmoid)

กระบวนการฝึกโครงข่ายประสาทเทียมอาศัยขั้นตอนการแพร่ย้อนกลับ (Backpropagation) ร่วมกับวิธีการลดค่าความคลาดเคลื่อนแบบไล่ระดับ (Gradient Descent) เพื่อปรับค่าน้ำหนักของการเชื่อมต่อระหว่างโหนดให้เหมาะสมที่สุด ทำให้โมเดลสามารถเรียนรู้รูปแบบและความสัมพันธ์ที่ซับซ้อนภายในข้อมูลได้อย่างมีประสิทธิภาพ โดยเฉพาะข้อมูลที่ไม่สามารถอธิบายได้ด้วยความสัมพันธ์เชิงเส้น

โครงข่ายประสาทเทียมมีจุดเด่นในการเรียนรู้ข้อมูลที่มีรูปแบบซับซ้อนและมีจำนวนตัวแปรจำนวนมาก จึงถูกนำไปประยุกต์ใช้ในงานด้านการรู้จำรูปภาพ การประมวลผลภาษา การพยากรณ์ข้อมูล และงานด้านปัญญาประดิษฐ์อีกหลากหลายประเภท

ในโครงการนี้ใช้โครงข่ายประสาทเทียมแบบมัลติเลเยอร์เพอร์เซปตรอน (Multilayer Perceptron: MLP) จากไลบรารี scikit-learn สำหรับการจำแนกสัญญาณกล้ำเนื้อ เนื่องจากสามารถเรียนรู้ความสัมพันธ์แบบไม่เป็นเชิงเส้น (Non-linear Relationship) ระหว่างคุณลักษณะต่าง ๆ ของข้อมูลได้เป็นอย่างดี ซึ่งสอดคล้องกับลักษณะของสัญญาณกล้ำเนื้อที่มีความซับซ้อนและแตกต่างกันในแต่ละบุคคล ส่งผลให้สามารถเพิ่มประสิทธิภาพในการจำแนกสัญญาณและช่วยให้การควบคุมมือเทียมมีความแม่นยำมากยิ่งขึ้น

2.2.9 แบบจำลองเชิงเส้น (Linear Model)



รูปที่ 2.4.5 หลักการทำงานของโมเดลเชิงเส้น (Logistic Regression)

ที่มา (https://scikit-learn.org/stable/modules/linear_model.html)

โมเดลเชิงเส้นเป็นกลุ่มอัลกอริธึมการเรียนรู้ของเครื่องที่สร้างความสัมพันธ์ระหว่างคุณลักษณะของข้อมูลและผลลัพธ์ในรูปแบบสมการเชิงเส้น โดยมีหลักการสำคัญคือการกำหนดค่าน้ำหนักให้กับคุณลักษณะแต่ละตัวเพื่อใช้ในการคำนวณผลลัพธ์ สำหรับงานจำแนกประเภทนิยมใช้การถดถอยลอจิสติก (Logistic Regression) ซึ่งเป็นอัลกอริธึมที่ใช้ฟังก์ชันซิกมอยด์ (Sigmoid Function) ในการแปลงค่าผลรวมเชิงเส้นให้เป็นค่าความน่าจะเป็น ของแต่ละกลุ่มข้อมูล เพื่อใช้ประกอบการตัดสินใจในการจำแนกประเภท

จุดเด่นของโมเดลเชิงเส้นคือมีความโปร่งใส และสามารถอธิบายผลการตัดสินใจได้ง่าย เนื่องจากค่าน้ำหนักของแต่ละคุณลักษณะสามารถตีความได้โดยตรงว่ามีผลต่อผลลัพธ์มากน้อยเพียงใด นอกจากนี้ยังใช้ทรัพยากรในการประมวลผลน้อย มีความรวดเร็วในการฝึกและการทำนายผล จึงมักถูกนำมาใช้เป็นโมเดลสำหรับเปรียบเทียบประสิทธิภาพกับโมเดลที่มีความซับซ้อนสูงกว่า

ในโครงการนี้ใช้โมเดลเชิงเส้นเป็นโมเดลพื้นฐานสำหรับเปรียบเทียบประสิทธิภาพกับอัลกอริธึมอื่น เช่น ป่าสุ่ม และโครงข่ายประสาทเทียม โดยหากข้อมูลสัญญาณกล้ำเนื้อของผู้ใช้งานมีลักษณะที่สามารถแบ่งแยกได้ด้วยความสัมพันธ์เชิงเส้น โมเดลเชิงเส้นอาจให้ผลลัพธ์ที่มีความแม่นยำเพียงพอต่อการใช้งานจริง ขณะเดียวกันยังใช้ทรัพยากรในการประมวลผลต่ำกว่ามาก ทำให้เหมาะสำหรับการประมวลผลแบบตลอดเวลา บน Raspberry Pi 5 ซึ่งมีข้อจำกัดด้านทรัพยากรเมื่อเทียบกับคอมพิวเตอร์ประสิทธิภาพสูง

2.2.10 การจำแนกแบบนาอ์ฟเบย์ (Naive Bayes)

$$P(x_i | y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

รูปที่ 2.4.6 หลักการทำงานของนาอ์ฟเบย์

ที่มา (https://scikit-learn.org/stable/modules/naive_bayes.html)


การจำแนกแบบเบย์อย่างไ้เดียงสา เป็นอัลกอริธึมการเรียนรู้ของเครื่องที่สร้างขึ้นจากทฤษฎีบทของเบย์ (Bayes' Theorem) ซึ่งคำนวณความน่าจะเป็นภายหลัง (Posterior Probability) ของแต่ละประเภทข้อมูล โดยอาศัยข้อสมมติฐานสำคัญที่ว่า คุณลักษณะ (Feature) แต่ละตัวมีความเป็นอิสระต่อกัน โดยมีเงื่อนไขจากประเภทข้อมูล (Conditional Independence) แม้ข้อสมมติฐานนี้มักไม่เป็นจริงทั้งหมดในข้อมูลจริง แต่ในทางปฏิบัติอัลกอริธึมนี้ยังคงให้ผลลัพธ์ที่ดีในหลายกรณี จึงเป็นที่มาของคำว่า "ไ้เดียงสา" (Naive)

รูปแบบที่ใช้ในโครงการนี้คือ Gaussian Naive Bayes ซึ่งสมมติว่าคุณลักษณะเชิงตัวเลขแต่ละตัวมีการกระจายตัวแบบปกติ (Gaussian Distribution) ภายในแต่ละประเภทข้อมูล จุดเด่นของ Naive Bayes คือมีความเร็วในการเทรนและทำนายสูงมาก ใช้ทรัพยากรในการประมวลผลต่ำ และทำงานได้ดีแม้มีข้อมูลฝึกไม่มาก จึงมักถูกใช้เป็นโมเดลพื้นฐานสำหรับเปรียบเทียบ ประสิทธิภาพกับโมเดลที่มีความซับซ้อนสูงกว่า

ในโครงการนี้ใช้ Naive Bayes จากไลบรารี scikit-learn (GaussianNB) เป็นหนึ่งในโมเดลพื้นฐานสำหรับจำแนกสัญญาณกล้ำเนื้อ เช่นเดียวกับ SVM โมเดลนี้รองรับการเทรนแบบ partial_fit ซึ่งเป็นการเทรนแบบออนไลน์จริง (อัปเดตแบบจำลองทีละส่วนจากข้อมูลใหม่ โดยไม่ต้องเทรนซ้ำจากศูนย์

ทั้งหมด) ต่างจากโมเดลอื่นส่วนใหญ่ในโครงการที่ใช้วิธี Full-refit (เทรนใหม่ทั้งหมดทุกครั้งที่ได้รอบ) ทำให้ Naive Bayes เหมาะสำหรับการทดสอบรูปแบบการเทรนแบบต่อเนื่องควบคู่กับ SVM

2.2.11 ต้นไม้แบบสุ่ม (Random Tree / Extra Tree)



รูปที่ 2.4.7 หลักการทำงานของต้นไม้แบบสุ่ม


ที่มา (<https://www.sciencedirect.com/science/chapter/edited-volume/abs/pii/B9780128219614000063>)

ต้นไม้แบบสุ่ม เป็นรูปแบบหนึ่งของอัลกอริธึมต้นไม้ตัดสินใจที่เพิ่มระดับการสุ่มเข้าไปในกระบวนการสร้างต้นไม้มากกว่าต้นไม้ตัดสินใจ แบบมาตรฐาน (เช่น C4.5 ในหัวข้อ 2.2.5) โดยแทนที่จะเลือกจุดแบ่งข้อมูล (Split Point) ที่ดีที่สุดในแต่ละคุณลักษณะเสมอ ต้นไม้แบบสุ่มจะสุ่มเลือกเกณฑ์การแบ่งข้อมูลขึ้นมาจำนวนหนึ่งแล้วเลือกเกณฑ์ที่ดีที่สุดจากกลุ่มที่สุ่มได้นั้นแทน วิธีการดังกล่าวช่วยลดความแปรปรวน (Variance) ของแบบจำลองและลดโอกาสเกิดการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป (Overfitting) เมื่อเทียบกับต้นไม้ตัดสินใจแบบมาตรฐานที่ใช้ต้นไม้เพียงต้นเดียว

ในโครงการนี้ใช้ Extra Tree จากไลบรารี scikit-learn (ExtraTreeClassifier) กำหนดความลึกสูงสุดของต้นไม้ (max_depth) เท่ากับ 5 เช่นเดียวกับ Decision Tree และ Random Forest เพื่อให้เปรียบเทียบกันได้อย่างยุติธรรมภายใต้เงื่อนไขเดียวกัน เป็นหนึ่งในโมเดลพื้นฐานสำหรับเปรียบเทียบประสิทธิภาพการจำแนกสัญญาณกล้ำเนื้อ โดยมีความรวดเร็วในการเทรนใกล้เคียงกับ ต้นไม้ตัดสินใจแบบมาตรฐาน แต่มีแนวโน้มทนทานต่อความแปรปรวนของสัญญาณรบกวนในข้อมูลได้ดีกว่าเล็กน้อยจากการสุ่มเกณฑ์การแบ่งข้อมูล

2.2.12 การรวมกลุ่มแบบแบ็กกิง (Bagging)

The Process of Bagging (Bootstrap Aggregation)




รูปที่ 2.4.8 หลักการทำงานของแบ็กกิง

ที่มา (https://medium.com/@brijesh_soni/boost-your-machine-learning-models-with-bagging-a-powerful-ensemble-learning-technique-692bfc4d1a51)

การรวมกลุ่มแบบแบ็กกิง หรือ Bootstrap Aggregating เป็นเทคนิคการรวมผลหลายแบบจำลอง (Ensemble Learning) ที่ทำงานร่วมกับแบบจำลองพื้นฐาน (Base Model) ชนิดใดก็ได้ โดยหลักการสำคัญคือการสุ่มตัวอย่างข้อมูลฝึกแบบสุ่มคืนกลับ (Bootstrap Sampling) ขึ้นมาหลายชุดจากชุดข้อมูลเดิม แล้วนำแต่ละชุดไปฝึกแบบจำลองพื้นฐานแยกจากกันเป็นจำนวนหลายตัว จากนั้นจึงรวมผลการทำงาน of แบบจำลองทั้งหมดด้วยการลงคะแนนเสียงข้างมากในกรณีการจำแนกประเภท เทคนิคนี้ช่วยลดความแปรปรวน ของแบบจำลองและเพิ่มความเสถียรของผลการทำนาย โดยเฉพาะกับแบบจำลองที่มีแนวโน้ม Overfitting ง่าย เช่น ต้นไม้ตัดสินใจ

ในโครงงานนี้ใช้ BaggingClassifier จากไลบรารี scikit-learn ห่อหุ้ม (Wrap) แบบจำลองพื้นฐานที่ผู้ดูแลระบบเลือกไว้ โดยปรับจำนวนแบบจำลองย่อย ($n_estimators$) ตามความหนักเบาของแบบจำลองพื้นฐาน กล่าวคือหากเป็นแบบจำลองที่ใช้ทรัพยากร ในการประมวลผลสูงอยู่แล้ว เช่น โครงข่ายประสาทเทียม เครื่องเวกเตอร์สนับสนุน ป่าสุ่ม XGBoost หรือ CatBoost ระบบจะลดจำนวนแบบจำลองย่อยเหลือ 6 ตัว แต่หากเป็นแบบจำลองที่เบากว่า ระบบจะใช้ 10 ตัว เพื่อควบคุมเวลาในการเทรนให้เหมาะสมกับทรัพยากร ที่จำกัดของ Raspberry Pi 5 โดยไม่ให้หน้าจอค้างระหว่างการเทรน

2.2.13 แบบอะดาบูสต์ (AdaBoost: Adaptive Boosting)




รูปที่ 2.4.9 หลักการทำงานของ AdaBoost

ที่มา (<https://scikit-learn.org/stable/modules/ensemble.html#adaboost>)]

การรวมกลุ่มแบบปรับเพิ่มน้ำหนัก หรือ Adaptive Boosting เป็นเทคนิคการรวมผลหลายแบบจำลองอีกรูปแบบหนึ่งที่แตกต่างจาก Bagging ตรงที่แบบจำลองย่อยแต่ละตัวจะถูกฝึกตามลำดับ (Sequential) ไม่ใช่แบบขนาน โดยในแต่ละรอบ ระบบจะเพิ่มน้ำหนัก ให้กับตัวอย่างข้อมูลที่แบบจำลองรอบก่อนหน้าทำนายผิดพลาด เพื่อให้แบบจำลองรอบถัดไปมุ่งเน้นเรียนรู้ตัวอย่างที่ยากขึ้น เป็นพิเศษ ผลการทำนายสุดท้ายได้จากการรวมผลของแบบจำลองย่อยทั้งหมดแบบถ่วงน้ำหนักตามความแม่นยำของแต่ละตัว เทคนิคนี้ ช่วยลดความคลาดเคลื่อนเชิงระบบ (Bias) ของแบบจำลอง และมักให้ความแม่นยำสูงขึ้นเมื่อเทียบกับแบบจำลองเดี่ยว

ในโครงงานนี้ใช้ AdaBoostClassifier จากไลบรารี scikit-learn ปรับจำนวนแบบจำลองย่อยตามความหนักเบาของแบบจำลองพื้นฐาน เช่นเดียวกับ Bagging (6 ตัวสำหรับแบบจำลองหนัก และ 15 ตัวสำหรับแบบจำลองเบา) ทั้งนี้ ระบบได้จำกัดไม่ให้ใช้ k-NN ร่วมกับ AdaBoost เนื่องจาก k-NN ไม่รองรับพารามิเตอร์น้ำหนักตัวอย่างที่ AdaBoost ต้องใช้ในการปรับน้ำหนักข้อมูล ระหว่างรอบการฝึกดังที่กล่าวไว้ในหัวข้อ k-NN นอกจากนี้ ในกรณีที่ใช้ร่วมกับ XGBoost ระบบยังได้ปรับสเกลน้ำหนักตัวอย่าง ที่ AdaBoost ส่งมาให้เหมาะสมกับการตีความของ XGBoost โดยเฉพาะ เนื่องจากไลบรารีทั้งสองตีความความหมายของน้ำหนักตัวอย่าง แตกต่างกัน ซึ่งหากไม่ปรับแก้จะทำให้ความแม่นยำของแบบจำลองลดลงอย่างมีนัยสำคัญ

2.2.14 เอ็กซ์ตรีมเกรเดียนท์บูสติง (XGBoost: Extreme Gradient Boosting)



รูปที่ 2.4.10 โลโก้ไลบรารี เอ็กซ์ตรีมเกรเดียนท์บูสติง


ที่มา (<https://www.geeksforgeeks.org/machine-learning/implementation-of-xgboost-extreme-gradient-boosting>)

เอ็กซ์ตรีมเกรเดียนท์บูสติง เป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบรวมผลหลายแบบจำลองในกลุ่ม Gradient Boosting ที่ได้รับการปรับปรุงให้มีประสิทธิภาพการประมวลผลสูงและควบคุม Overfitting ได้ดีกว่า Gradient Boosting แบบดั้งเดิม โดยอาศัยหลักการสร้างต้นไม้ตัดสินใจต่อเนื่องกันเป็นลำดับ โดยต้นไม้แต่ละต้นจะเรียนรู้เพื่อแก้ไขความคลาดเคลื่อน (Residual Error) ที่เหลือจากต้นไม้อีก่อนหน้า พร้อมทั้งมีกลไกการปรับค่าปกติ (Regularization) ในตัวเพื่อลดความซับซ้อนของแบบจำลองและป้องกันการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป

XGBoost เป็นไลบรารีอิสระที่พัฒนาสถาปัตยกรรมสอดคล้องกับรูปแบบมาตรฐานของ scikit-learn (Scikit-learn Compatible API) ทำให้สามารถนำมาใช้งานร่วมกับเครื่องมือของ scikit-learn ได้โดยตรง เช่น การห่อหุ้มด้วย Bagging หรือ AdaBoost อย่างไรก็ตาม ตั้งแต่เวอร์ชัน 1.6 เป็นต้นมา XGBoost กำหนดให้ป้ายกำกับ (Label) ของข้อมูลต้องอยู่ในรูปแบบจำนวนเต็มเรียงจากศูนย์เท่านั้น ไม่รองรับข้อความ (String) เช่น "FIST"/"OPEN" เหมือนโมเดลอื่นในโครงการนี้ ในโครงการนี้จึงพัฒนาคลาสตัวห่อหุ้มเฉพาะ (Wrapper Class) ขึ้นมาเพื่อแปลงป้ายกำกับข้อความให้เป็นจำนวนเต็มก่อนป้อนเข้า XGBoost และแปลงผลการทำนายกลับเป็นข้อความ หลังจากนั้น เพื่อให้ทำงานร่วมกับส่วนอื่นของระบบได้โดยไม่ต้องแก้ไขโค้ดจุดอื่นเพิ่มเติม

ในโครงงานนี้ กำหนดจำนวนต้นไม้ ($n_estimators$) เท่ากับ 40 ต้น ความลึกสูงสุด (max_depth) เท่ากับ 4 และอัตราการเรียนรู้ ($learning_rate$) เท่ากับ 0.3 XGBoost เป็นไลบรารีเสริมที่ต้องติดตั้งเพิ่มเติมนอกเหนือจาก scikit-learn (ผ่านคำสั่ง `pip install xgboost`) หากเครื่องที่ใช้งานไม่ได้ติดตั้งไลบรารีนี้ไว้ ระบบจะไม่แสดงตัวเลือก XGBoost ในรายการ แบบจำลองที่เลือกได้ แต่จะไม่เกิดข้อผิดพลาดกับการทำงานส่วนอื่นของระบบแต่อย่างใด

2.2.15 แคตบูสท์ (CatBoost: Categorical Boosting)




รูปที่ 2.4.11 โลโก้ไลบรารี CatBoost

ที่มา (<https://www.geeksforgeeks.org/machine-learning/catboost-ml/>)

แคตบูสท์ เป็นอัลกอริธึมการเรียนรู้ของเครื่องในกลุ่ม Gradient Boosting เช่นเดียวกับ XGBoost แต่พัฒนาขึ้นโดยมุ่งเน้น การจัดการกับคุณลักษณะเชิงกลุ่ม (Categorical Feature) ได้อย่างมีประสิทธิภาพโดยไม่ต้องแปลงข้อมูลล่วงหน้า และใช้เทคนิค Ordered Boosting ซึ่งช่วยลดปัญหาการรั่วไหลของข้อมูล (Target Leakage) ที่อาจเกิดขึ้นระหว่างกระบวนการเทรน เมื่อเทียบกับ Gradient Boosting แบบดั้งเดิม ส่งผลให้แบบจำลองมีความทนทานต่อ Overfitting มากขึ้นโดยเฉพาะกับชุดข้อมูลขนาดเล็ก

ในโครงงานนี้ใช้ CatBoost จากไลบรารีต้นฉบับ (CatBoostClassifier) กำหนดจำนวนรอบการวนซ้ำ (iterations) เท่ากับ 60 รอบ และความลึกสูงสุด (depth) เท่ากับ 4 พร้อมปิดการแสดงผล Log ระหว่างเทรน (`verbose=False`) และปิดการเขียนไฟล์ชั่วคราวลงดิสก์ (`allow_writing_files=False`) เพื่อไม่ให้เกิดกระทบกับพื้นที่จัดเก็บข้อมูลที่จำกัดของ Raspberry Pi 5 เช่นเดียวกับ XGBoost CatBoost เป็นไลบรารีเสริมที่ต้องติดตั้งเพิ่มเติม (ผ่านคำสั่ง `pip install catboost`) และจะไม่ปรากฏเป็นตัวเลือกในระบบ หากเครื่องที่ใช้งานไม่ได้ติดตั้งไลบรารีนี้ไว้เช่นเดียวกัน ทั้งนี้ CatBoost รองรับป้ายกำกับข้อความได้โดยตรงโดยไม่ต้องใช้ ตัวห่อหุ้มพิเศษเหมือน XGBoost จึงนำมาใช้งานร่วมกับส่วนอื่นของระบบได้ทันที

2.2.16 โมดูลเซนเซอร์สัญญาณกล้ามเนื้อ (EMG Sensor Module (Gravity))



รูปที่ 2.5 เซนเซอร์ตรวจจับสัญญาณกล้ามเนื้อ
ที่มา (<https://www.dfrobot.com/product-1661.html>)

โมดูลเซนเซอร์สัญญาณกล้ามเนื้อ เป็นองค์ประกอบสำคัญในการตรวจจับสัญญาณไฟฟ้าที่เกิดจากการหดตัวของกล้ามเนื้อ โดยทำหน้าที่รับสัญญาณไฟฟ้าขนาดเล็กจากผิวหนัง ขยายสัญญาณให้มีระดับที่เหมาะสม กรองสัญญาณรบกวนที่ไม่ต้องการ และส่งออกเป็นสัญญาณแอนะล็อกเพื่อให้ระบบสามารถนำไปประมวลผลต่อได้

ในโครงการนี้ โมดูลเซนเซอร์สัญญาณกล้ามเนื้อถูกติดตั้งบนผิวหนังบริเวณกล้ามเนื้อส่วนแขนที่เหลืออยู่ของผู้ใช้งาน โดยไม่จำเป็นต้องผ่าตัดหรือฝังอุปกรณ์ภายในร่างกาย สัญญาณที่ได้จะถูกส่งผ่านตัวแปลงสัญญาณแอนะล็อกเป็นดิจิทัล เพื่อแปลงข้อมูลให้อยู่ในรูปแบบดิจิทัลสำหรับการประมวลผลบน Raspberry Pi 5

ข้อมูลที่ได้จากเซนเซอร์สามารถแบ่งออกเป็นสองส่วนสำคัญ ได้แก่ ระดับความแรงของการหดตัวของกล้ามเนื้อ ซึ่งสามารถนำไปแปลความหมายเป็นคำสั่งควบคุมการทำงานของมือเทียม และรูปแบบของสัญญาณกล้ามเนื้อที่ใช้ในการฝึกและทดสอบโมเดลการเรียนรู้ของเครื่อง เพื่อจดจำลักษณะการเคลื่อนไหวหรือท่าทางที่ผู้ใช้งานต้องการสั่งงาน

ด้วยคุณสมบัติในการตรวจวัดสัญญาณได้แบบตลอดเวลา มีความแม่นยำสูง และเป็นวิธีที่ไม่ก่อให้เกิดการรุกรานต่อร่างกายผู้ใช้งาน โมดูลเซนเซอร์สัญญาณกล้ามเนื้อจึงเป็นอุปกรณ์ที่มีความเหมาะสมสำหรับการนำมาใช้ในระบบควบคุมมือเทียมอัจฉริยะของโครงการนี้

2.2.17 Servo motor mg996r



รูปที่ 2.6 Servo motor mg996r

ที่มา (<https://www.arduitronics.com/product/440/high-torque-servo-motor-mg996r-tower-pro-180-degree>)

เซอร์โวมอเตอร์ รุ่น MG996R เป็นมอเตอร์ไฟฟ้าชนิดหนึ่งที่สามารถควบคุมตำแหน่ง มุมการหมุน และความเร็วได้อย่างแม่นยำ โดยอาศัยสัญญาณพัลส์แบบปรับความกว้างพัลส์จากหน่วยควบคุมในการกำหนดตำแหน่งการหมุนของเพลา มอเตอร์ชนิดนี้มีวงจรควบคุมและระบบป้อนกลับ ติดตั้งอยู่ภายใน ทำให้สามารถรักษาค่าแรงบิดที่กำหนดไว้ได้อย่างแม่นยำและมีเสถียรภาพ

เซอร์โวมอเตอร์ มีจุดเด่นด้านแรงบิดสูง สามารถรองรับงานที่ต้องการแรงดึงหรือแรงผลักในระดับที่เหมาะสม อีกทั้งยังมีความรวดเร็วในการตอบสนองต่อคำสั่งควบคุม จึงได้รับความนิยมในการประยุกต์ใช้งานด้านหุ่นยนต์ ระบบอัตโนมัติ และอุปกรณ์ช่วยเหลือทางการแพทย์ที่ต้องการการควบคุมตำแหน่งอย่างแม่นยำ

ในโครงการนี้ใช้เซอร์โวมอเตอร์ เป็นกลไกขับเคลื่อนการเคลื่อนไหวของนิ้วมือเทียม โดยรับสัญญาณควบคุมจากพอร์ตอินพุต-เอาต์พุตของ Raspberry Pi 5 เพื่อกำหนดมุมการหมุนให้สอดคล้องกับคำสั่งที่ได้จากการวิเคราะห์สัญญาณกล้ามเนื้อ การควบคุมดังกล่าวช่วยให้มือเทียมสามารถงอและเหยียดนิ้วได้อย่างแม่นยำ มีความนุ่มนวลในการเคลื่อนไหว และสามารถหยิบจับวัตถุได้อย่างมีประสิทธิภาพ นอกจากนี้แรงบิดที่สูงของเซอร์โวมอเตอร์ยังช่วยเพิ่มความสามารถในการทำงานจริงของมือเทียมให้รองรับกิจกรรมในชีวิตประจำวันได้ดียิ่งขึ้น

2.2.18 ราสป์เบอร์รี่พาย 5 (Raspberry Pi 5)



รูปที่ 2.7 ไมโครคอมพิวเตอร์ราสป์เบอร์รี่พาย 5
ที่มา (<https://www.arduitronics.com/product/5874/>)

ราสป์เบอร์รี่พาย 5 เป็นไมโครคอมพิวเตอร์ขนาดเล็กที่ได้รับการออกแบบตามหลักสถาปัตยกรรมคอมพิวเตอร์ โดยใช้หน่วยประมวลผลแบบเออาร์เอ็ม (ARM Architecture) ซึ่งมีจุดเด่นด้านการใช้พลังงานต่ำและให้ประสิทธิภาพในการประมวลผลสูง ภายในบอร์ดประกอบด้วยหน่วยประมวลผลกลาง (Central Processing Unit: CPU) หน่วยประมวลผลกราฟิก (Graphics Processing Unit: GPU) หน่วยความจำ และวงจรเชื่อมต่ออุปกรณ์ต่าง ๆ ไว้ในแผงวงจรเดียว ทำให้มีขนาดกะทัดรัดและเหมาะสำหรับการพัฒนาระบบสมองกลฝังตัวและงานด้านอินเทอร์เน็ตของสรรพสิ่ง

ราสป์เบอร์รี่พาย 5 รองรับระบบปฏิบัติการหลายรูปแบบ และสามารถเชื่อมต่อกับอุปกรณ์ภายนอกผ่านพอร์ตอินพุต-เอาต์พุตเนกประสงค์ รวมถึงรองรับโปรโตคอลการสื่อสารต่าง ๆ เช่น I²C, UART และ SPI ทำให้สามารถนำไปประยุกต์ใช้งานด้านการควบคุมอุปกรณ์อิเล็กทรอนิกส์ การเก็บรวบรวมข้อมูลจากเซนเซอร์ และการประมวลผลข้อมูลได้อย่างมีประสิทธิภาพ

ในโครงการนี้ ราสป์เบอร์รี่พาย 5 ทำหน้าที่เป็นหน่วยประมวลผลหลักของระบบ โดยรับข้อมูลสัญญาณกล้ำมเนื่องจากโมดูลเซนเซอร์ผ่านตัวแปลงสัญญาณแอนะล็อกเป็นดิจิทัล จากนั้นนำข้อมูลเข้าสู่กระบวนการวิเคราะห์ด้วยโมเดลการเรียนรู้ของเครื่อง เพื่อจำแนกคำสั่งการเคลื่อนไหวของผู้ใช้งาน เมื่อได้ผลลัพธ์แล้ว ระบบจะส่งคำสั่งควบคุมไปยังไดรเวอร์มอเตอร์ TB6600 เพื่อขับเคลื่อนกลไกของมือเทียม นอกจากนี้ยังทำหน้าที่บันทึกข้อมูลลงใน Firebase Realtime Database และแสดงผลข้อมูลผ่านเครื่องมือสอบเทียบบนหน้าจอแบบตลอดเวลา ทำให้ผู้ใช้งานสามารถติดตามสถานะการทำงานของระบบได้อย่างต่อเนื่อง

การเลือกใช้วัสดุเบอร์รีพาย 5 ช่วยลดต้นทุนในการพัฒนาระบบ เมื่อเปรียบเทียบกับคอมพิวเตอร์อุตสาหกรรมหรืออุปกรณ์ประมวลผลเฉพาะทาง อีกทั้งยังมีความยืดหยุ่นสูง สามารถพัฒนาต่อยอดและเพิ่มความสามารถของระบบได้ในอนาคต

2.2.19 เทคโนโลยีการพิมพ์สามมิติ (3D Printing)



รูปที่ 2.8 เครื่องพิมพ์สามมิติสำหรับสร้างโครงมือเทียม
ที่มา (<https://www.creality.com/>)

เทคโนโลยีการพิมพ์สามมิติ เป็นกระบวนการสร้างชิ้นงานสามมิติด้วยการเพิ่มวัสดุทีละชั้นตามแบบจำลองดิจิทัลที่ออกแบบไว้ กระบวนการดังกล่าวอาศัยข้อมูลจากซอฟต์แวร์ออกแบบโดยใช้คอมพิวเตอร์ช่วย (Computer-Aided Design: CAD) เพื่อกำหนดรูปร่าง ขนาด และรายละเอียดของชิ้นงานก่อนเข้าสู่กระบวนการผลิตจริง

หลักการสำคัญของเทคโนโลยีการพิมพ์สามมิติแตกต่างจากกระบวนการผลิตแบบดั้งเดิมที่มักใช้การตัดหรือขึ้นรูปวัสดุ โดยจะสร้างชิ้นงานจากการสะสมวัสดุเป็นชั้น ๆ จนได้รูปร่างตามที่กำหนด วิธีการดังกล่าวช่วยลดการสูญเสียวัสดุ สามารถผลิตชิ้นงานที่มีรูปทรงซับซ้อนได้ง่าย และรองรับการผลิตชิ้นงานเฉพาะบุคคลได้อย่างมีประสิทธิภาพ นอกจากนี้ยังช่วยลดต้นทุนในการสร้างต้นแบบและลดระยะเวลาในการพัฒนาผลิตภัณฑ์เมื่อเทียบกับการผลิตที่ต้องใช้แม่พิมพ์

ในโครงการนี้ใช้เทคโนโลยีการพิมพ์สามมิติในการผลิตโครงสร้างของนิ้วมือและฝ่ามือเทียม โดยเลือกใช้พลาสติกพอลิแลกติกแอซิด (Polylactic Acid: PLA) เป็นวัสดุหลัก เนื่องจากมีน้ำหนักเบา มีความแข็งแรงเพียงพอต่อการใช้งาน และเป็นวัสดุที่เป็นมิตรต่อสิ่งแวดล้อม การออกแบบชิ้นส่วนของมือเทียมมุ่งเน้นการปรับแต่งให้เหมาะสมกับสรีระของผู้ใช้งานแต่ละบุคคลเพื่อเพิ่มความสะดวกสบายและประสิทธิภาพในการใช้งาน ซึ่งถือเป็นข้อได้เปรียบสำคัญเมื่อเปรียบเทียบกับมือเทียมที่ผลิตจากโรงงานซึ่งมักมีขนาดและรูปแบบมาตรฐาน

2.2.20 ไฟร์เบส (Firebase)



รูปที่ 2.9 แพลตฟอร์ม Firebase สำหรับจัดเก็บข้อมูลผู้ใช้งานคลาวด์
ที่มา (<https://firebase.google.com/>)

ไฟร์เบส เป็นแพลตฟอร์มสำหรับการพัฒนาแอปพลิเคชันบนคลาวด์ (Cloud Application Development Platform) ที่พัฒนาโดย Google ซึ่งให้บริการเครื่องมือและโครงสร้างพื้นฐานสำหรับการพัฒนาแอปพลิเคชันทั้งบนเว็บและอุปกรณ์เคลื่อนที่ โดยหนึ่งในบริการที่ได้รับความนิยมคือฐานข้อมูลไฟร์เบสแบบตลอดเวลา (Firebase Realtime Database) ซึ่งเป็นฐานข้อมูลแบบไม่มีโครงสร้างตาราง (NoSQL Database) ที่สามารถซิงโครไนซ์ข้อมูลระหว่างอุปกรณ์ต่าง ๆ ได้อย่างต่อเนื่อง

ฐานข้อมูลไฟร์เบสแบบตลอดเวลาจัดเก็บข้อมูลในรูปแบบต้นไม้เจสัน (JSON Tree) ซึ่งมีโครงสร้างที่ยืดหยุ่นและสามารถเข้าถึงข้อมูลได้อย่างรวดเร็ว ส่งผลให้เหมาะสำหรับระบบที่ต้องมีการรับส่งและอัปเดตข้อมูลอยู่ตลอดเวลา นอกจากนี้ยังรองรับการทำงานแบบออฟไลน์ โดยสามารถจัดเก็บข้อมูลชั่วคราวภายในอุปกรณ์ และทำการซิงโครไนซ์ข้อมูลกลับไปยังฐานข้อมูลโดยอัตโนมัติเมื่อมีการเชื่อมต่ออินเทอร์เน็ตอีกครั้ง ช่วยเพิ่มความเสถียรและความน่าเชื่อถือของระบบในสถานะที่เครือข่ายไม่เสถียร

ในโครงการนี้ใช้ฐานข้อมูลไฟร์เบสแบบตลอดเวลาในการจัดเก็บข้อมูลโปรไฟล์การสอบเทียบของผู้ใช้งานแต่ละคน ซึ่งประกอบด้วยรูปแบบสัญญาณกล้ามเนื้อที่ได้จากกระบวนการสอบเทียบพารามิเตอร์ของโมเดลการเรียนรู้ของเครื่องที่ผ่านการฝึกแล้ว และข้อมูลประวัติการใช้งานของระบบ ข้อมูลทั้งหมดจะถูกส่งจาก Raspberry Pi 5 ไปยังระบบคลาวด์ผ่านไลบรารี pyrebase เพื่อให้สามารถจัดเก็บและเรียกใช้งานได้จากทุกที่ที่มีการเชื่อมต่ออินเทอร์เน็ต

การนำไฟร์เบสมาใช้ในโครงการช่วยให้ผู้ดูแลระบบสามารถติดตามสถานะการทำงานและประวัติการใช้งานของมือเทียมจากระยะไกล รวมทั้งสามารถปรับปรุงข้อมูลการสอบเทียบหรืออัปเดตพารามิเตอร์ของโมเดลผ่านระบบคลาวด์ได้โดยไม่ต้องเชื่อมต่อกับอุปกรณ์โดยตรง ส่งผลให้การดูแลรักษาและพัฒนาระบบในระยะยาวมีความสะดวก ยืดหยุ่น และมีประสิทธิภาพมากยิ่งขึ้น

2.2.21 งานวิจัยและโครงการที่เกี่ยวข้อง (Related Works)

คมสันต์ เหลี่ยมมะ และคณะ (2561) ได้ทำการศึกษาวิจัยเชิงพรรณนาเรื่องการบาดเจ็บที่เกี่ยวข้องเนื่องจากการทำงานและพฤติกรรมการทำงานที่ปลอดภัยของพนักงานโรงงานอุตสาหกรรมผลิตชิ้นส่วนรถยนต์ในจังหวัดระยอง จำนวน 386 คน โดยเก็บรวบรวมข้อมูลด้วยแบบสอบถามและวิเคราะห์ข้อมูลด้วยสถิติเชิงพรรณนา ผลการศึกษาพบว่าในช่วง 3 เดือนที่ผ่านมากลุ่มตัวอย่างเคยได้รับบาดเจ็บจากการทำงานร้อยละ 6.5 โดยพบการบาดเจ็บมากที่สุดในขั้นตอนการตัด ร้อยละ 36.0 และอวัยวะที่ได้รับบาดเจ็บมากที่สุดคือนิ้วมือ ร้อยละ 53.8 ซึ่งส่วนใหญ่ร้อยละ 76.9 เป็นการบาดเจ็บเล็กน้อยที่ไม่ต้องหยุดงาน สาเหตุของการบาดเจ็บส่วนใหญ่เกิดจากชิ้นงานหรือสิ่งของตัด บาด ทิ่มแทง ร้อยละ 61.5 ส่วนพฤติกรรมการทำงานที่ปลอดภัยโดยรวมของกลุ่มตัวอย่างอยู่ในระดับปานกลาง ร้อยละ 74.9 ทั้งด้านการใช้อุปกรณ์ป้องกันอันตรายส่วนบุคคล การใช้เครื่องมือเครื่องจักรอย่างถูกวิธี และการปฏิบัติตามกฎระเบียบความปลอดภัยในการทำงาน ผู้วิจัยเสนอแนะให้พยาบาลอาชีวอนามัยและทีมงานที่เกี่ยวข้องให้ความสำคัญกับการเสริมสร้างพฤติกรรมการทำงานที่ปลอดภัยแก่พนักงานในโรงงานอุตสาหกรรมที่ต้องทำงานกับเครื่องจักรและอุปกรณ์มีคมอย่างต่อเนื่อง งานวิจัยนี้สะท้อนให้เห็นว่าการบาดเจ็บที่นิ้วมือและมือจากการทำงานกับเครื่องจักรในภาคอุตสาหกรรมยังคงเป็นปัญหาสำคัญที่อาจนำไปสู่ความพิการหรือการสูญเสียอวัยวะส่วนปลายของแขนได้ ซึ่งเป็นข้อมูลพื้นฐานสำคัญที่สนับสนุนความจำเป็นของการพัฒนาโมเดลที่ควบคุมด้วยสัญญาณกล้ามเนื้อในโครงการนี้ เพื่อรองรับผู้ที่สูญเสียอวัยวะมือหรือนิ้วมือจากอุบัติเหตุในการทำงาน

พุดตาน พันธุ์เนตร และคณะ (2561) ได้ศึกษาการวิเคราะห์และพยากรณ์ความต้องการกำลังคนด้านสุขภาพสำหรับระบบบริการระดับทุติยภูมิของประเทศไทยในปี พ.ศ. 2569 โดยประยุกต์ใช้แบบจำลองอ้างอิงการใช้บริการ (Utilization-Based Model) ร่วมกับแนวคิดการวิเคราะห์กำลังคนด้านสุขภาพของ Segal และการวิเคราะห์ความอ่อนไหว เพื่อประเมินความต้องการบุคลากรทางการแพทย์ในอนาคต จากการศึกษาพบว่า ความต้องการกำลังคนด้านสุขภาพในทุกสาขาวิชาชีพมีแนวโน้มเพิ่มขึ้นจากปี พ.ศ. 2556 โดยเฉลี่ยประมาณร้อยละ 9 อันเป็นผลมาจากการเปลี่ยนแปลงโครงสร้างประชากรเข้าสู่สังคมผู้สูงอายุ ส่งผลให้ความต้องการใช้บริการทางการแพทย์และการฟื้นฟูสมรรถภาพเพิ่มสูงขึ้น โดยเฉพาะบุคลากรด้านกายภาพบำบัดและการฟื้นฟูผู้พิการ

งานวิจัยนี้มีความเกี่ยวข้องกับโครงการ เนื่องจากสะท้อนให้เห็นถึงแนวโน้มการเพิ่มขึ้นของผู้สูงอายุและผู้พิการที่ต้องการการฟื้นฟูสมรรถภาพ ขณะที่จำนวนบุคลากรทางการแพทย์และนักกายภาพบำบัดมีอยู่อย่างจำกัด ดังนั้นการพัฒนาโมเดลที่ควบคุมด้วยสัญญาณกล้ามเนื้อที่มีต้นทุนต่ำและใช้งานได้ง่ายสะดวก จึงเป็นแนวทางหนึ่งที่สามารถช่วยสนับสนุนการฟื้นฟูสมรรถภาพของผู้พิการ ลดภาระของบุคลากรทางการแพทย์ และเพิ่มโอกาสในการเข้าถึงอุปกรณ์ช่วยเหลือของผู้ใช้งานในอนาคต

มณีนีฉัตร มาสมภพ (2546) ได้ศึกษาปัญหา ความต้องการ และระดับความพึงพอใจของผู้มารับบริการด้านเบี้ยยังชีพ เงินสงเคราะห์ครอบครัว และกายอุปกรณ์ ณ สำนักส่งเสริมและพิทักษ์คนพิการ โดยใช้การวิเคราะห์ตารางไขว้และสถิติไคสแควร์ (Chi-Square) เพื่อศึกษาความสัมพันธ์ระหว่างปัจจัยส่วน

บุคคลกับความรู้ ความต้องการ ปัญหา และความพึงพอใจของผู้รับบริการ ผลการศึกษาพบว่าผู้มารับบริการส่วนใหญ่เป็นผู้พิการทางกายหรือการเคลื่อนไหว และมีความพึงพอใจต่อสถานที่และการให้บริการของเจ้าหน้าที่ในระดับสูง อย่างไรก็ตาม ผู้รับบริการมีความพึงพอใจต่ำที่สุดในด้านการได้รับข้อมูลข่าวสารเกี่ยวกับสวัสดิการ และยังพบว่ากายอุปกรณ์เป็นบริการที่มีผู้มาขอรับน้อยกว่าสวัสดิการประเภทอื่น นอกจากนี้ ปัจจัยด้านเพศ อายุ ระดับการศึกษา อาชีพ และประเภทความพิการ มีความสัมพันธ์กับความรู้ ความต้องการ และปัญหาในการเข้าถึงบริการอย่างมีนัยสำคัญทางสถิติ

งานวิจัยนี้มีความเกี่ยวข้องกับโครงการ เนื่องจากสะท้อนให้เห็นถึงข้อจำกัดในการเข้าถึงกายอุปกรณ์และข้อมูลด้านสวัสดิการของผู้พิการในประเทศไทย ซึ่งยังไม่สามารถตอบสนองความต้องการได้อย่างทั่วถึง ข้อมูลดังกล่าวสนับสนุนความสำคัญของการพัฒนาเมื่อเทียมควบคุมด้วยสัญญาณกล้ามเนื้อที่มีต้นทุนเหมาะสมและเข้าถึงได้ง่าย เพื่อเพิ่มทางเลือกในการใช้งานกายอุปกรณ์สำหรับผู้พิการแขนขา และช่วยยกระดับคุณภาพชีวิตของผู้ใช้งานในระยะยาว

Carey, S. L. และคณะ (2015) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเพื่อเปรียบเทียบความแตกต่างระหว่างเมื่อเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อ (Myoelectric Prosthesis) และเมื่อเทียมแบบควบคุมด้วยแรงจากร่างกาย (Body-Powered Prosthesis) โดยทำการสืบค้นข้อมูลจากฐานข้อมูลทางวิชาการจำนวน 9 แหล่ง ได้แก่ PubMed, CINAHL, RECAL Legacy, Cochrane Database of Systematic Reviews, Cochrane Clinical Trials Registry, EMBASE, PMC-NIH, Web of Science และ Google Scholar จากนั้นคัดกรองบทความที่เกี่ยวข้องจำนวน 462 ฉบับตามเกณฑ์การคัดเข้าและคัดออก จนเหลือ 31 ฉบับสำหรับการวิเคราะห์เชิงคุณภาพ และสรุปเป็นข้อความหลักฐานเชิงประจักษ์ (Empirical Evidence Statement: EES) จำนวน 11 ประเด็น

ผลการศึกษาพบว่าเมื่อเทียมแบบควบคุมด้วยแรงจากร่างกายมีข้อได้เปรียบในด้านความทนทาน ใช้ระยะเวลาในการฝึกใช้งานน้อยกว่า ต้องการการปรับแต่งและการบำรุงรักษาน้อยกว่า รวมถึงให้ข้อมูลป้อนกลับเชิงสัมผัส (Sensory Feedback) ที่ชัดเจน เนื่องจากระบบสายเคเบิลและฮาร์ดแวร์ช่วยให้ผู้ใช้รับรู้ระดับการเปิด-ปิดของเมื่อเทียมได้แม้ในสถานะที่ไม่สามารถมองเห็นได้โดยตรง

ในขณะเดียวกัน เมื่อเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อมีข้อได้เปรียบด้านความสวยงาม เนื่องจากมีรูปลักษณ์ใกล้เคียงมือจริงมากกว่า เหมาะสำหรับงานที่ต้องใช้แรงไม่มาก และมีแนวโน้มช่วยลดอาการปวดจากแขนขาที่ไม่มีอยู่จริงเมื่อมีการใช้งานอย่างต่อเนื่อง อย่างไรก็ตาม ผลการศึกษาพบว่าอัตราการเลิกใช้งาน (Rejection Rate) ของเมื่อเทียมทั้งสองประเภทไม่แตกต่างกันอย่างชัดเจน โดยเมื่อเทียมแบบแรงจากร่างกายมีอัตราการเลิกใช้งานเฉลี่ยร้อยละ 26 และเมื่อเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อมีอัตราการเลิกใช้งานเฉลี่ยร้อยละ 23

งานวิจัยสรุปว่าหลักฐานเชิงประจักษ์ในปัจจุบันยังไม่เพียงพอที่จะระบุได้ว่าเมื่อเทียมประเภทใดมีความเหนือกว่าอย่างชัดเจน การเลือกใช้งานจึงควรพิจารณาตามความต้องการเฉพาะบุคคล ลักษณะการใช้งาน และบริบทของผู้ใช้เป็นสำคัญ ซึ่งข้อค้นพบนี้มีความเกี่ยวข้องกับโครงการ เนื่องจากสนับสนุน

แนวคิดในการพัฒนาเมื่อเทียบควบคุมด้วยสัญญาณกล้ามเนื้อที่ไม่เพียงคำนึงถึงประสิทธิภาพการทำงาน แต่ ยังต้องให้ความสำคัญกับความสวยงาม ความเหมาะสม และความต้องการของผู้ใช้งานควบคู่กันไปด้วย

Chadwell, A. และคณะ (2016) ได้กล่าวว่าผู้ใช้งานมือเทียมที่ควบคุมด้วยสัญญาณกล้ามเนื้อ มักประสบปัญหาในการควบคุมอุปกรณ์ ซึ่งอาจนำไปสู่พฤติกรรมการใช้งานแบบเฉื่อยชา หรือการเลิกใช้ งานโดยสิ้นเชิง และส่งผลให้เกิดการใช้งานแขนข้างที่สมบูรณ์มากเกินไป ในทางกลับกัน ระบบมือเทียมที่ ใช้งานจริงในเชิงคลินิกส่วนใหญ่ยังเป็นระบบวงเปิด ซึ่งไม่มีข้อมูลป้อนกลับกลับไปยังผู้ใช้งานอย่างเพียงพอ

แม้ว่าจะมีการพัฒนาระบบป้อนกลับเชิงสัมผัส เพื่อเพิ่มประสิทธิภาพการควบคุมแบบวงปิด แต่ ผลการศึกษาบางส่วนพบว่าความสามารถในการคาดเดาการตอบสนองของมือเทียม อาจมีความสำคัญไม่ แแพ้หรือมากกว่าการมีข้อมูลป้อนกลับโดยตรง ดังนั้นผู้วิจัยจึงได้พัฒนาโปรโตคอลสำหรับประเมินปัจจัย สำคัญในระบบควบคุมมือเทียม 2 ด้าน ได้แก่ ทักษะในการสร้างสัญญาณไฟฟ้ากล้ามเนื้อของผู้ใช้ และ ความไม่แน่นอนของระบบรับสัญญาณ

การประเมินทักษะดังกล่าววัดจากความเร็วและความแม่นยำในการสร้างสัญญาณ โดยใช้ แบบทดสอบเวลาตอบสนองอย่างง่าย และเวลาตอบสนองแบบเลือก ตามแนวคิดการลบของดอนเดอร์ส เพื่อวิเคราะห์ระยะเวลาที่ใช้ในการตัดสินใจของผู้ใช้งาน ส่วนความไม่แน่นอนของระบบเกิดจาก ความสัมพันธ์ระหว่างอิเล็กโทรดกับผิวหนังและความกระชับของเบ้าซ็อกเก็ตซึ่งส่งผลต่อความเสถียรของ สัญญาณที่ตรวจวัดได้

ปัจจัยทั้งสองถูกนำไปเชื่อมโยงกับความสามารถในการใช้งานจริง ซึ่งประเมินผ่านภารกิจการ หยิบจับวัตถุทรงกระบอกหลายชิ้นตอน โดยวัดอัตราความสำเร็จ ระยะเวลาในการทำภารกิจ คุณภาพการ เคลื่อนไหวด้วยเซนเซอร์วัดความเร็ว และพฤติกรรมกรมองด้วยเครื่องติดตามการเคลื่อนไหวของดวงตา รวมถึงการใช้งานในชีวิตประจำวัน ที่วัดผ่านเครื่องวัดความเร็วที่สวมบริเวณข้อมือทั้งสองข้างเป็น ระยะเวลา 1 สัปดาห์

ผลการศึกษาพบว่าผู้ใช้งานมือเทียมมีเวลาตอบสนองเฉลี่ยอยู่ที่ประมาณ 270–420 มิลลิวินาที ซึ่งช้ากว่าค่าของกล้ามเนื้อปกติที่ประมาณ 190 มิลลิวินาที นอกจากนี้ยังพบว่าความไม่เสถียร ของเบ้าซ็อกเก็ตอาจทำให้เกิดการตอบสนองที่ไม่พึงประสงค์ เช่น การสั่งเปิดมือแต่กลับเกิดการปิดมือแทน ในบางครั้ง

งานวิจัยนี้สรุปว่าทั้งทักษะของผู้ใช้ในการสร้างสัญญาณกล้ามเนื้อและความเสถียรของระบบรับ สัญญาณมีผลอย่างมากต่อประสิทธิภาพการควบคุมมือเทียม ซึ่งมีความเกี่ยวข้องโดยตรงกับโครงการนี้ใน การออกแบบกระบวนการสอบเทียบสัญญาณกล้ามเนื้อ (Calibration) และการจัดเก็บข้อมูลโปรไฟล์ เฉพาะบุคคลในฐานะข้อมูล เพื่อเพิ่มความแม่นยำและความเสถียรในการควบคุมมือเทียมต้นแบบในระบบ ของโครงการ

ten Kate, J. และคณะ (2017) ได้ทำการทบทวนวรรณกรรมเกี่ยวกับมือเทียมแขนส่วนบนที่ ผลิตด้วยเทคโนโลยีการพิมพ์สามมิติ โดยรวบรวมข้อมูลจากฐานข้อมูลทางวิชาการ Scopus และ Web of Science ร่วมกับแหล่งข้อมูลออนไลน์ที่เกี่ยวข้องกับเทคโนโลยีการพิมพ์สามมิติ ได้แก่

enablingthefuture.org, 3dprint.com และ 3ders.org จนได้อุปกรณ์มือเทียมที่นำมาวิเคราะห์ทั้งสิ้น 58 ชิ้น

ผลการจำแนกประเภทพบว่าอุปกรณ์เหล่านี้แบ่งตามระดับการตัดแขนได้เป็น มือหรือมือบางส่วน 18 ชิ้น แขนส่วนล่าง 37 ชิ้น และแขนส่วนบน 3 ชิ้น ขณะเดียวกันเมื่อแบ่งตามลักษณะการขับเคลื่อน พบว่าเป็นแบบพาสซีฟอยู่กึ่งที่ 2 ชิ้น แบบพาสซีฟปรับได้ 1 ชิ้น แบบควบคุมด้วยแรงจากร่างกาย 32 ชิ้น และแบบขับเคลื่อนจากภายนอก 23 ชิ้น โดยในกลุ่มหลังส่วนใหญ่ใช้ระบบควบคุมด้วยสัญญาณกล้ามเนื้อ จำนวน 20 ชิ้น

ด้านน้ำหนักของอุปกรณ์พบว่ามีเพียง 11 ชิ้นจากทั้งหมด 58 ชิ้นที่ระบุน้ำหนักอย่างชัดเจน โดยมีช่วงน้ำหนักตั้งแต่ 71 กรัมจนถึง 2,000 กรัมสำหรับแขนเทียมเต็มรูปแบบ ซึ่งใกล้เคียงกับน้ำหนักเฉลี่ยของมือมนุษย์ที่ประมาณ 400 ± 90 กรัม ในด้านกลไกการทำงานพบว่าส่วนใหญ่ใช้สายเคเบิลหรือเชือกในการงอนิ้ว (Flexion) และใช้กลไก หรือยางยืดในการเหยียดนิ้ว ตามหลักการปิดด้วยความสมัครใจ

ในด้านเทคโนโลยีการผลิต พบว่าเทคนิคการพิมพ์แบบหลอมเส้นพลาสติก เป็นวิธีที่ได้รับความนิยมสูงที่สุด โดยมีจำนวนถึง 46 จาก 58 ชิ้น เนื่องจากสามารถใช้เครื่องพิมพ์ราคาประหยัดได้ประมาณ 2,000 ดอลลาร์สหรัฐ และใช้งานได้ง่าย แม้จะมีข้อจำกัดด้านความละเอียดของพื้นผิวเมื่อเทียบกับเทคนิคอื่น วัสดุที่นิยมใช้ ได้แก่ ABS และ PLA สำหรับต้นทุนการผลิต พบว่าอุปกรณ์ที่มีการระบุข้อมูลต้นทุนมีค่าใช้จ่ายอยู่ระหว่าง 5–500 ดอลลาร์สหรัฐ ซึ่งต่ำกว่ามือเทียมเชิงพาณิชย์แบบควบคุมด้วยแรงจากร่างกาย (4,000–10,000 ดอลลาร์สหรัฐ) และมือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อเชิงพาณิชย์ (25,000–75,000 ดอลลาร์สหรัฐ) อย่างมาก

อย่างไรก็ตาม งานวิจัยยังระบุว่ายังขาดหลักฐานเชิงประจักษ์เกี่ยวกับความคงทน การยอมรับของผู้ใช้งาน และประสิทธิภาพในการใช้งานจริงของมือเทียมที่ผลิตด้วยการพิมพ์สามมิติ อีกทั้งยังชี้ว่าการพิมพ์สามมิติไม่ได้มีต้นทุนต่ำกว่าวิธีการผลิตแบบดั้งเดิมเสมอไป เช่น การฉีดขึ้นรูป แต่มีข้อได้เปรียบสำคัญในด้านการออกแบบเฉพาะบุคคล เช่น รูปทรง ขนาด สี และความเหมาะสมกับผู้ใช้งาน โดยไม่ต้องปรับเปลี่ยนกระบวนการผลิตเชิงอุตสาหกรรม

งานวิจัยนี้มีความเกี่ยวข้องกับโครงการ เนื่องจากสนับสนุนการเลือกใช้เทคโนโลยีการพิมพ์สามมิติแบบหลอมเส้นพลาสติก (FDM) ร่วมกับวัสดุ PLA ในการผลิตโครงสร้างมือเทียมต้นแบบ ด้วยเหตุผลด้านต้นทุนต่ำ ความสะดวกในการเข้าถึง และความสามารถในการปรับแต่งให้เหมาะสมกับสรีระของผู้ใช้งานแต่ละบุคคล

Edwards, A. L. และคณะ (2016) ได้ทำการศึกษาการประยุกต์ใช้การเรียนรู้ของเครื่อง ในการควบคุมมือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อแบบตลอดเวลา) โดยออกแบบการทดลองเชิงกรณีศึกษา (Case Series) เพื่อเปรียบเทียบวิธีการควบคุมแบบสลับฟังก์ชัน จำนวน 2 รูปแบบ ได้แก่ การควบคุมแบบไม่ปรับตัว และการควบคุมแบบปรับตัวได้ ซึ่งอาศัยการเรียนรู้และการพยากรณ์แบบตลอดเวลาด้วยเทคนิค General Value Functions ที่อยู่ภายใต้กรอบการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning)

การทดลองแบ่งออกเป็นสองส่วน ส่วนแรกให้ผู้พิการแขนขาระดับต้นแขน 1 คน และผู้ที่มีร่างกายสมบูรณ์ 1 คน ทดลองควบคุมแขนกลในการฝึกพื้นฐาน ส่วนที่สองให้ผู้เข้าร่วมที่มีร่างกายสมบูรณ์ 3 คน ควบคุมแขนกล Bento Arm ซึ่งมี 5 องศาอิสระ ในการฝึก Box-and-Blocks ที่มีความซับซ้อนมากขึ้น โดยวัดจำนวนครั้งและระยะเวลาในการสลับฟังก์ชันของข้อต่อแขนกลระหว่างการทำภารกิจ

ผลการศึกษาพบว่า การควบคุมแบบปรับตัวได้สามารถลดจำนวนครั้งและระยะเวลาในการสลับฟังก์ชันลงได้อย่างมีนัยสำคัญเมื่อเทียบกับการควบคุมแบบเดิมในทั้งสองภารกิจ โดยในการฝึกพื้นฐานผู้พิการแขนขาสามารถลดเวลาในการสลับฟังก์ชันได้เฉลี่ยประมาณ 20 วินาทีต่อการทดลองระยะเวลา 3 นาที หรือคิดเป็นร้อยละ 11 ของเวลารวม ส่วนในภารกิจที่ซับซ้อนขึ้น ผู้ใช้งานสามารถลดระยะเวลาในการทำภารกิจได้สูงสุดประมาณร้อยละ 20 ในช่วงท้ายของการทดลอง

งานวิจัยนี้สรุปว่าการเรียนรู้และการพยากรณ์เจตนาของผู้ใช้แบบตลอดเวลาที่มีศักยภาพในการลดภาระการควบคุม และเพิ่มประสิทธิภาพในการใช้งานมือเทียมที่มีหลายองศาอิสระ โดยข้อค้นพบดังกล่าวมีความเกี่ยวข้องกับโครงการนี้ เนื่องจากสนับสนุนแนวทางการนำเทคนิคการเรียนรู้ของเครื่องมาประยุกต์ใช้ร่วมกับการประมวลผลสัญญาณกล้ามเนื้อ เพื่อจำแนกเจตนาการเคลื่อนไหวของผู้ใช้บน Raspberry Pi 5 ให้มีความแม่นยำและตอบสนองได้เหมาะสมมากขึ้น แทนการใช้การควบคุมแบบสลับฟังก์ชันเพียงอย่างเดียว

Igual, C. และคณะ (2019) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับการควบคุมมือเทียมแขนส่วนบนด้วยสัญญาณคลื่นไฟฟ้ากล้ามเนื้อ โดยนำเสนอกรอบแนวคิดของวงรอบการควบคุมแบบปิด ซึ่งประกอบด้วย 4 ขั้นตอนหลัก ได้แก่ การเก็บสัญญาณกล้ามเนื้อจากกล้ามเนื้อแขนส่วนที่เหลือ การประมวลผลสัญญาณด้วยเทคนิคการเรียนรู้ของเครื่อง เพื่อแปลงเป็นสัญญาณควบคุม การประมาณผลลัพธ์การเคลื่อนไหวของมือเทียม และการให้ข้อมูลป้อนกลับแก่ผู้ใช้งาน

ในด้านการเก็บสัญญาณ ผู้วิจัยรายงานว่าการวิจัยส่วนใหญ่ใช้จำนวนช่องสัญญาณกล้ามเนื้อระหว่าง 4–12 ช่อง โดยมีความถี่การสุ่มตัวอย่างที่ประมาณ 1,000 เฮิรตซ์ ตามทฤษฎี Nyquist–Shannon และมีการกำหนดขนาดหน้าต่างสัญญาณ สำหรับการสกัดคุณลักษณะอยู่ในช่วง 100–125 มิลลิวินาที เนื่องจากหน้าต่างที่มีขนาดเล็กเกินไป (ต่ำกว่า 100 มิลลิวินาที) จะส่งผลให้ประสิทธิภาพของระบบลดลง

ในขั้นตอนการเรียนรู้ พบว่าวิธีการจำแนกประเภท เป็นแนวทางที่นิยมในงานประยุกต์จริง เนื่องจากใช้ทรัพยากรคำนวณต่ำและมีความทนทาน โดยมักใช้พีเจอร์ในโดเมนเวลา เช่น Root Mean Square (RMS) ซึ่งเหมาะสำหรับการหัตถ์ของกล้ามเนื้อระดับสูง และ Mean Absolute Value (MAV) ซึ่งเหมาะสำหรับการหัตถ์ระดับต่ำหรือภาวะกล้ามเนื้อล้า ร่วมกับตัวจำแนก Linear Discriminant Analysis (LDA) ซึ่งให้ความสมดุลระหว่างความแม่นยำและความซับซ้อนในการประมวลผล ขณะที่วิธีการถดถอย (Regression) แม้จะให้การควบคุมที่ต่อเนื่องและเป็นธรรมชาติมากกว่า แต่ยังมีข้อจำกัดในการควบคุมที่มีหลายองศาอิสระ

นอกจากนี้ งานวิจัยยังชี้ให้เห็นปัญหาความไม่นิ่งของสัญญาณกล้ามเนื้อ ในสภาวะการใช้งานจริง ซึ่งเกิดจากการเปลี่ยนตำแหน่งแขน การเลื่อนของอิเล็กโทรด เหนือ และความล้าของกล้ามเนื้อ ส่งผลให้โมเดลที่มีประสิทธิภาพสูงในสภาพแวดล้อมควบคุมอาจทำงานได้ลดลงเมื่อใช้งานจริงนอกห้องปฏิบัติการ

งานวิจัยสรุปว่าช่องว่างระหว่างงานวิจัยเชิงวิชาการและการใช้งานเชิงพาณิชย์ยังคงเป็นประเด็นสำคัญ พร้อมเสนอให้พัฒนาโปรโตคอลการสอบเทียบที่ใช้งานง่ายสำหรับผู้ใช้งานทั่วไป ซึ่งมีความเกี่ยวข้องโดยตรงกับโครงการนี้ในการกำหนดแนวทางเลือกจำนวนช่องสัญญาณ ความถี่การสุ่มตัวอย่าง ขนาดหน้าต่างสัญญาณ และการเลือกฟีเจอร์ในโดเมนเวลาสำหรับการใช้งานไลบรารี scikit-learn บน Raspberry Pi 5 รวมถึงการออกแบบกระบวนการสอบเทียบเพื่อเพิ่มความเสถียรของระบบในสภาวะการใช้งานจริง

Segura, D. และคณะ (2024) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับมือเทียมแขนส่วนบน โดยจำแนกตามระดับการตัดแขน (Level of Amputation) ได้แก่ ระดับการตัดผ่านกระดูกฝ่ามือ ระดับการตัดผ่านข้อมือ ระดับการตัดผ่านกระดูกปลายแขนใต้ข้อศอก และระดับการตัดผ่านกระดูกต้นแขนเหนือข้อศอก โดยทำการสืบค้นข้อมูลจากฐานข้อมูลทางวิชาการ ได้แก่ Scopus, IEEE Xplore, Springer, PubMed, Frontiers และ Espacenet ในช่วงปี ค.ศ. 2018–2023 ตามแนวทาง PRISMA จนได้อุปกรณ์มือเทียมที่นำมาวิเคราะห์ทั้งสิ้น 90 ชิ้น ซึ่งประกอบด้วยบทความวิชาการ สิทธิบัตร และผลิตภัณฑ์เชิงพาณิชย์

ผลการศึกษาพบว่าวิธีการควบคุมที่ได้รับความนิยมสูงที่สุดคือการควบคุมด้วยสัญญาณกล้ามเนื้อ (Myoelectric Control) คิดเป็นร้อยละ 44.44 ของอุปกรณ์ทั้งหมด รองลงมาคือระบบที่ไม่มีการควบคุมอัตโนมัติร้อยละ 22.22 และระบบกลไกล้วนร้อยละ 13.33 โดยพบว่าระดับการตัดแขนใต้ข้อศอกเป็นกลุ่มที่มีการพัฒนามากที่สุดจำนวน 40 ชิ้น เนื่องจากมีพื้นที่เพียงพอสำหรับติดตั้งองค์ประกอบของระบบโดยไม่ต้องใช้โครงสร้างเสริมเพิ่มเติม

ในด้านระดับความพร้อมทางเทคโนโลยี (Technology Readiness Level: TRL) พบว่าไม่มีอุปกรณ์ใดที่อยู่ในระดับ TRL 8 ซึ่งสะท้อนถึงช่องว่างระหว่างการพัฒนาต้นแบบในห้องปฏิบัติการกับการนำไปใช้งานจริงในเชิงพาณิชย์ โดยเฉพาะในขั้นตอนการทดสอบในสภาพแวดล้อมจริงและการขอรับรองมาตรฐานก่อนการจำหน่าย

สำหรับมือเทียมในระดับแขนใต้ข้อศอก ซึ่งมีความใกล้เคียงกับขอบเขตของโครงการนี้ พบว่ามีน้ำหนักอยู่ในช่วงประมาณ 100–980 กรัม และมีองศาอิสระ (Degrees of Freedom) อยู่ระหว่าง 0–20 องศา โดยมือเทียมเชิงพาณิชย์บางรุ่น เช่น Max Bionic สามารถรองรับรูปแบบการจับที่ตั้งโปรแกรมไว้ล่วงหน้าได้มากถึง 30 รูปแบบ

นอกจากนี้ งานวิจัยยังชี้ให้เห็นประเด็นด้านการเข้าถึง โดยระบุว่าผู้พิการแขนขาดประมาณ 4 ใน 5 ของโลกอาศัยอยู่ในประเทศกำลังพัฒนา ขณะที่มือเทียมเชิงพาณิชย์ระดับสูง เช่น LUKE Arm

สำหรับผู้พิการระดับแขนเหนือข้อศอกมีราคาสูงถึงประมาณ 100,000 ดอลลาร์สหรัฐ ซึ่งถือเป็นข้อจำกัดสำคัญในการเข้าถึงอุปกรณ์ของผู้ใช้งานส่วนใหญ่

งานวิจัยนี้มีความเกี่ยวข้องกับโครงการ เนื่องจากช่วยกำหนดกรอบการออกแบบมือเทียมต้นแบบให้สอดคล้องกับแนวโน้มในปัจจุบัน โดยเฉพาะในระดับแขนใต้ข้อศอกทั้งในด้านน้ำหนัก งบค่า อีสระ และวิธีการควบคุมด้วยสัญญาณกล้ามเนื้อ อีกทั้งยังสนับสนุนแนวทางการพัฒนามือเทียมต้นทุนต่ำที่สามารถเข้าถึงได้ง่ายสำหรับผู้พิการในประเทศไทย

Guo, K. และคณะ (2567) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับความก้าวหน้าของมือเทียมเชิงชีวลักษณะ โดยครอบคลุม 3 ด้านหลัก ได้แก่ กลไกการควบคุม การให้ข้อมูลป้อนกลับเชิงสัมผัส และการออกแบบเชิงกล โดยผู้วิจัยได้จำแนกโครงสร้างการขับเคลื่อนของมือเทียมออกเป็น 3 รูปแบบหลัก ได้แก่ การขับเคลื่อนด้วยเอ็น การขับเคลื่อนด้วยก้านโยง และการขับเคลื่อนด้วยมอเตอร์โดยตรง (Motor-Driven) ซึ่งพบว่าโครงสร้างแบบก้านโยงมีข้อได้เปรียบในด้านความแข็งแรง ความง่ายในการผลิตและการบำรุงรักษา รวมถึงสามารถให้แรงส่งออกได้สูง

ในด้านการควบคุม งานวิจัยนี้ยืนยันว่าการควบคุมด้วยสัญญาณกล้ามเนื้อ ยังเป็นวิธีที่มีความแม่นยำสูงและสามารถจำแนกท่าทางได้หลากหลายมากกว่าการควบคุมด้วยคลื่นสมอง และการเคลื่อนไหวลูกตา โดยได้รวบรวมผลการศึกษาเปรียบเทียบขั้นตอนวิธีการเรียนรู้ของเครื่อง สำหรับการจำแนกท่าทางมือจากสัญญาณกล้ามเนื้อ พบว่าโครงข่ายประสาทเทียม ที่พิจารณาความแตกต่างทางเพศของผู้ใช้ให้ความแม่นยำสูงสุดถึงร้อยละ 98.4 ขณะที่ตัวจำแนกประเภท K-Nearest Neighbor (KNN) และ เครื่องเวกเตอร์สนับสนุน ให้ความแม่นยำร้อยละ 94 และ 94.2 ตามลำดับ

นอกจากนี้ยังมีการศึกษาความสัมพันธ์ระหว่างจำนวนช่องสัญญาณกล้ามเนื้อกับความแม่นยำในการจำแนก โดยพบว่าการใช้ 7 ช่องสัญญาณให้ความแม่นยำเฉลี่ยร้อยละ 90.52 ซึ่งถือเป็นจุดสมดุลระหว่างความแม่นยำและการประมวลผล สำหรับด้านลักษณะทางกายภาพของมือเทียม ผู้วิจัยรายงานว่าน้ำหนักมือนมนุษย์โดยเฉลี่ยอยู่ที่ประมาณ 426 กรัม ขณะที่มือเทียมเชิงพาณิชย์ส่วนใหญ่อยู่ที่ประมาณ 500 กรัม โดยรุ่นที่เป็นที่รู้จัก เช่น i-Limb และ BeBionic Hand มีราคาประมาณ 18,000 และ 11,000 ดอลลาร์สหรัฐตามลำดับ


งานวิจัยยังชี้ให้เห็นปัญหาความไม่นิ่งของสัญญาณกล้ามเนื้อ ที่เกิดจากการเลื่อนตำแหน่งของอิเล็กโทรดและการเปลี่ยนแปลงของสภาพผิวหนัง ซึ่งยังคงเป็นข้อจำกัดสำคัญในการใช้งานจริงทั้งในสถานพยาบาลและในชีวิตประจำวัน ข้อมูลดังกล่าวเป็นประโยชน์ต่อโครงการนี้ในการเลือกใช้ตัวจำแนกประเภทที่เหมาะสมสำหรับการประมวลผลสัญญาณกล้ามเนื้อด้วยไลบรารี scikit-learn รวมถึงการกำหนดเป้าหมายด้านน้ำหนักและแรงจับของมือเทียมต้นแบบให้ใกล้เคียงกับมือนมนุษย์และมือเทียมเชิงพาณิชย์ในปัจจุบัน

บทที่ 3

วิธีดำเนินการพัฒนา

3.1 กระบวนการดำเนินงานโครงการ

การดำเนินโครงการนี้ถูกออกแบบให้เป็นขั้นตอนเชิงวิศวกรรม เพื่อให้กระบวนการพัฒนามีความเป็นระบบและสามารถตรวจสอบความก้าวหน้าได้อย่างต่อเนื่อง โดยแบ่งออกเป็น 5 ระยะสำคัญ ได้แก่ ระยะการศึกษา ระยะการออกแบบ ระยะการสร้าง ระยะการทดสอบ และระยะการวิเคราะห์



รูปที่ 3.1 กระบวนการดำเนินงาน (Flowchart 5 ระยะ)

3.1.1 การศึกษา

เป็นการรวบรวมข้อมูลและความรู้ที่เกี่ยวข้องกับปัญหาการควบคุมมือเทียมของผู้พิการที่สูญเสียอวัยวะระดับใต้ข้อศอก ศึกษาหลักการทำงานของสัญญาณคลื่นไฟฟ้ากล้ามเนื้อ การทำงานของเซนเซอร์ตัวแปลงสัญญาณอนาล็อกเป็นดิจิทัล หลักการกรองสัญญาณแบบตัวกรองผ่านแถบความถี่แบบบัตเตอร์เวิร์ธ (Butterworth Bandpass Filter) และตัวกรองแบบบาก (Notch Filter) รวมถึงอัลกอริทึมการเรียนรู้ของเครื่องที่เหมาะสมกับการจำแนกท่าทางกำมือ/คลายมือจากสัญญาณกล้ามเนื้อ

3.1.2 การออกแบบ

เป็นการออกแบบทั้งด้านฮาร์ดแวร์และซอฟต์แวร์ โดยฮาร์ดแวร์ประกอบด้วย การออกแบบวงจรเชื่อมต่อเซนเซอร์กับตัวแปลงสัญญาณและวงจรควบคุมเซอร์โวมอเตอร์ผ่านตัวขับ ส่วนซอฟต์แวร์ประกอบด้วย การออกแบบสถาปัตยกรรมการไหลของข้อมูล (System Workflow) แผนภาพกรณีการใช้

งาน (Use Case Diagram) แผนภาพกิจกรรม (Activity Diagram) และการออกแบบโครงสร้างฐานข้อมูล สำหรับจัดเก็บสัญญาณ EMG และผลการเปรียบเทียบของผู้ใช้แต่ละคน

3.1.3 การพัฒนา

เป็นการนำแบบที่ออกแบบไว้มาพัฒนาเป็นระบบจริง เริ่มจากการเขียนโปรแกรมภาษา Python เพื่ออ่านค่าจากเซนเซอร์ผ่าน ไลบรารี adafruit-circuitpython-ads1x15 พัฒนาโมดูลกรองสัญญาณด้วย scipy.signal พัฒนาโมดูลสกัดคุณลักษณะสัญญาณ (Feature Extraction) พัฒนาโมดูลฝึกฝนโมเดลเรียนรู้ของเครื่องแบบ Online พัฒนาโมดูลควบคุมเซอร์โวมอเตอร์ พัฒนาระบบยืนยันตัวตนผ่าน Firebase Authentication และพัฒนาส่วนติดต่อผู้ใช้แบบกราฟิก (GUI) ด้วย Tkinter

3.1.4 การทดสอบ


เป็นการตรวจสอบการทำงานของระบบในแต่ละส่วน ทั้งการอ่านค่าสัญญาณจากเซนเซอร์ การกรองสัญญาณ การสกัดคุณลักษณะ ความถูกต้องของการจำแนกท่าทางด้วยโมเดลเรียนรู้ของเครื่อง การควบคุมเซอร์โวมอเตอร์ การบันทึกและซิงค์ข้อมูลขึ้น Firebase รวมถึงทดสอบการทำงานร่วมกันของทั้งระบบ (Integration Testing) และการทดสอบการยอมรับจากผู้ใช้งาน (User Acceptance Testing)

3.1.5 การวิเคราะห์ผล

เป็นการนำข้อมูลที่ได้จากการทดสอบมาวิเคราะห์ เพื่อเปรียบเทียบประสิทธิภาพของเรียนรู้ของเครื่อง แต่ละแบบประเมินความแม่นยำในการจำแนกท่าทางกำมือ/คลายมือ วิเคราะห์เสถียรภาพของระบบควบคุม เซอร์โวมอเตอร์และสรุปแนวทางการปรับปรุง ระบบในระยะต่อไป

3.2 ภาพรวมสถาปัตยกรรมของระบบ

ระบบมือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อที่พัฒนาขึ้นประกอบด้วย 3 ส่วนหลักที่ทำงานร่วมกัน ได้แก่ ส่วนฮาร์ดแวร์ (Hardware) ทำหน้าที่ตรวจจับสัญญาณกล้ามเนื้อและขับเคลื่อนกลไกมือเทียม ส่วนซอฟต์แวร์ประมวลผลบน Raspberry Pi ทำหน้าที่กรองสัญญาณ สกัดคุณลักษณะ จำแนกท่าทาง และควบคุมการทำงานของทั้งระบบ และส่วนระบบคลาวด์ทำหน้าที่จัดเก็บข้อมูลสำรองและยืนยันตัวตนผู้ใช้งาน ดังแสดงในรูปที่ 3.2



รูปที่ 3.2 ภาพรวมสถาปัตยกรรมของระบบ

การทำงานเริ่มจากเซนเซอร์ตรวจจับสัญญาณไฟฟ้ากล้ามเนื้อบริเวณแขนส่วนที่เหลือนอยู่ส่งเป็นสัญญาณแรงดันอนาล็อก ผ่านตัวแปลงสัญญาณ ADS1115 เข้าสู่ Raspberry Pi ผ่านบัส I²C จากนั้นซอฟต์แวร์บน Raspberry Pi จะกรองสัญญาณรบกวน คำนวณค่า RMS Envelope และสกัดคุณลักษณะสัญญาณ 7 ค่า ก่อนนำไปตัดสินใจสั่งงานเซอร์โวมอเตอร์ผ่านตัวขับ PCA9685 ได้ 2 แนวทาง คือ การเทียบค่า RMS กับค่าเกณฑ์โดยตรง หรือการทำนายท่าทางด้วยโมเดลการเรียนรู้ของเครื่องที่ฝึกฝน จากคุณลักษณะสัญญาณทั้ง 7 ค่า ขึ้นอยู่กับโหมดที่ผู้ใช้เลือกในส่วนติดต่อผู้ใช้ ขณะเดียวกันทุกค่าที่อ่านได้จะถูก บันทึกลงไฟล์ในเครื่องแบบทันทีก่อนที่เซิร์ฟเวอร์จะทยอยส่งข้อมูลขึ้น Firebase Realtime Database เมื่อมีการเชื่อมต่ออินเทอร์เน็ต

3.2.1 ส่วนประกอบหลักของระบบ

ตารางที่ 3.1 ส่วนประกอบหลักของระบบและหน้าที่การทำงาน

ส่วนประกอบ	หน้าที่
EMG Sensor (SEN0240 Gravity)	ตรวจจับสัญญาณไฟฟ้ากล้ามเนื้อแปลงเป็นแรงดันไฟฟ้าขนาดเล็ก
ADS1115 (16-bit ADC)	แปลงสัญญาณอนาล็อกจากเซนเซอร์เป็นดิจิทัล โหมด Continuous Conversion ที่ 860 SPS
Raspberry Pi	ประมวลผลสัญญาณ กรองสัญญาณ สกัดคุณลักษณะ รันโมเดลการเรียนรู้เครื่องและควบคุมเซอร์โวมอเตอร์
PCA9685 (16-Channel PWM Driver)	แปลงคำสั่งจาก Raspberry Pi เป็นสัญญาณ PWM เพื่อขับเซอร์โวมอเตอร์
Servo Motor	ขับเคลื่อนกลไกนิ้วมือเทียมให้กำ/คลายมือตามคำสั่งที่ได้รับ
ไฟล์ .jsonl ในเครื่อง	จัดเก็บข้อมูลสัญญาณกล้ามเนื้อทุก sample แบบบันทึกลงไฟล์ในเครื่องก่อนซิงค์ขึ้นคลาวด์
Firebase Authentication	ยืนยันตัวตนผู้ดูแลระบบด้วยอีเมล/รหัสผ่านก่อนเข้าใช้งานโปรแกรม
Firebase Realtime Database	จัดเก็บข้อมูลสำรองบนคลาวด์ (sessions, calibrations, datasets, session_meta)
โปรแกรม GUI (Tkinter)	ส่วนติดต่อผู้ใช้แสดงผลสัญญาณ ควบคุมการทำงาน และจัดการโมเดล การเรียนรู้เครื่อง

3.3 การออกแบบวงจรฮาร์ดแวร์

วงจรฮาร์ดแวร์และการจัดวางอุปกรณ์ของระบบแบ่งออกเป็น 4 ส่วนหลัก ได้แก่ การจัดวางอุปกรณ์วงจรไฟฟ้ากำลัง วงจรสัญญาณไฟฟ้ากล้ามเนื้อ และวงจรควบคุมมอเตอร์ โดยทั้งวงจรสัญญาณและวงจรควบคุมมอเตอร์สื่อสารกับ Raspberry Pi 5 ผ่านบัส I²C เส้นเดียวกัน ซึ่งช่วยให้เชื่อมต่ออุปกรณ์หลายตัว


บนสายสัญญาณชุดเดียวกันได้ โดยแยกกันด้วยเลขที่อยู่เฉพาะของแต่ละอุปกรณ์ นอกจากนี้ระบบยังมีกลไกรองรับการทำงานในกรณีที่ไม่มีฮาร์ดแวร์ต่ออยู่จริงด้วย

3.3.1 การจัดวางอุปกรณ์

การจัดวางอุปกรณ์ภายในโครงมือเทียมคำนึงถึงทั้งความปลอดภัยของผู้ใช้งานและความสะดวกในการบำรุงรักษา โดยโมดูลเซนเซอร์ EMG (SEN0240) ติดตั้งแนบผิวหนังบริเวณกล้ามเนื้อแขนส่วนที่เหลืออยู่ของผู้ใช้งาน ส่วนแบตเตอรี่ วงจร BMS Raspberry Pi 5 และวงจรควบคุมอื่น ๆ จัดวางอยู่ในกล่องป้องกันแยกจากตัวมือเทียมโดยตรง เพื่อลดน้ำหนักส่วนปลายและป้องกันความชื้นหรือแรงกระแทกที่อาจเกิดกับวงจรอิเล็กทรอนิกส์

3.3.2 วงจรไฟฟ้ากำลัง

การออกแบบวงจรไฟฟ้ากำลังเป็นหัวใจสำคัญของระบบ เนื่องจากอุปกรณ์อิเล็กทรอนิกส์หลายชนิดต้องทำงานร่วมกันอย่างสอดคล้องและปลอดภัย แบตเตอรี่ลิเทียมไอออนชนิด INR21700 จำนวน 4 เซลล์ต่อแบบอนุกรม (4S, 14.8–16.8V) ต่อเข้ากับวงจร BMS ขนาด 30A เพื่อป้องกันแรงดันเกินหรือต่ำเกินไป และช่วยบาลานซ์เซลล์ให้สม่ำเสมอ ดังแสดงในรูปที่ 3.4




รูปที่ 3.4 แผนผังวงจรไฟฟ้ากำลัง ประกอบด้วยแบตเตอรี่ ระบบจัดการแบตเตอรี่

จากรูปที่ 3.4 ไฟจาก BMS แยกออกเป็นสองเส้นทาง คือ จอแสดงผล Monitor LCD ที่ต่อขนานตรงจากขั้ว P+/P- เพื่อแสดงค่าแบตเตอรี่ได้ตลอดเวลาไม่ว่าจะอยู่ในโหมดใด และสวิตช์ Kcd4 ซึ่งเป็นสวิตช์ 2 ขั้ว (DPDT) ทำหน้าที่เลือกโหมดการทำงานระหว่าง RUN (จ่ายไฟไปยัง Step-down converter ทั้งสองตัว) และ CHARGE (เชื่อมต่อกับ DC Jack เพื่อชาร์จแบตเตอรี่กลับผ่าน BMS) โดยไฟ 5V จาก Step-down converter ทั้งสองตัวถูกแยกเป็นวงจรอิสระต่อกัน เพื่อป้องกันไม่ให้งานของเซอร์โวล่งผลกระทบต่อนไฟเลี้ยงของ Raspberry Pi 5 ดังแสดงในรูปที่ 3.5 และรูปที่ 3.6

จากรูปที่ 3.5 และรูปที่ 3.6 วงจรแรกจ่ายไฟให้ Raspberry Pi 5 โดยตรงผ่านช่อง USB Type-C ส่วนวงจรที่สองจ่ายไฟให้ INA219 และ PCA9685 สำหรับขับเคลื่อนมอเตอร์ โดยกระแสไฟฟ้าจะไหลผ่าน INA219 ก่อน เพื่อให้สามารถวัดปริมาณกระแสที่มอเตอร์วิ่งไปใช้จริงได้อย่างแม่นยำ ก่อนส่งต่อไปยัง PCA9685

3.3.3 วงจรสัญญาณไฟฟ้ากล้ามเนื้อ

โมดูลเซนเซอร์ EMG (SEN0240) ทำงานที่แรงดัน 5V ติดตั้งบนผิวหนังบริเวณกล้ามเนื้อแขนส่วนที่เหลื่อของผู้ใช้ ส่งสัญญาณเอาต์พุตเป็นแรงดันไฟฟ้าอนาล็อกในช่วง 0–3.3 โวลต์ทางขา SIG เข้าสู่ช่องสัญญาณ A0 ของ ADS1115 ซึ่งเป็นตัวแปลงสัญญาณอนาล็อกเป็นดิจิทัลความละเอียด 16 บิต ตั้งค่า Gain=1 (ช่วงการวัด ± 4.096 โวลต์) ที่อยู่ I2C เป็น 0x48 (ขา ADDR ต่อกับ GND) และเปิดโหมดแปลงสัญญาณต่อเนื่องจากความเร็วสูงสุด 860 SPS เพื่อให้ได้อัตราสุ่มตัวอย่างที่รวดเร็วและสม่ำเสมอ ก่อนนำไป downsample ให้ได้ค่า sample rate เป้าหมายที่ 500 Hz ผ่านฟังก์ชัน stream() ADS1115 เชื่อมต่อกับ Raspberry Pi 5 ผ่านบัส I2C เดียวกับอุปกรณ์อื่น โดยขา VDD ต่อกับ 3.3V (Pin 1) GND ต่อกับ Pin 6 SCL ต่อกับ GPIO3 (Pin 5) และ SDA ต่อกับ GPIO2 (Pin 3) ดังแสดงในรูปที่ 3.7




รูปที่ 3.7 วงจรเชื่อมต่อเซนเซอร์สัญญาณไฟฟ้ากล้ามเนื้อ กับ ADS1115 และ Raspberry Pi

3.3.4 วงจรควบคุมมอเตอร์

Servo Motor รุ่น MG996R ที่ใช้ขับเคลื่อนกลไกนิ้วมือเทียมเชื่อมต่อผ่านตัวขับ PCA9685 ซึ่งเป็นวงจรขับสัญญาณ PWM 16 ช่องสัญญาณ ควบคุมผ่านบัส I2C เดียวกันกับ ADS1115 โดยแยกกันด้วย

เลขที่อยู่ (0x40 สำหรับ PCA9685 และ 0x48 สำหรับ ADS1115) นอกจากนี้ Raspberry Pi 5 ยังสื่อสารกับ INA219 (ที่อยู่ I2C 0x41 หลังบัดกรีแก้ไข ADDR เพื่อไม่ให้ชนกับ PCA9685) ผ่านบัส I2C เส้นเดียวกัน โดย Step-down converter ตัวที่สองจ่ายไฟ 5V เข้าที่ขา VIN+ ของ INA219 ก่อน แล้วจึงส่งต่อออกจากขา VIN- ไปยังขา V+ ของ PCA9685 เพื่อให้ INA219 วัดกระแสไฟฟ้าที่เซอร์โวดึงไปใช้จริงได้อย่างแม่นยำ จากนั้น PCA9685 ส่งสัญญาณ PWM ผ่านช่อง CH0 ไปควบคุมมุมหมุนของเซอร์โว โดยระบบกำหนดมุมพัก (angle_rest) ไว้ที่ 0 องศา และมุมกำมือ (angle_active) ไว้ที่ 90 องศา ดังแสดงในรูปที่ 3.8



รูปที่ 3.8 แผนผังการเชื่อมต่อ Raspberry Pi 5 กับวงจรควบคุมมอเตอร์

3.3.5 การรองรับโหมดจำลอง

เพื่อให้สามารถพัฒนาและทดสอบซอฟต์แวร์ได้แม้ไม่มีฮาร์ดแวร์ต่ออยู่จริง (เช่น พัฒนบนเครื่องคอมพิวเตอร์ทั่วไป) ระบบถูกออกแบบให้ตรวจจับความพร้อมของฮาร์ดแวร์โดยอัตโนมัติ หากไม่พบไลบรารีหรือไม่สามารถเปิดใช้งานบัส I2C ได้ ทั้งโมดูลอ่านสัญญาณ (EMGStreamThread) และโมดูลควบคุมเซอร์โวมอเตอร์ (EMGServoController) จะสลับไปทำงานในโหมดจำลอง (Simulated Mode) โดยอัตโนมัติ โดยฝั่งสัญญาณจะสร้างคลื่นสัญญาณจำลองที่มีหน่วยใกล้เคียงกับสัญญาณจริง และฝั่ง Servo จะพิมพ์ข้อความแจ้งสถานะแทนการสั่งเซอร์โวมอเตอร์จริง ทำให้พัฒนาและทดสอบตรรกะของระบบทั้งหมดได้โดยไม่ต้องพึ่งพาฮาร์ดแวร์ ตลอดเวลา

3.4 การประมวลผลสัญญาณกล้ามเนื้อ

สัญญาณกล้ามเนื้อดิบที่อ่านได้จากเซนเซอร์มีสัญญาณรบกวนปะปนอยู่มาก จึงจำเป็นต้องผ่านกระบวนการกรองสัญญาณและสกัดคุณลักษณะ (Feature Extraction) ก่อนนำไปใช้ตัดสินใจควบคุมมือเทียมหรือฝึกฝนโมเดลการเรียนรู้ของเครื่อง โดยกระบวนการทั้งหมดถูกออกแบบให้ทำงานแบบเรียลไทม์ทีละตัวอย่าง (Real-time, sample-by-sample) เพื่อไม่ให้เกิดความหน่วงเวลา (Latency) ที่ผู้ใช้รับรู้ได้

3.4.1 การกรองสัญญาณ

โมดูล `emg_filters.py` ทำหน้าที่กรองสัญญาณด้วยตัวกรองแบบ IIR (Infinite Impulse Response) ชนิด Butterworth อันดับที่ 4 จำนวน 2 ตัวต่อกัน ได้แก่ ตัวกรองผ่านแถบความถี่ (Bandpass Filter) ช่วง 20-249 Hz เพื่อตัดสัญญาณ ความถี่ต่ำที่เกิดจากการเคลื่อนไหวของอิเล็กโทรด (Motion Artifact) และสัญญาณความถี่สูงเกินขอบเขตของ EMG จริง และตัวกรองตัดความถี่เฉพาะจุดที่ 50 Hz เพื่อตัดสัญญาณรบกวนจากไฟฟ้ากระแสสลับ ทั้งสองตัวกรอง ถูกออกแบบด้วยฟังก์ชัน `scipy.signal.butter` และ `scipy.signal.iirnotch` ตามลำดับ และรันแบบ Real-time ทีละตัวอย่าง ด้วยฟังก์ชัน `filter` ร่วมกับการเก็บสถานะตัวกรอง (Filter State: `zi`) เพื่อไม่ต้องรอสะสมสัญญาณเป็นก้อนก่อนกรอง ซึ่งจะทำให้เกิดความหน่วงเวลา หลังจากกรองสัญญาณแล้วจะทำการเรียงเต็มคลื่นด้วยค่า `samplerate`

จากสัญญาณที่ผ่านการเรียงเต็มคลื่นแล้ว ระบบคำนวณค่า Moving RMS Envelope โดยเก็บค่ากำลังสองของสัญญาณไว้ใน หน้าต่างเลื่อนขนาด 100 มิลลิวินาที แล้วคำนวณรากที่สองของค่าเฉลี่ย ได้ค่า RMS ที่สะท้อน "กำลังการหดตัวของกล้ามเนื้อ" ในขณะนั้น ซึ่งใช้เป็นค่าอ้างอิงหลักสำหรับการเทียบค่าเกณฑ์ (Threshold) ในโหมดควบคุมแบบดั้งเดิม

3.4.2 การสกัดคุณลักษณะสัญญาณ

เพื่อเพิ่มความแม่นยำในการจำแนกท่าทางให้มากกว่าการใช้ค่า RMS เพียงตัวเดียว ระบบได้พัฒนาโมดูลกลาง `emg_features.py` สำหรับคำนวณคุณลักษณะสัญญาณ (Feature) จำนวน 7 ค่าต่อ 1 หน้าต่างสัญญาณ (Sliding Window) โดยทุกส่วนของระบบ (การอ่านสัญญาณเรียลไทม์ การปรับเทียบ และการฝึกฝนโมเดล) เรียกใช้ฟังก์ชันคำนวณชุดเดียวกันเสมอ เพื่อป้องกันความคลาดเคลื่อนจากการคำนวณคนละสูตรในแต่ละจุดของโปรแกรม รายละเอียดสูตรคำนวณแสดงในตารางที่ 3.2 โดยคำนวณจากสัญญาณ ที่ผ่านตัวกรอง กรองสัญญาณแบบตัวกรองผ่านแถบความถี่แบบบัตเตอร์เวิร์ธ และตัวกรองแบบบีก (ไม่ใช่สัญญาณที่ถูกเรียงเต็มคลื่น) เนื่องจากต้องการสัญญาณที่แกว่งรอบ 0 จริง โดยเฉพาะคุณลักษณะ Zero Crossing และ Slope Sign Change ที่ความหมายจะผิดเพี้ยนไปหากใช้สัญญาณที่เป็นบวกตลอด

ตารางที่ 3.2 สูตรคำนวณคุณลักษณะสัญญาณ EMG จำนวน 7 ค่า

คุณลักษณะ (Feature)	สูตรคำนวณ	ความหมาย
RMS (Root Mean Square)	$\sqrt{\text{mean}(x^2)}$	กำลังเฉลี่ยของสัญญาณในหน้าต่าง
MAV (Mean Absolute Value)	$\text{mean}(x)$	ค่าเฉลี่ยขนาดสัญญาณ
Variance	$\text{mean}((x - \text{mean}(x))^2)$	ความแปรปรวนของสัญญาณ
Waveform Length	$\sum x[i] - x[i-1] $	ความยาวคลื่นสะสม สะท้อนความซับซ้อนของสัญญาณ
Zero Crossing	นับจำนวนครั้งที่สัญญาณตัดผ่าน 0	ความถี่ของการแกว่งสัญญาณ (มีค่าเกณฑ์กัน สัญญาณรบกวน)
Slope Sign Change	นับจำนวนจุดยอด/จุดหุบ	ความถี่การกลับทิศของความชัน (มีค่าเกณฑ์กัน สัญญาณรบกวน)
IEMG (Integrated EMG)	$\sum x $	ผลรวมสะสมของขนาดสัญญาณ (ไม่หารเฉลี่ย)

ค่าเกณฑ์ที่ใช้ป้องกันสัญญาณรบกวนขนาดเล็กในการนับ Zero Crossing และ Slope Sign Change กำหนดไว้ที่ 0.005 โวลต์ ทั้งสองค่า เพื่อป้องกันไม่ให้สัญญาณรบกวนเล็กน้อยขณะกล้ามเนื้อพัก ถูกนับเป็นการตัดผ่านศูนย์ซ้ำ ๆ จนได้ค่าที่ สูงผิดปกติ ลำดับของคุณลักษณะทั้ง 7 ค่า (FEATURE_NAMES) ถูกกำหนดตายตัวและใช้เป็นมาตรฐานเดียวกันทั้งระบบ ตั้งแต่ขั้นตอนบันทึกลง Firebase จนถึงขั้นตอนสร้างเวกเตอร์คุณลักษณะป้อนเข้าโมเดลเรียนรู้เครื่องเพื่อป้องกัน การสลับตำแหน่งคอลัมน์ที่จะทำให้โมเดลเรียนรู้ผิดพลาด

3.4.3 หน้าต่างเลื่อนสำหรับสกัดคุณลักษณะ

เนื่องจากการคำนวณคุณลักษณะทั้ง 7 ค่าทุกตัวอย่างสัญญาณที่อัตราสุ่ม 500 Hz จะเป็นภาระการประมวลผลที่หนักเกินไป สำหรับ Raspberry Pi โดยเฉพาะ Waveform Length และ Zero Crossing ที่ต้องไล่สแกนข้อมูลทั้งหน้าต่าง ระบบจึงออกแบบ คลาส SlidingWindowFeatureExtractor ให้คำนวณคุณลักษณะใหม่เฉพาะเมื่อหน้าต่างสัญญาณเลื่อนครบตามระยะก้าว (Step Size) ที่กำหนดเท่านั้น แทนที่จะคำนวณทุกตัวอย่างที่รับเข้ามา พารามิเตอร์ที่ใช้แสดงในตารางที่ 3.3

ตารางที่ 3.3 พารามิเตอร์ของ Sliding Window Feature Extractor


พารามิเตอร์	ค่าเริ่มต้น	ความหมาย
Sample Rate (fs)	500 Hz	อัตราการสุ่มตัวอย่างสัญญาณ EMG

พารามิเตอร์	ค่าเริ่มต้น	ความหมาย
Window Size (window_sec)	0.2 วินาที (100 samples)	ความยาวของหน้าต่างสัญญาณที่ใช้ คำนวณคุณลักษณะ
Step Size (step_sec)	0.1 วินาที (50 samples)	ระยะก้าวก่อนคำนวณคุณลักษณะ ใหม่ (10 Hz)

ด้วยการออกแบบเช่นนี้ ระบบยังคงตอบสนองแบบเรียลไทม์ที่เพียงพอต่อการรับรู้ของผู้ใช้ (คำนวณคุณลักษณะใหม่ทุก 0.1 วินาที) ในขณะที่ลดภาระการประมวลผลลงถึง 50 เท่าเมื่อเทียบกับการคำนวณทุกอย่าง


3.5 การออกแบบซอฟต์แวร์: แผนภาพการทำงานของระบบ

แผนภาพการทำงานของระบบแสดงลำดับขั้นตอนการไหลของข้อมูลตั้งแต่การอ่านสัญญาณดิบจากเซนเซอร์ไปจนถึงการสั่งงานเซอร์โวมอเตอร์ และการบันทึกข้อมูล โดยระบบถูกออกแบบให้มี 2 เส้นทางการตัดสินใจคู่ขนานกันคือ เส้นทาง RMS Threshold แบบดั้งเดิม ซึ่งเทียบค่า RMS กับค่าคงที่โดยตรง และเส้นทางการเรียนรู้เครื่อง ซึ่งใช้ คุณลักษณะสัญญาณทั้ง 7 ค่าผ่านโมเดลที่ฝึกฝนไว้ ผู้ใช้สามารถเลือกสลับโหมดควบคุมได้จากหน้าจอโดยไม่กระทบต่อกลไก Debounce ที่ใช้ป้องกันเซอร์โวมอเตอร์สั่นเมื่อสัญญาณกว้างใกล้จุดตัดสินใจ ดังแสดงในรูปที่ 3.9



รูปที่ 3.9 แผนภาพการทำงานของระบบ

3.5.1 แผนภาพกรณีการใช้งานของระบบ (Use Case Diagram)




รูปที่ 3.10 แผนภาพกรณีการใช้งานของระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อ (Myoelectric Hand Control System & Application)

หัวข้อนี้แสดงภาพรวมของการทำงานทั้งหมดในระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อ ซึ่งงานวิจัยนี้ได้พัฒนาขึ้นโดยมีวัตถุประสงค์เพื่อให้ ผู้ดูแลระบบสามารถเฝ้าติดตาม ตรวจสอบ ปรับเทียบ และควบคุมการเคลื่อนไหวของมือเทียมได้อย่างแม่นยำและสอดคล้อง กับเจตนาของผู้ใช้งาน โดยอาศัยสัญญาณไฟฟ้ากล้ามเนื้อ ร่วมกับกระบวนการประมวลผล ด้วยการเรียนรู้ของเครื่องในการ จำแนกท่าทางการเคลื่อนไหว

ระบบที่น่าเสนอประกอบด้วยผู้แสดงบทบาท (Actor) หลักจำนวน 4 ราย ได้แก่ ประการแรก ผู้ดูแลระบบ ซึ่งเป็นผู้ใช้งานหลักของระบบ ทำหน้าที่เข้าสู่ระบบ เฝ้าติดตามสถานะการทำงาน ตรวจสอบ สัญญาณ จัดการข้อมูล ตลอดจนฝึกฝนแบบจำลอง (Model) การเรียนรู้ของเครื่อง ประการที่สอง เซนเซอร์ ซึ่งทำหน้าที่ตรวจจับ สัญญาณไฟฟ้ากล้ามเนื้อและส่งข้อมูลเข้าสู่ระบบ ประการที่สาม มือเทียม ซึ่งเป็นอุปกรณ์ฮาร์ดแวร์ ที่รับคำสั่งควบคุมเซอร์โวมอเตอร์จากระบบ และประการสุดท้าย Firebase ซึ่งทำหน้าที่ เป็นฐานข้อมูลสำหรับยืนยันสิทธิ์ผู้ใช้งานและจัดเก็บ/ซิงค์ข้อมูลของระบบ

ในการนี้ ระบบได้ถูกแบ่งออกเป็น 6 กลุ่มการทำงานหลัก ได้แก่ (1) การยืนยันตัวตน (Authentication) (2) การเฝ้าติดตามแบบเรียลไทม์ (Dashboard) (3) การตรวจสอบและปรับเทียบมือ เทียม (4) การจัดการข้อมูลและผู้ใช้ (5) การเรียนรู้ของเครื่อง (Machine Learning) และ (6) การตั้งค่า ระบบ โดยมีรายละเอียดของแต่ละกลุ่มดังต่อไปนี้


3.5.1.1 การยืนยันตัวตน (Authentication)



รูปที่ 3.11 Use Case Diagram กลุ่มกรณีการใช้งานการยืนยันตัวตน

กลุ่มกรณีการใช้งานนี้มีหน้าที่ตรวจสอบและยืนยันตัวตนของผู้ดูแลระบบก่อนอนุญาต ให้เข้าใช้งานฟังก์ชันต่าง ๆ ของระบบ ประกอบด้วยกรณีการใช้งาน UC-01 เข้าสู่ระบบ ซึ่งดำเนินการผ่าน กระบวนการยืนยันตัวตนของ Firebase Authentication และกรณีการใช้งาน UC-02 ตรวจสอบสิทธิ์ ผู้ดูแลระบบซึ่งมีความสัมพันธ์แบบรวมการทำงาน (include) กับ UC-01 กล่าวคือทำงานต่อเนื่องกันโดย อัตโนมัติ โดยระบบจะตรวจสอบรายชื่อผู้ได้รับอนุญาต ที่จัดเก็บไว้ในฐานข้อมูลแบบตลอดเวลา ของ Firebase หากไม่พบรายชื่อผู้ใช้งานดังกล่าว ระบบจะปฏิเสธการเข้าใช้งานทันที กรณีการใช้งานกลุ่มนี้จึง ถือเป็นส่วนแรกที่ช่วยป้องกันการเข้าถึงระบบโดยไม่ได้รับอนุญาต


3.5.1.2 การเฝ้าติดตามแบบเรียลไทม์ (Dashboard)



รูปที่ 3.12 Use Case Diagram กลุ่มกรณีการใช้งานการเฝ้าติดตามแบบเรียลไทม์

กลุ่มกรณีการใช้งานนี้เป็นหน้าจอแรกที่คุณดูแลระบบพบเห็นภายหลังเข้าสู่ระบบสำเร็จ ทำหน้าที่แสดงสถานะการทำงานของระบบแบบเรียลไทม์ในภาพรวม ประกอบด้วยกรณีการใช้งาน UC-18 เฝ้าติดตามสัญญาณกล้ามเนื้อและผลทำนายทาง ซึ่งแสดงกราฟสัญญาณไฟฟ้ากล้ามเนื้อ ค่าทำนายทางปัจจุบันพร้อมค่าความมั่นใจ สถานะการเชื่อมต่อกับฐานข้อมูลจำนวนตัวอย่างข้อมูลที่ผ่านการฝึกแบบจำลองแล้ว ตลอดจนเมตริกซ์ความสับสนโดยย่อของแบบจำลองที่ใช้ทำงานอยู่ ในปัจจุบัน โดยมีกรณีการใช้งาน UC-19 เลือกแหล่งที่มาคำสั่งควบคุมเซอร์โว เป็นกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน (extend) ซึ่งเปิดโอกาสให้ผู้ดูแลระบบสามารถเลือกได้ว่าจะใช้ค่าเกณฑ์หรือผลลัพธ์จากแบบจำลองการเรียนรู้ของเครื่องเป็นเกณฑ์ในการสั่งงานเซอร์โวของมือเทียม กรณีการใช้งานกลุ่มนี้ จึงเป็นศูนย์กลางในการติดตามภาพรวมของระบบตลอดระยะเวลาการใช้งาน

3.5.1.3 การตรวจวัดและปรับเทียบมือเทียม




รูปที่ 3.13 Use Case Diagram กลุ่มกรณีการใช้งานการตรวจวัดและปรับเทียบมือเทียม

กลุ่มกรณีการใช้งานนี้ถือเป็นแกนหลักของระบบ โดยทำหน้าที่ตรวจวัดสัญญาณไฟฟ้ากล้ามเนื้อ ปรับเทียบค่าสัญญาณ และควบคุมการเคลื่อนไหวของมือเทียม ประกอบด้วยกรณีการใช้งาน UC-03 อ่าน/แสดงสัญญาณกล้ามเนื้อแบบเรียลไทม์ ผ่านวงจรแปลงสัญญาณแอนะล็อกเป็นดิจิทัลโดยมีเซ็นเซอร์เป็นผู้ส่งสัญญาณเข้าสู่ระบบ จากนั้นระบบจะเรียกใช้กรณีการใช้งาน UC-04 ปรับเทียบสัญญาณ ซึ่งเป็นการปรับเทียบท่าทาง คลายมือและกำมือด้วยความสัมพันธ์แบบรวมการทำงานเพื่อกำหนดค่าอ้างอิงเฉพาะบุคคล และเรียกใช้กรณีการใช้งาน UC-05 ควบคุมเซอร์โวมือเทียม ด้วยความสัมพันธ์แบบรวมการทำงานในลำดับถัดไป โดยอาศัยค่าเกณฑ์ที่คำนวณจากค่ารากที่สองของค่าเฉลี่ยกำลังสองของสัญญาณ (Root Mean Square: RMS) หรือผลลัพธ์จากแบบจำลอง การเรียนรู้ของเครื่อง

ในการส่งงานเซอร์โวมือเทียม กรณีการใช้งานกลุ่มนี้จึงเป็นวงจรการทำงานหลักที่เกิดขึ้นซ้ำ ตลอดระยะเวลาการใช้งานจริง


3.5.1.4 การจัดการข้อมูลและผู้ใช้งาน



รูปที่ 3.14 Use Case Diagram กลุ่มกรณีการใช้งานการจัดการข้อมูลและผู้ใช้งาน

กลุ่มกรณีการใช้งานนี้มีหน้าที่จัดการข้อมูลผู้ใช้งานและข้อมูลสัญญาณไฟฟ้ากล้ำมเนื้อที่ถูกบันทึกไว้ในระบบ ประกอบด้วยกรณีการใช้งาน UC-06 จัดการผู้ใช้งาน สำหรับเลือก เพิ่ม หรือลบ ข้อมูลผู้ใช้งานในระบบ ซึ่งมีความสัมพันธ์แบบรวมการทำงานกับกรณีการใช้งาน UC-07 บันทึก/ซิงค์ข้อมูลขึ้นฐานข้อมูลเพื่อจัดเก็บข้อมูลผู้ใช้งานและสัญญาณไฟฟ้ากล้ำมเนื้อไว้บนฐานข้อมูลออนไลน์ ในลำดับถัดไประบบจะเรียกใช้กรณีการใช้งาน UC-08 ดู Log ข้อมูล ด้วยความสัมพันธ์แบบรวมการทำงาน เพื่อให้ผู้ดูแลระบบสามารถตรวจสอบประวัติข้อมูลย้อนหลังได้ กรณีการใช้งาน กลุ่มนี้จึงเป็นพื้นฐานสำคัญที่ทำให้ข้อมูลของผู้ใช้งานแต่ละรายถูกจัดเก็บและสืบค้นได้อย่างเป็นระบบ


3.5.1.5 การเรียนรู้ของเครื่อง



รูปที่ 3.15 Use Case Diagram กลุ่มกรณีการใช้งานด้านการเรียนรู้ของเครื่อง

กลุ่มกรณีการใช้งานนี้เกี่ยวข้องกับกระบวนการฝึกฝนและประเมินผลแบบจำลองการเรียนรู้ของเครื่องสำหรับจำแนกท่าทางจากสัญญาณไฟฟ้ากล้ามเนื้อ โดยเริ่มต้นจากกรณีการใช้งาน UC-10 ฝึกโมเดลซึ่งมีความสัมพันธ์แบบรวมการทำงานกับกรณีการใช้งาน UC-11 เลือกผู้ใช้ เพื่อกำหนดว่าจะนำข้อมูลของผู้ใช้งานรายใดมาใช้ในการฝึกแบบจำลอง โดยมีกรณีการใช้งาน UC-15 เลือกรูปแบบผู้ใช้ เป็นกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งให้ผู้ดูแลระบบสามารถเลือกได้ระหว่างการใช้อข้อมูลผู้ใช้งานเดี่ยวหรือข้อมูลผู้ใช้งานหลายรายร่วมกัน นอกจากนี้ กรณีการใช้งาน UC-10 ยังมีความสัมพันธ์แบบขยายการทำงานกับกรณีการใช้งาน UC-09 ส่งออกชุดข้อมูล (Dataset) เป็น CSV เพื่อให้ผู้ดูแลระบบสามารถส่งออกชุดข้อมูลที่ใช้ฝึกแบบจำลองไปวิเคราะห์ต่อภายนอกระบบได้ ในลำดับถัดไประบบจะเรียกใช้กรณีการใช้งาน UC-12 เลือกโมเดล Machine Learning ด้วยความสัมพันธ์แบบรวมการทำงาน เพื่อกำหนดชนิดของแบบจำลองที่จะนำมาใช้ฝึก โดยมีกรณีการใช้งาน UC-16 เลือกวิธีการฝึกโมเดล เป็นกรณีการใช้งานแบบขยายการทำงาน สำหรับเลือกระหว่างการใช้แบบจำลองพื้นฐาน (Base Model) เพียงลำพัง หรือใช้ร่วมกับวิธีการรวมกลุ่มแบบจำลอง (Ensemble Method) และในขั้นตอนสุดท้ายระบบจะเรียกใช้กรณีการใช้งาน UC-13 เปรียบเทียบโมเดล ML ด้วยความสัมพันธ์แบบรวมการทำงาน เพื่อประเมินผลด้วยค่าความถูกต้อง (Accuracy) ค่า F1 (F1-score) และเมทริกซ์ความสับสน (Confusion Matrix) โดยมีกรณีการใช้งาน UC-17 เปรียบเทียบผลลัพธ์การจำแนกกับโมเดลอื่น เป็นกรณีการใช้งานแบบขยายการทำงานเพิ่มเติม สำหรับเปรียบเทียบประสิทธิภาพระหว่างแบบจำลองหลายชนิด และมีกรณีการใช้งาน UC-20 ส่งออกผลเปรียบเทียบโมเดลเป็น CSV เป็นกรณีการใช้งานแบบขยายการทำงานขั้นสุดท้ายของกลุ่มนี้ เพื่อให้สามารถนำผลการเปรียบเทียบไปจัดทำรายงานหรือวิเคราะห์ต่อภายนอกระบบได้

3.5.1.6 การตั้งค่าระบบ



รูปที่ 3.16 Use Case Diagram กลุ่มกรณีการใช้งานการตั้งค่าระบบ

กลุ่มกรณีการใช้งานนี้ประกอบด้วยกรณีการใช้งาน UC-14 ตั้งค่าระบบ ซึ่งเปิดโอกาสให้ผู้ดูแลระบบสามารถกำหนดค่าพารามิเตอร์พื้นฐานในการทำงานของระบบ อาทิ ค่าเกณฑ์เริ่มต้นสำหรับตรวจจับสัญญาณ ตลอดจนตรวจสอบสถานะการเชื่อมต่อฮาร์ดแวร์และข้อมูลรุ่นของระบบ ค่าที่กำหนดไว้ในกรณีการใช้งานนี้จะถูกนำไปใช้ร่วมกับกรณีการใช้งาน UC-05 ในการควบคุมเซอร์โวของมือเทียมต่อไป

3.5.2 คำอธิบายกรณีการใช้งาน (Use Case Description)

ตารางที่ 3.4 คำอธิบาย UC-01 เข้าสู่ระบบ

หัวข้อ	รายละเอียด
Use Case ID	UC-01

Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเข้าสู่ระบบด้วยบัญชีผู้ใช้ที่ลงทะเบียนไว้ผ่านกระบวนการยืนยันตัวตนของ Firebase เพื่อขอรับสิทธิ์ในการใช้งานระบบ
Pre-conditions	ผู้ดูแลระบบมีบัญชีผู้ใช้ที่ลงทะเบียนไว้กับ Firebase เรียบร้อยแล้ว และแอปพลิเคชันของระบบอยู่ในสถานะพร้อมใช้งาน
Post-conditions	ผู้ดูแลระบบเข้าสู่ระบบได้สำเร็จ และระบบเรียกใช้กรณีการใช้งาน UC-02 เพื่อดำเนินการตรวจสอบสิทธิ์ในลำดับถัดไป
Main Flow	1) ผู้ดูแลระบบกรอกอีเมลและรหัสผ่าน 2) ระบบส่งข้อมูลดังกล่าวไปตรวจสอบกับกระบวนการยืนยันตัวตนของ Firebase 3) ระบบเรียกใช้ UC-02 เพื่อตรวจสอบสิทธิ์ของผู้ดูแลระบบต่อไป
Alternative Flows	A1: หากอีเมลหรือรหัสผ่านไม่ถูกต้อง ระบบจะแจ้งเตือนข้อผิดพลาดและให้ผู้ดูแลระบบกรอกข้อมูลใหม่อีกครั้ง

จากตารางที่ 1 แสดงให้เห็นถึงขั้นตอนการเข้าสู่ระบบของผู้ดูแลระบบผ่านกระบวนการยืนยันตัวตนของ Firebase ซึ่งถือเป็นจุดเริ่มต้นที่สำคัญของการใช้งานระบบทั้งหมด หากผู้ใช้งานไม่สามารถผ่านขั้นตอนนี้ได้ ย่อมไม่สามารถเข้าถึงฟังก์ชันการทำงานอื่นใดของระบบได้

ตารางที่ 3.5 คำอธิบาย UC-02 ตรวจสอบสิทธิ์ ผู้ดูแลระบบ

หัวข้อ	รายละเอียด
Use Case ID	UC-02
Actor(s)	Firebase
Description	ระบบดำเนินการตรวจสอบสิทธิ์ของผู้ดูแลระบบ โดยเปรียบเทียบกับรายชื่อผู้ได้รับอนุญาตที่จัดเก็บไว้ในฐานข้อมูลแบบเวลาจริงของ Firebase
Pre-conditions	ผู้ดูแลระบบเข้าสู่ระบบผ่านกรณีการใช้งาน UC-01 เรียบร้อยแล้ว
Post-conditions	ระบบทราบผลว่าผู้ใช้งานดังกล่าวมีสิทธิ์เป็นผู้ดูแลระบบหรือไม่
Main Flow	1) ระบบรับรหัสประจำตัวผู้ใช้ (UID) ของผู้ที่เข้าสู่ระบบ 2) ระบบตรวจสอบรหัสดังกล่าวกับรายชื่อผู้ได้รับอนุญาตในฐานข้อมูล 3) ระบบอนุญาตให้เข้าใช้งานหากตรวจพบรายชื่อที่สอดคล้องกัน
Alternative Flows	A1: หากไม่พบรหัสประจำตัวผู้ใช้ในรายชื่อผู้ได้รับอนุญาต ระบบจะปฏิเสธการเข้าใช้งานและบังคับให้ออกจากระบบทันที

จากตารางที่ 2 แสดงกระบวนการตรวจสอบสิทธิ์การเข้าใช้งานของผู้ดูแลระบบ โดยอ้างอิงจากรายชื่อผู้ได้รับอนุญาตซึ่งจัดเก็บไว้ในฐานข้อมูลแบบเวลาจริงของ Firebase กรณีการใช้งานนี้มีส่วนช่วยเสริมสร้างความปลอดภัยของระบบโดยจำกัดขอบเขตการเข้าถึงให้เฉพาะผู้ที่ได้รับอนุญาตเท่านั้น

ตารางที่ 3.6 คำอธิบาย UC-03 อ่าน/แสดงสัญญาณ EMG แบบเรียลไทม์ (เครื่องมือสอบเทียบ)

หัวข้อ	รายละเอียด
Use Case ID	UC-03
Actor(s)	เซนเซอร์, ผู้ดูแลระบบ
Description	ระบบทำการอ่านค่าสัญญาณไฟฟ้ากล้ามเนื้อแบบเรียลไทม์ผ่านวงจรแปลงสัญญาณแอนะล็อกเป็นดิจิทัลและแสดงผลบนหน้าเครื่องมือสอบเทียบ ของระบบ
Pre-conditions	เซนเซอร์ตรวจวัดสัญญาณไฟฟ้ากล้ามเนื้อเชื่อมต่อกับวงจร ADS1115 และเครื่องแม่ข่าย Raspberry Pi เรียบร้อยแล้ว
Post-conditions	ระบบได้รับข้อมูลสัญญาณไฟฟ้ากล้ามเนื้อแบบเรียลไทม์ที่พร้อมสำหรับการเปรียบเทียบและประมวลผลในลำดับถัดไป
Main Flow	1) เซนเซอร์ตรวจจับสัญญาณไฟฟ้ากล้ามเนื้อ 2) วงจร ADS1115 แปลงสัญญาณดังกล่าวให้อยู่ในรูปแบบดิจิทัล 3) ระบบอ่านค่าและแสดงผลเป็นกราฟแบบเรียลไทม์บนหน้าเครื่องมือสอบเทียบ
Alternative Flows	A1: หากระบบไม่สามารถอ่านค่าจากวงจร ADS1115 ได้ ระบบจะแจ้งเตือนให้ผู้ดูแลระบบตรวจสอบการเชื่อมต่อของอุปกรณ์ฮาร์ดแวร์ และเข้าสู่โหมดจำลองการทำงานโดยอัตโนมัติ

จากตารางที่ 3 แสดงกระบวนการอ่านและแสดงผลสัญญาณไฟฟ้ากล้ามเนื้อแบบเรียลไทม์ ซึ่งถือเป็นข้อมูลนำเข้าหลักของระบบทั้งหมด หากปราศจากข้อมูลจากขั้นตอนนี้ ระบบย่อมไม่สามารถดำเนินการเปรียบเทียบหรือควบคุมมือเทียมในขั้นตอนถัดไปได้

ตารางที่ 3.7 คำอธิบาย UC-04 ปรับเทียบสัญญาณ (Calibration OPEN/FIST)

หัวข้อ	รายละเอียด
Use Case ID	UC-04
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการปรับเทียบสัญญาณไฟฟ้ากล้ามเนื้อ โดยบันทึกค่าอ้างอิงของท่าทางคลายมือและกำมืออันเป็นค่าเฉพาะบุคคลของผู้ใช้งานแต่ละราย
Pre-conditions	ระบบสามารถอ่านค่าสัญญาณไฟฟ้ากล้ามเนื้อได้แล้ว กล่าวคือกรณีการใช้งาน UC-03 ดำเนินการสำเร็จ และผู้ดูแลระบบระบุหรือเลือกรหัสผู้ใช้เรียบร้อยแล้ว
Post-conditions	ระบบได้รับตัวอย่างสัญญาณสำหรับท่าทางคลายมือและกำมือของผู้ใช้งานแต่ละราย พร้อมสำหรับนำไปฝึกแบบจำลองและควบคุมเซอร์โวในลำดับถัดไป

Main Flow	1) ผู้ดูแลระบบกดปุ่มเริ่มบันทึกท่าทาง 2) ผู้ใช้งานคงท่าทางคลายมือไว้ตามระยะเวลาที่กำหนด 3) ผู้ใช้งานคงท่าทางกำมือไว้ตามระยะเวลาที่กำหนด 4) ระบบบันทึกตัวอย่างสัญญาณพร้อมป้ายกำกับ 5) ผู้ดูแลระบบยืนยันและบันทึกชุดข้อมูลขึ้น Firebase
Alternative Flows	A1: หากยังไม่ได้ระบุรหัสผู้ใช้ ระบบจะแจ้งเตือนและไม่อนุญาตให้บันทึกข้อมูล A2: ผู้ดูแลระบบสามารถเลือกใช้การจำลองเก็บข้อมูลอัตโนมัติ ซึ่งระบบจะนับถอยหลังสลับท่าทางคลายมือและกำมือให้เองตามจำนวนรอบที่กำหนด แทนการกดบันทึกด้วยตนเองทีละครั้ง

จากตารางที่ 4 แสดงขั้นตอนการปรับเทียบสัญญาณไฟฟ้ากล้ามเนื้อเฉพาะบุคคล ซึ่งถือเป็นเงื่อนไขสำคัญที่ทำให้ระบบสามารถแยกแยะท่าทางคลายมือและกำมือได้อย่างแม่นยำ ก่อนที่จะนำค่าที่ได้ไปใช้ในการควบคุมเซอร์โวของมือเทียมในลำดับต่อไป

ตารางที่ 3.8 คำอธิบาย UC-05 ควบคุม Servo มือเทียม

หัวข้อ	รายละเอียด
Use Case ID	UC-05
Actor(s)	มือเทียม
Description	ระบบสั่งงานเซอร์โวของมือเทียมให้ทำการกำหรือคลายมือ โดยอาศัยค่าเกณฑ์ที่ได้จากการปรับเทียบ หรือผลลัพธ์จากการจำแนกด้วยแบบจำลองการเรียนรู้ของเครื่อง ตามแหล่งที่มาที่ผู้ดูแลระบบเลือกไว้
Pre-conditions	ระบบมีค่าเกณฑ์ที่ได้จากการฝึกการใช้งาน UC-04 มือเทียมเชื่อมต่อกับระบบเรียบร้อยแล้ว และทราบแหล่งที่มาของคำสั่งควบคุมเซอร์โวจากการฝึกการใช้งาน UC-19
Post-conditions	เซอร์โวของมือเทียมเคลื่อนไหวสอดคล้องกับสัญญาณไฟฟ้ากล้ามเนื้อของผู้ใช้งาน
Main Flow	1) ระบบเปรียบเทียบค่า RMS ของสัญญาณกับค่าเกณฑ์ที่กำหนดไว้ หรือส่งข้อมูลเข้าสู่แบบจำลองการเรียนรู้ของเครื่อง 2) ระบบแปลผลลัพธ์เป็นคำสั่งกำมือหรือคลายมือ 3) ระบบส่งคำสั่งดังกล่าวไปยังเซอร์โวของมือเทียม
Alternative Flows	A1: หากการเชื่อมต่อกับเซอร์โวเกิดข้อขัดข้อง ระบบจะหยุดการส่งคำสั่งและแจ้งเตือนผู้ดูแลระบบทันที

จากตารางที่ 5 แสดงกระบวนการควบคุมเซอร์โวของมือเทียม ซึ่งเป็นผลลัพธ์ปลายทางที่ผู้ใช้งานสามารถรับรู้ได้โดยตรง โดยอาศัยค่าที่ได้จากการปรับเทียบหรือผลการจำแนกด้วยการเรียนรู้ของเครื่องเป็นปัจจัยกำหนดลักษณะการเคลื่อนไหว

ตารางที่ 3.9 คำอธิบาย UC-06 จัดการผู้ใช้งาน

หัวข้อ	รายละเอียด
Use Case ID	UC-06
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเลือก เพิ่ม หรือลบรายชื่อผู้ใช้งานที่มีการจัดเก็บข้อมูลสัญญาณไฟฟ้ากล่อมเนื้อไว้ในระบบ
Pre-conditions	ผู้ดูแลระบบเข้าสู่ระบบสำเร็จเรียบร้อยแล้ว
Post-conditions	รายชื่อผู้ใช้งานในระบบได้รับการปรับปรุงให้เป็นปัจจุบัน
Main Flow	1) ผู้ดูแลระบบเลือกเมนูจัดการผู้ใช้งาน 2) ผู้ดูแลระบบเลือก เพิ่ม หรือลบผู้ใช้งานตามต้องการ 3) ระบบเรียกใช้กรณีการใช้งาน UC-07 เพื่อบันทึกการเปลี่ยนแปลงขึ้น Firebase
Alternative Flows	A1: หากชื่อผู้ใช้งานที่เพิ่มซ้ำกับข้อมูลที่มีอยู่เดิม ระบบจะแจ้งเตือนและไม่บันทึกรายการซ้ำซ้อน

จากตารางที่ 6 แสดงกระบวนการจัดการรายชื่อผู้ใช้งานภายในระบบ ซึ่งถือเป็นข้อมูลพื้นฐานที่ใช้แยกชุดข้อมูลสัญญาณไฟฟ้ากล่อมเนื้อของผู้ใช้งานแต่ละรายออกจากกันอย่างเป็นระบบ

ตารางที่ 3.10 คำอธิบาย UC-07 บันทึก/ซิงค์ข้อมูลขึ้น Firebase

หัวข้อ	รายละเอียด
Use Case ID	UC-07
Actor(s)	Firebase
Description	ระบบดำเนินการบันทึกและซิงค์ข้อมูลผู้ใช้งานตลอดจนสัญญาณไฟฟ้ากล่อมเนื้อขึ้นสู่ฐานข้อมูลแบบเวลาจริงของ Firebase
Pre-conditions	ระบบมีการเชื่อมต่อกับเครือข่ายอินเทอร์เน็ต และมีข้อมูลที่ต้องดำเนินการบันทึกจากกรณีการใช้งาน UC-06
Post-conditions	ข้อมูลถูกจัดเก็บไว้บน Firebase เรียบร้อยแล้ว และพร้อมสำหรับการเรียกดูในภายหลัง
Main Flow	1) ระบบรวบรวมข้อมูลที่ต้องดำเนินการบันทึก 2) ระบบส่งข้อมูลดังกล่าวขึ้นสู่ Firebase 3) ระบบยืนยันผลว่าการซิงค์ข้อมูลดำเนินการสำเร็จ
Alternative Flows	A1: หากไม่มีสัญญาณเครือข่ายอินเทอร์เน็ต ระบบจะบันทึกข้อมูลไว้ในเครื่องก่อนแล้วจึงดำเนินการซิงค์ข้อมูลในภายหลัง (offline-first)

จากตารางที่ 7 แสดงกระบวนการบันทึกและซิงค์ข้อมูลขึ้นสู่ Firebase ซึ่งได้รับการออกแบบให้รองรับการทำงานแบบออฟไลน์ก่อน (offline-first) เพื่อป้องกันความสูญเสียของข้อมูลในกรณีที่เกิดการเชื่อมต่อเครือข่ายอินเทอร์เน็ต

ตารางที่ 3.11 คำอธิบาย UC-08 ดู Log ข้อมูล

หัวข้อ	รายละเอียด
Use Case ID	UC-08
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบเรียกดูประวัติหรือบันทึกข้อมูลของสัญญาณไฟฟ้ากลั่นเนื้อและเหตุการณ์ต่างๆที่ถูกบันทึกไว้ในระบบ
Pre-conditions	มีข้อมูลที่ถูกบันทึกไว้แล้วจากกรณีการใช้งาน UC-07
Post-conditions	ผู้ดูแลระบบได้รับทราบประวัติข้อมูลตามที่ต้องการ
Main Flow	1) ผู้ดูแลระบบเลือกเมนูดูบันทึกข้อมูลข้อมูล 2) ระบบดึงข้อมูลจาก Firebase หรือจากไฟล์ที่จัดเก็บภายในเครื่อง 3) ระบบแสดงรายการบันทึกข้อมูลตามช่วงเวลา que เลือกไว้
Alternative Flows	A1: หากไม่พบข้อมูลในช่วงเวลาที่เลือก ระบบจะแจ้งให้ทราบว่าไม่มีข้อมูลในช่วงเวลาดังกล่าว

จากตารางที่ 8 แสดงกระบวนการเรียกดูประวัติข้อมูลย้อนหลังของระบบ ซึ่งช่วยให้ผู้ดูแลระบบสามารถตรวจสอบความถูกต้องและความสมบูรณ์ของข้อมูลก่อนที่จะนำไปใช้งานในลำดับต่อไป

ตารางที่ 3.12 คำอธิบาย UC-09 ส่งออก Dataset เป็น CSV

หัวข้อ	รายละเอียด
Use Case ID	UC-09
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการส่งออกชุดข้อมูลที่ใช้ฝึกแบบจำลองการเรียนรู้ของเครื่องล่าสุดให้อยู่ในรูปแบบไฟล์ CSV เพื่อนำไปใช้วิเคราะห์ต่อภายนอกระบบ
Pre-conditions	ผู้ดูแลระบบดำเนินการโหลดข้อมูลย้อนหลังหรืออัปโหลดไฟล์จากกรณีการใช้งาน UC-10 เรียบร้อยแล้ว จึงมี Dataset อยู่ในหน่วยความจำให้ส่งออกได้
Post-conditions	ได้ไฟล์ CSV ของ Dataset ที่ใช้ฝึกแบบจำลองล่าสุด บันทึกไว้ในเครื่อง
Main Flow	1) ผู้ดูแลระบบเลือกคำสั่งส่งออกชุดข้อมูลเป็น CSV ในกลุ่มการเรียนรู้ของเครื่อง 2) ระบบดำเนินการแปลงข้อมูลให้อยู่ในรูปแบบ CSV 3) ระบบบันทึกไฟล์ดังกล่าวลงในเครื่อง

Alternative Flows	A1: หากยังไม่เคยโหลดชุดข้อมูลในเซสชันการใช้งานปัจจุบัน ระบบจะแจ้งเตือนและยกเลิกการทำงานในขั้นตอนนี้
-------------------	---

จากตารางที่ 9 แสดงกระบวนการส่งออกชุดข้อมูลที่ใช้ฝึกแบบจำลองในรูปแบบไฟล์ CSV ซึ่งเป็นกรณีการใช้งานแบบขยายการทำงานของกรณีการใช้งาน UC-10 อันช่วยให้สามารถนำชุดข้อมูลไปใช้ในการวิเคราะห์เพิ่มเติมภายนอกระบบได้อย่างสะดวก

ตารางที่ 3.13 คำอธิบาย UC-10 ฝึกโมเดล Machine Learning

หัวข้อ	รายละเอียด
Use Case ID	UC-10
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเริ่มต้นกระบวนการฝึกแบบจำลองการเรียนรู้ของเครื่องโดยใช้ข้อมูลสัญญาณไฟฟ้ากล่อมเนื้อที่ถูกบันทึกไว้
Pre-conditions	มีข้อมูลสัญญาณไฟฟ้ากล่อมเนื้อที่บันทึกไว้ในปริมาณเพียงพอสำหรับการฝึกแบบจำลอง
Post-conditions	ระบบเข้าสู่ขั้นตอนการเลือกผู้ใช้งานและการเลือกแบบจำลองสำหรับดำเนินการฝึกในลำดับถัดไป
Main Flow	1) ผู้ดูแลระบบเข้าสู่แท็บการเรียนรู้ของเครื่อง 2) ระบบเรียกใช้กรณีการใช้งาน UC-11 เพื่อเลือกผู้ใช้งาน 3) ระบบเรียกใช้กรณีการใช้งาน UC-12 เพื่อเลือกแบบจำลอง 4) ผู้ดูแลระบบสามารถเรียกใช้กรณีการใช้งาน UC-09 เพื่อส่งออกชุดข้อมูลที่ใช้ฝึกได้ในขั้นตอนนี้
Alternative Flows	A1: หากข้อมูลที่มีอยู่ไม่เพียงพอ ระบบจะแจ้งเตือนและไม่ดำเนินการฝึกแบบจำลอง

จากตารางที่ 10 แสดงจุดเริ่มต้นของกระบวนการฝึกแบบจำลองการเรียนรู้ของเครื่อง อันเป็นกรณีการใช้งานหลักที่เชื่อมโยงไปสู่การเลือกผู้ใช้งาน การเลือกแบบจำลอง และการส่งออกชุดข้อมูลในขั้นตอนถัดไป

ตารางที่ 3.14 คำอธิบาย UC-11 เลือกผู้ใช้

หัวข้อ	รายละเอียด
Use Case ID	UC-11
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเลือกข้อมูลผู้ใช้งานที่จะนำมาใช้ในการฝึกแบบจำลองการเรียนรู้ของเครื่อง

Pre-conditions	ระบบมีรายชื่อผู้ใช้งานและข้อมูลสัญญาณไฟฟ้ากล่อมเนื้อที่บันทึกไว้
Post-conditions	ได้ชุดข้อมูลของผู้ใช้งานที่ถูกเลือกไว้สำหรับนำไปใช้ฝึกแบบจำลอง
Main Flow	1) ระบบแสดงรายชื่อผู้ใช้งานที่มีข้อมูล 2) ผู้ดูแลระบบเลือกผู้ใช้งานตามต้องการ 3) ระบบเรียกใช้กรณีการใช้งาน UC-15 เพื่อเลือกรูปแบบผู้ใช้งานเดี่ยวหรือหลายราย
Alternative Flows	A1: หากไม่มีผู้ใช้งานที่มีข้อมูลเพียงพอ ระบบจะแจ้งเตือนให้ดำเนินการเก็บข้อมูลเพิ่มเติม

จากตารางที่ 11 แสดงขั้นตอนการเลือกผู้ใช้งานสำหรับนำข้อมูลไปฝึกแบบจำลอง โดยมีความเชื่อมโยงกับกรณีการใช้งาน UC-15 เพื่อกำหนดรูปแบบชุดข้อมูลที่จะนำไปใช้ในลำดับต่อไป

ตารางที่ 3.15 คำอธิบาย UC-12 เลือกโมเดล Machine Learning

หัวข้อ	รายละเอียด
Use Case ID	UC-12
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเลือกชนิดของแบบจำลองการเรียนรู้ของเครื่องที่ต้องการนำมาใช้ในการฝึก
Pre-conditions	ระบบมีชุดข้อมูลที่ถูกเลือกไว้แล้วจากกรณีการใช้งาน UC-11
Post-conditions	ได้ชนิดของแบบจำลองที่จะนำมาใช้ในการฝึกและประเมินผลในลำดับถัดไป
Main Flow	1) ระบบแสดงรายการแบบจำลองที่รองรับ 2) ผู้ดูแลระบบเลือกแบบจำลองตามต้องการ 3) ระบบเรียกใช้กรณีการใช้งาน UC-16 เพื่อเลือกวิธีการฝึกแบบจำลอง
Alternative Flows	A1: หากผู้ดูแลระบบไม่ได้เลือกแบบจำลองใด ระบบจะใช้แบบจำลองเริ่มต้นที่ถูกกำหนดไว้

จากตารางที่ 12 แสดงขั้นตอนการเลือกชนิดของแบบจำลองการเรียนรู้ของเครื่องที่จะนำมาใช้ฝึกจากชุดข้อมูลที่ถูกเลือกไว้ในขั้นตอนก่อนหน้านี้

ตารางที่ 3.16 คำอธิบาย UC-13 เปรียบเทียบโมเดล ML (Accuracy/F1/Confusion)

หัวข้อ	รายละเอียด
Use Case ID	UC-13
Actor(s)	ผู้ดูแลระบบ
Description	ระบบดำเนินการฝึกและประเมินผลแบบจำลองการเรียนรู้ของเครื่องด้วยค่าความถูกต้อง ค่า F1 และเมตริกซ์ความสับสน

Pre-conditions	ผู้ดูแลระบบดำเนินการเลือกแบบจำลองและวิธีการฝึกจากกรณีการใช้งาน UC-12 และ UC-16 เรียบร้อยแล้ว
Post-conditions	ได้ผลการประเมินประสิทธิภาพของแบบจำลองที่ผ่านการฝึกแล้ว
Main Flow	1) ระบบแบ่งข้อมูลออกเป็นชุดฝึก ชุดตรวจสอบ และชุดทดสอบ 2) ระบบดำเนินการฝึกแบบจำลองตามที่ได้เลือกไว้ 3) ระบบคำนวณและแสดงผลค่าความถูกต้อง ค่า F1 และเมตริกซ์ความสับสน
Alternative Flows	A1: หากกระบวนการฝึกแบบจำลองเกิดข้อผิดพลาด ระบบจะแจ้งเตือนและยกเลิกการฝึกในรอบนั้น

จากตารางที่ 13 แสดงกระบวนการฝึกและประเมินผลแบบจำลอง ซึ่งเป็นผลลัพธ์สำคัญที่ใช้ประกอบการตัดสินใจเลือกแบบจำลองที่มีความเหมาะสมที่สุดสำหรับการจำแนกท่าทาง

ตารางที่ 3.17 คำอธิบาย UC-14 ตั้งค่าระบบ

หัวข้อ	รายละเอียด
Use Case ID	UC-14
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการกำหนดค่าเกณฑ์เริ่มต้นสำหรับการตรวจจับสัญญาณตลอดจนตรวจสอบสถานะฮาร์ดแวร์และข้อมูลรุ่นของระบบ
Pre-conditions	ผู้ดูแลระบบเข้าสู่ระบบสำเร็จเรียบร้อยแล้ว
Post-conditions	ค่าที่กำหนดไว้ถูกนำไปใช้ร่วมกับกรณีการใช้งาน UC-05 ในการควบคุมเซอร์โวของมือเทียมต่อไป
Main Flow	1) ผู้ดูแลระบบเข้าสู่เมนูตั้งค่าระบบ 2) ผู้ดูแลระบบปรับค่าเกณฑ์ด้วยแถบเลื่อน 3) ระบบบันทึกค่าที่กำหนดไว้ทันที
Alternative Flows	A1: หากไม่พบฮาร์ดแวร์เซ็นเซอร์จริง ระบบจะแสดงตัวเลือกเพิ่มเติมสำหรับสลับท่าทางกำมือ/คลายมือด้วยตนเอง เพื่อจำลองการทดสอบ (โหมดจำลอง)

จากตารางที่ 14 แสดงกระบวนการตั้งค่าระบบ ซึ่งเปิดโอกาสให้ผู้ดูแลระบบสามารถปรับค่าเกณฑ์การตรวจจับสัญญาณให้มีความเหมาะสมสอดคล้องกับสภาพการใช้งานจริง ส่วนการเลือกแหล่งที่มาของคำสั่งควบคุมเซอร์โวงระหว่างค่าเกณฑ์ RMS กับแบบจำลองการเรียนรู้ของเครื่องนั้น เป็นการดำเนินการแยกต่างหากที่หน้าเฝ้าติดตามแบบเรียลไทม์ ตามกรณีการใช้งาน UC-19

ตารางที่ 3.18 คำอธิบาย UC-15 เลือกรูปแบบผู้ใช้

หัวข้อ	รายละเอียด
Use Case ID	UC-15

Actor(s)	ผู้ดูแลระบบ, Firebase
Description	ผู้ดูแลระบบดำเนินการเลือกรูปแบบข้อมูลผู้ใช้งานสำหรับการฝึกแบบจำลอง โดยเลือกได้ระหว่างข้อมูลผู้ใช้งานเดี่ยวหรือข้อมูลผู้ใช้งานหลายรายรวมกัน
Pre-conditions	ผู้ดูแลระบบอยู่ในขั้นตอนการเลือกผู้ใช้งาน (กรณีการใช้งาน UC-11)
Post-conditions	ระบบทราบรูปแบบของชุดข้อมูลที่จะนำมาใช้ฝึกแบบจำลอง
Main Flow	1) ระบบแสดงตัวเลือกระหว่างผู้ใช้งานเดี่ยวและผู้ใช้งานหลายราย 2) ผู้ดูแลระบบเลือกรูปแบบที่ต้องการ 3) ระบบดึงข้อมูลจาก Firebase ให้สอดคล้องกับรูปแบบที่เลือกไว้
Alternative Flows	A1: หากเลือกรูปแบบผู้ใช้งานหลายรายแต่ข้อมูลของบางรายไม่ครบถ้วน ระบบจะแจ้งเตือนและให้ดำเนินการเลือกใหม่

จากตารางที่ 15 แสดงกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งขยายขีดความสามารถของกรณีการใช้งาน UC-11 ให้รองรับทั้งการฝึกแบบจำลองเฉพาะรายบุคคลและการฝึกแบบจำลองรวมจากผู้ใช้งานหลายราย

ตารางที่ 3.19 คำอธิบาย UC-16 เลือกวิธีการฝึกโมเดล

หัวข้อ	รายละเอียด
Use Case ID	UC-16
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเลือกวิธีการฝึกแบบจำลอง โดยเลือกได้ระหว่างการใช้แบบจำลองพื้นฐานเพียงลำพัง หรือใช้แบบจำลองพื้นฐานร่วมกับวิธีการรวมกลุ่มแบบจำลอง
Pre-conditions	ผู้ดูแลระบบดำเนินการเลือกชนิดของแบบจำลองจากกรณีการใช้งาน UC-12 เรียบร้อยแล้ว
Post-conditions	ระบบทราบวิธีการฝึกที่จะนำไปใช้ในขั้นตอนถัดไป
Main Flow	1) ระบบแสดงตัวเลือกวิธีการฝึก 2) ผู้ดูแลระบบเลือกแบบจำลองพื้นฐานหรือแบบจำลองพื้นฐานร่วมกับวิธีการรวมกลุ่มแบบจำลอง 3) ระบบบันทึกวิธีการฝึกที่เลือกไว้
Alternative Flows	A1: หากทรัพยากรของเครื่องแม่ข่าย Raspberry Pi ไม่เพียงพอสำหรับวิธีการรวมกลุ่มแบบจำลอง ระบบจะแนะนำให้ใช้แบบจำลองพื้นฐานเพียงลำพัง

จากตารางที่ 16 แสดงกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งขยายขีดความสามารถของกรณีการใช้งาน UC-12 ให้สามารถเลือกได้ว่าจะดำเนินการฝึกด้วยแบบจำลองเดี่ยวหรือร่วมกับวิธีการรวมกลุ่มแบบจำลองเพื่อเพิ่มความแม่นยำในการจำแนก

ตารางที่ 3.20 คำอธิบาย UC-17 เปรียบเทียบผลลัพธ์การจำแนกกับโมเดลอื่น

หัวข้อ	รายละเอียด
Use Case ID	UC-17
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเปรียบเทียบผลลัพธ์การจำแนกของแบบจำลองที่ผ่านการฝึกแล้วกับแบบจำลองอื่นที่เคยฝึกไว้ก่อนหน้านี้
Pre-conditions	มีผลการประเมินแบบจำลองจากกรณีการใช้งาน UC-13 อย่างน้อยสองแบบจำลองขึ้นไป
Post-conditions	ผู้ดูแลระบบทราบว่าแบบจำลองใดมีประสิทธิภาพเหมาะสมที่สุดสำหรับการใช้งาน
Main Flow	1) ระบบแสดงผลการประเมินของแบบจำลองทั้งหมดที่ผ่านการฝึกไว้ 2) ผู้ดูแลระบบเลือกแบบจำลองที่ต้องการเปรียบเทียบ 3) ระบบแสดงตารางเปรียบเทียบค่าประสิทธิภาพของแต่ละแบบจำลอง 4) ผู้ดูแลระบบสามารถเรียกใช้กรณีการใช้งาน UC-20 เพื่อส่งออกผลการเปรียบเทียบเป็น CSV ได้ในขั้นตอนนี้
Alternative Flows	A1: หากมีแบบจำลองให้เปรียบเทียบเพียงชนิดเดียว ระบบจะแจ้งว่าไม่สามารถดำเนินการเปรียบเทียบได้

จากตารางที่ 17 แสดงกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งขยายขีดความสามารถของกรณีการใช้งาน UC-13 ให้สามารถเปรียบเทียบประสิทธิภาพระหว่างแบบจำลองหลายชนิดได้ในคราวเดียวกัน อันเป็นการสนับสนุนการเลือกแบบจำลองที่เหมาะสมที่สุดสำหรับงานวิจัยนี้

ตารางที่ 3.21 คำอธิบาย UC-18 ฝ้าติดตามสัญญาณ EMG และผลทำนายท่าทาง (Dashboard)

หัวข้อ	รายละเอียด
Use Case ID	UC-18
Actor(s)	ผู้ดูแลระบบ, เซนเซอร์
Description	ระบบแสดงสถานะการทำงานแบบเรียลไทม์บนหน้าฝ้าติดตามซึ่งเป็นหน้าแรกที่ปรากฏภายหลังเข้าสู่ระบบสำเร็จ ประกอบด้วยกราฟสัญญาณ EMG ค่าทำนายท่าทางปัจจุบันพร้อมค่าความมั่นใจ สถานะการเชื่อมต่อ Firebase จำนวนตัวอย่างข้อมูลที่ผ่านการฝึกแล้ว และเมทริกซ์ความสับสนโดยย่อของแบบจำลองที่ใช้งานอยู่
Pre-conditions	ผู้ดูแลระบบเข้าสู่ระบบสำเร็จเรียบร้อยแล้ว และเซนเซอร์เชื่อมต่อกับระบบ หรืออยู่ในโหมดจำลอง
Post-conditions	ผู้ดูแลระบบทราบสถานะปัจจุบันของระบบแบบเรียลไทม์ และสามารถตัดสินใจปรับตั้งค่าต่าง ๆ ในลำดับต่อไปได้

Main Flow	1) ระบบอ่านค่าสัญญาณ EMG ต่อเนื่องจากเซนเซอร์ 2) ระบบคำนวณค่า RMS และ/หรือทำนายท่าทางด้วยแบบจำลองที่เลือกไว้ 3) ระบบอัปเดตกราฟ ตัวเลข และเมทริกซ์ความสัมพันธ์บนหน้าจอตามช่วงเวลาที่กำหนด
Alternative Flows	A1: หากไม่พบฮาร์ดแวร์เซนเซอร์จริง ระบบจะเข้าสู่โหมดจำลองและแสดงข้อความแจ้งเตือนบนแถบสถานะ

จากตารางที่ 18 แสดงกระบวนการเฝ้าติดตามสถานะของระบบแบบเรียลไทม์ ซึ่งเป็นกรณีการใช้งานที่ผู้ดูแลระบบพบเห็นเป็นลำดับแรกภายหลังเข้าสู่ระบบสำเร็จ ทำหน้าที่เป็นศูนย์กลางในการติดตามภาพรวมการทำงานของระบบตลอดระยะเวลาการใช้งาน

ตารางที่ 3.22 คำอธิบาย UC-19 เลือกแหล่งที่มาคำสั่งควบคุมเซอร์โว

หัวข้อ	รายละเอียด
Use Case ID	UC-19
Actor(s)	ผู้ดูแลระบบ
Description	ผู้ดูแลระบบดำเนินการเลือกว่าจะใช้ค่าเกณฑ์ RMS Threshold หรือผลลัพธ์จากแบบจำลองการเรียนรู้ของเครื่องเป็นตัวตัดสินใจสั่งงานเซอร์โวของมือเทียม
Pre-conditions	ผู้ดูแลระบบอยู่ในหน้าจอเฝ้าติดตามแบบเรียลไทม์ (กรณีการใช้งาน UC-18)
Post-conditions	ระบบทราบแหล่งที่มาของคำสั่งควบคุมเซอร์โวที่จะนำไปใช้ในกรณีการใช้งาน UC-05 ต่อไป
Main Flow	1) ระบบแสดงตัวเลือกระหว่างค่าเกณฑ์ RMS Threshold และแบบจำลองการเรียนรู้ของเครื่อง 2) ผู้ดูแลระบบเลือกแหล่งที่มาที่ต้องการ 3) ระบบบันทึกตัวเลือกดังกล่าวและนำไปใช้ทันทีในรอบถัดไปของกรณีการใช้งาน UC-05
Alternative Flows	A1: หากเลือกแบบจำลองการเรียนรู้ของเครื่องแต่ยังไม่เคยมีการฝึกแบบจำลองใดเลย ระบบจะแจ้งเตือนและใช้ค่าเกณฑ์ RMS Threshold แทนโดยอัตโนมัติ

จากตารางที่ 19 แสดงกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งขยายขีดความสามารถของกรณีการใช้งาน UC-18 ให้ผู้ดูแลระบบสามารถกำหนดแหล่งที่มาของการตัดสินใจควบคุมเซอร์โวได้ตามความเหมาะสมของสภาพการใช้งาน

ตารางที่ 3.23 คำอธิบาย UC-20 ส่งออกผลเปรียบเทียบโมเดลเป็น CSV


หัวข้อ	รายละเอียด
Use Case ID	UC-20
Actor(s)	ผู้ดูแลระบบ

Description	ผู้ดูแลระบบดำเนินการส่งออกตารางเปรียบเทียบผลลัพธ์ของแบบจำลองทั้งหมดที่เคยฝึกไว้ ให้อยู่ในรูปแบบไฟล์ CSV
Pre-conditions	มีผลการประเมินแบบจำลองอย่างน้อยหนึ่งแบบจำลองจากกรณีการใช้งาน UC-13 หรือ UC-17
Post-conditions	ได้ไฟล์ CSV ของตารางเปรียบเทียบแบบจำลองทั้งหมด บันทึกไว้ในเครื่อง
Main Flow	1) ผู้ดูแลระบบเลือกคำสั่งส่งออกที่หน้าสรุปผลโมเดล 2) ระบบแปลงตารางเปรียบเทียบให้อยู่ในรูปแบบ CSV 3) ระบบบันทึกไฟล์ดังกล่าวลงในเครื่อง
Alternative Flows	A1: หากยังไม่มีแบบจำลองใดผ่านการฝึกเลย ระบบจะแจ้งเตือนและยกเลิกการทำงานในขั้นตอนนี้

จากตารางที่ 20 แสดงกรณีการใช้งานที่มีความสัมพันธ์แบบขยายการทำงาน ซึ่งขยายขีดความสามารถของกรณีการใช้งาน UC-17 ให้สามารถนำผลการเปรียบเทียบระหว่างแบบจำลองไปจัดทำรายงานหรือวิเคราะห์ต่อภายนอกระบบได้อย่างสะดวก อันเป็นขั้นตอนสุดท้ายของกลุ่มกรณีการใช้งานด้านการเรียนรู้ของเครื่อง

3.6 แผนภาพกิจกรรม (Activity Diagram)

แผนภาพกิจกรรมแสดงลำดับการทำงานของระบบในระดับที่ละเอียดกว่าแผนภาพการทำงานของระบบ (System Workflow) ในหัวข้อ 3.5 โดยครอบคลุมตั้งแต่การอ่านสัญญาณดิบจากเซนเซอร์ กระบวนการกรองและสกัดคุณลักษณะสัญญาณ การตัดสินใจเลือกเส้นทางควบคุมระหว่างค่าเกณฑ์ RMS Threshold กับแบบจำลองการเรียนรู้ของเครื่อง กลไก Debounce ที่ป้องกันเซอร์โวลันเมื่อสัญญาณแกว่งใกล้จุดตัดสินใจ ไปจนถึงการบันทึกข้อมูลและซิงก์ขึ้น Firebase ซึ่งทำงานคู่ขนานกับการอัปเดตหน้าจอ Dashboard ดังแสดงในรูปที่ 3.17



รูปที่ 3.17 แผนภาพกิจกรรมของระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อ

จากรูปที่ 3.17 กระบวนการเริ่มต้นจากการอ่านสัญญาณไฟฟ้ากล้ามเนื้อด้วยอัตราสุ่มตัวอย่าง 500 Hz ผ่านกระบวนการกรองสัญญาณและสกัดคุณลักษณะทั้ง 7 ค่าตามที่อธิบายไว้ในหัวข้อ 3.4 จากนั้นระบบจะตรวจสอบแหล่งที่มาของคำสั่งควบคุมที่ผู้ดูแลระบบเลือกไว้ หากเลือกค่าเกณฑ์ RMS Threshold ระบบจะเปรียบเทียบค่า RMS กับค่าเกณฑ์โดยตรง แต่หากเลือกแบบจำลองการเรียนรู้ของเครื่อง ระบบจะป้อนคุณลักษณะทั้ง 7 ค่าเข้าแบบจำลองที่ฝึกไว้แล้วเพื่อทำนายท่าทาง ไม่ว่าจะเลือกเส้นทางใด ผลลัพธ์ที่ได้จะถูกตรวจสอบผ่านกลไก Debounce ก่อนตัดสินใจส่งคำสั่งควบคุมเซอร์วอมอเตอร์จริง เพื่อป้องกันการสั่งงานที่ถี่เกินไปจากสัญญาณที่แกว่งใกล้จุดตัดสินใจ ในขั้นตอนถัดไป ระบบจะดำเนินการสองงานคู่ขนานกัน คือ การบันทึกข้อมูลตัวอย่างลงไฟล์ในเครื่องแบบทันที และการอัปเดตหน้าจอ Dashboard ให้สะท้อนสถานะล่าสุด ก่อนที่เธรดพื้นหลังจะทยอยซิงค์ข้อมูลขึ้น Firebase เมื่อ

ตรวจพบการเชื่อมต่ออินเทอร์เน็ต อันเป็นการออกแบบแบบออฟไลน์ก่อน (Offline-first) ที่ช่วยให้ระบบยังคงทำงานได้ต่อเนื่องแม้ในสถานะที่เครือข่ายไม่เสถียร


3.7 การเลือกใช้และเปรียบเทียบแบบจำลองการเรียนรู้ของเครื่อง (Model Selection)

เนื่องจากสัญญาณไฟฟ้ากล่อมเนื้อมีความแปรปรวนสูงระหว่างผู้ใช้งานแต่ละราย ทั้งในด้านความแรงของสัญญาณ ตำแหน่งการติดตั้งอิเล็กทรอนิกส์ และลักษณะทางสรีระของกล้ามเนื้อที่เหลือนอยู่ จึงไม่มีแบบจำลองการเรียนรู้ของเครื่องชนิดใดชนิดหนึ่งที่ให้ผลลัพธ์ดีที่สุดสำหรับผู้ใช้งานทุกราย ระบบจึงออกแบบให้รองรับแบบจำลองพื้นฐาน (Base Model) จำนวน 9 ชนิด และวิธีการรวมกลุ่มแบบจำลอง (Ensemble Method) อีก 2 แบบ เพื่อให้ผู้ดูแลระบบสามารถทดลองและเลือกแบบจำลองที่เหมาะสมที่สุดสำหรับผู้ใช้งานแต่ละบุคคลได้ โดยหัวข้อย่อยต่อไปนี้อธิบายหลักการทำงาน แนวคิดเชิงคณิตศาสตร์ และเหตุผลของการนำแบบจำลองแต่ละชนิดมาใช้ในโครงงานนี้โดยละเอียด

3.7.1 การจำแนกแบบเบย์อย่างไร้เดียงสา (Naive Bayes)

การจำแนกแบบเบย์อย่างไร้เดียงสาอาศัยทฤษฎีบทของเบย์ (Bayes' Theorem) ในการคำนวณความน่าจะเป็นภายหลัง (Posterior Probability) ของแต่ละประเภทเมื่อทราบค่าคุณลักษณะ โดยมีข้อสมมติที่ว่าคุณลักษณะแต่ละตัวมีความเป็นอิสระต่อกันภายใต้เงื่อนไขของประเภทนั้น (Conditional Independence) ดังสมการ

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}, \quad \hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y)$$



รูปที่ 3.18 การกระจายตัวความน่าจะเป็นของแต่ละประเภทใน Naive Bayes

จากรูปที่ 3.18 แต่ละประเภท (OPEN และ FIST) มีการกระจายตัวของค่าคุณลักษณะเป็นโค้งระฆังคว่ำ (Gaussian Distribution) ที่แตกต่างกัน เมื่อพบตัวอย่างใหม่ ระบบจะคำนวณว่าตัวอย่างนั้นมีโอกาสเกิดจากการกระจายตัวของประเภทใดมากกว่ากัน โดยเส้นประคือขอบเขตการตัดสินใจ (Decision Boundary) ที่แบ่งพื้นที่ระหว่างสองประเภทออกจากกัน


```
# Gaussian Naive Bayes -- Pseudocode
Given training data {(x_i, y_i)}, classes C = {OPEN, FIST}
1) For each class c in C:
    คำนวณ mean(x|c) และ variance(x|c) ของคุณลักษณะแต่ละตัว
2) เมื่อพบขารณ์ตัวอย่างใหม่ x:
    For each class c: score(c) = P(c) * prod_i P(x_i | c)
    (Gaussian PDF)
3) ทำนายเป็นคลาสที่ score(c) สูงสุด: y_hat = argmax_c score(c)
```

ในโครงงานนี้ใช้ GaussianNB จากไลบรารี scikit-learn เป็นหนึ่งในแบบจำลองพื้นฐานที่ใช้ทรัพยากรในการประมวลผลน้อยที่สุด และรองรับการเทรนแบบ partial_fit ซึ่งเป็นการเรียนรู้แบบออนไลน์จริง (อัปเดตแบบจำลองทีละส่วนโดยไม่ต้องเทรนซ้ำจากศูนย์) เหมาะสำหรับการประมวลผลแบบเรียลไทม์บน Raspberry Pi 5

3.7.2 เพื่อนบ้านใกล้ที่สุด k ตัว (k-Nearest Neighbors: k-NN)

เพื่อนบ้านใกล้ที่สุด k ตัว เป็นอัลกอริธึมที่ไม่มีขั้นตอนการสร้างแบบจำลองล่วงหน้า (Lazy Learning) โดยจำแนกประเภทของตัวอย่างใหม่จากประเภทของเพื่อนบ้าน k จุดที่อยู่ใกล้ที่สุดในปริภูมิคุณลักษณะ โดยใช้ระยะห่างแบบยูคลิด (Euclidean Distance) ดังสมการ

$$d(x, x') = \sqrt{\sum_{i=1}^n (x_i - x'_i)^2}$$



รูปที่ 3.19 หลักการทำงานของ k-Nearest Neighbors

จากรูปที่ 3.19 เมื่อพบจุดข้อมูลใหม่ (เครื่องหมายดาว) ระบบจะคำนวณระยะห่างไปยังจุดข้อมูลฝึกทุกจุด แล้วเลือก k จุดที่ใกล้ที่สุด (วงกลมประ) จากนั้นจึงตัดสินประเภทด้วยการลงคะแนนเสียงข้างมากของประเภทในกลุ่ม k จุดนั้น ในตัวอย่างนี้กำหนด k เท่ากับ 5

k-Nearest Neighbors -- Pseudocode
 Given training data $\{(x_i, y_i)\}$, parameter k ($k=5$ ในระบบนี้)

- 1) เมื่อพบขารณ์ตัวอย่างใหม่ x :
 คำนวณระยะห่าง $d(x, x_i)$ กับทุกตัวอย่างในชุดฝึก
- 2) เลือก k ตัวอย่างที่มีระยะห่างน้อยที่สุด
- 3) นับคะแนนเสียงของคลาสในกลุ่ม k ตัวอย่างนั้น
- 4) ทำนายเป็นคลาสที่ได้คะแนนเสียงมากที่สุด (Majority Voting)

ในโครงงานนี้ใช้ KNeighborsClassifier จากไลบรารี scikit-learn กำหนดค่า k เท่ากับ 5 เป็นแบบจำลองที่มีความเร็วในการเทรนสูงมาก (เพียงเก็บข้อมูลไว้เฉย ๆ) แต่ความเร็วในการทำนายจะลดลงเมื่อจำนวนข้อมูลฝึกเพิ่มขึ้น เนื่องจากต้องคำนวณระยะห่างกับทุกจุดข้อมูลในทุกครั้งที่ทำนาย


3.7.3 ต้นไม้ตัดสินใจและป่าสุ่ม (Decision Tree / Random Forest / Random Tree)

ต้นไม้ตัดสินใจจำแนกข้อมูลด้วยการแบ่งข้อมูลออกเป็นกลุ่มย่อยตามเงื่อนไขของคุณลักษณะเข้าไปเรื่อย ๆ โดยเลือกเงื่อนไขการแบ่งที่ทำให้แต่ละกลุ่มย่อยมีความบริสุทธิ์มากที่สุด วัดด้วยค่าความไม่บริสุทธิ์ของจินี (Gini Impurity) ดังสมการ

$$\text{Gini} = 1 - \sum_{i=1}^C p_i^2$$

โดย p_i คือสัดส่วนของตัวอย่างประเภทที่ i ในโหนดนั้น ยิ่งค่า Gini ต่ำเท่าใด แสดงว่าข้อมูลในโหนดนั้นมีความบริสุทธิ์สูงเท่านั้น ป่าสุ่ม (Random Forest) และต้นไม้แบบสุ่ม (Random Tree) พัฒนาต่อยอดจากแนวคิดนี้โดยสร้างต้นไม้จำนวนมากรวมกันเป็นกลุ่ม แต่ละต้นฝึกด้วยข้อมูลชุดย่อยที่สุ่มแบบคืนกลับ (Bootstrap Sampling) และสุ่มเลือกคุณลักษณะบางส่วนมาพิจารณาในแต่ละโหนด ดังแสดงในรูปที่ 3.20

Decision Tree ensembles into Random Forest (Bootstrap + Majority Voting)



รูปที่ 3.20 การรวมต้นไม้ตัดสินใจหลายต้นเข้าเป็นป่าสุ่ม

จากรูปที่ 3.20 ต้นไม้แต่ละต้นเรียนรู้จากข้อมูลชุดย่อยที่แตกต่างกัน ทำให้แต่ละต้นให้ผลการทำนายที่อาจแตกต่างกันบ้าง แต่เมื่อรวมผลด้วยการลงคะแนนเสียงข้างมาก (Majority Voting) จะได้ผลลัพธ์ที่มีความแม่นยำและความเสถียรสูงกว่าการใช้ต้นไม้เพียงต้นเดียว


```
# Random Forest (Bootstrap + Bagging of Decision Trees) -- Pseudocode
Given training data D, จำนวนต้นไม้ B
1) For b = 1..B:
    a) ตุ่มตัวอย่างแบบคืนกลับ (Bootstrap) จาก D ได้ชุดข้อมูล D_b
    b) ฝึกต้นไม้ตัดสินใจ T_b บน D_b โดยแต่ละโหนดสุ่มเลือก
       คุณสมบัติบางส่วนมาพิจารณาแบ่งข้อมูล (เกณฑ์ Gini Impurity)
2) เมื่อพยากรณ์ตัวอย่างใหม่ x:
    รวมผลทำนายจากทุกต้นไม้ T_1..T_B ด้วย Majority Voting
```

ในโครงงานนี้ใช้ DecisionTreeClassifier (C4.5-like), ExtraTreeClassifier (Random Tree) และ RandomForestClassifier จากไลบรารี scikit-learn กำหนดความลึกสูงสุด (max_depth) เท่ากับ 5 เพื่อให้เปรียบเทียบกันได้อย่างยุติธรรม โดยกำหนดให้ป่าสุ่มเป็นแบบจำลองเริ่มต้นของระบบ เนื่องจากให้ความสมดุลที่ดีระหว่างความแม่นยำ ความเร็ว และความทนทานต่อสัญญาณรบกวนที่มักพบในสัญญาณกล้ำเนื้อ

3.7.4 โครงข่ายประสาทเทียม (Artificial Neural Network: ANN)

โครงข่ายประสาทเทียมประกอบด้วยชั้นอินพุต ชั้นซ่อน และชั้นเอาต์พุต ซึ่งแต่ละโหนดเชื่อมต่อกันด้วยค่าน้ำหนัก (Weight) และแปลงผลรวมถ่วงน้ำหนักของสัญญาณนำเข้าด้วยฟังก์ชันกระตุ้น (Activation Function) เช่น ฟังก์ชันซิกมอยด์ ดังสมการ

$$\hat{y} = \sigma\left(\sum_{i=1}^n w_i x_i + b\right), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$



รูปที่ 3.21 โครงสร้างโครงข่ายประสาทเทียมแบบหลายชั้น

จากรูปที่ 3.21 สัญญาณคุณลักษณะทั้ง 7 ค่าจะถูกส่งเข้าชั้นอินพุต ผ่านการประมวลผลในชั้นซ่อนสองชั้น ก่อนได้ผลลัพธ์เป็นความน่าจะเป็นของท่าทาง FIST ที่ชั้นเอาต์พุต กระบวนการฝึกใช้การแพร่ย้อนกลับ (Backpropagation) ร่วมกับการลดค่าความคลาดเคลื่อนแบบไล่ระดับ (Gradient Descent) เพื่อปรับค่าน้ำหนักของการเชื่อมต่อให้เหมาะสมที่สุด


```
# Multilayer Perceptron (ANN) -- Pseudocode
Given training data {(x_i, y_i)}, epochs, learning rate eta
1) กำหนดค่าน้ำหนัก (weight) เริ่มต้นแบบสุ่ม
2) For epoch = 1..N:
  a) Forward pass: คำนวณ y_hat ผ่านแต่ละชั้นด้วย sigma(sum(w*x)+b)
  b) คำนวณค่าความสูญเสีย (Loss) ระหว่าง y_hat กับ y จริง
  c) Backpropagation: คำนวณ gradient แล้วปรับน้ำหนัก
    w <- w - eta * dLoss/dw
3) ทำซ้ำตัวอย่างใหม่ด้วยน้ำหนักที่ฝึกเสร็จแล้ว (Forward pass เท่านั้น)
```

ในโครงงานนี้ใช้ MLPClassifier จากไลบรารี scikit-learn เป็นแบบจำลองที่สามารถเรียนรู้ความสัมพันธ์แบบไม่เป็นเชิงเส้นที่ซับซ้อนได้ดี เหมาะกับกรณีที่รูปแบบสัญญาณของผู้ใช้งานมีความซับซ้อนสูง แต่ใช้เวลาในการฝึกนานกว่าแบบจำลองกลุ่มเบา

3.7.5 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)

เครื่องเวกเตอร์สนับสนุนหาระนาบแบ่งประเภท (Hyperplane) ที่มีระยะขอบ (Margin) ระหว่างสองประเภทกว้างที่สุด โดยยอมให้มีข้อผิดพลาดได้บ้างผ่านฟังก์ชันการสูญเสียแบบบานพับ (Hinge Loss) ร่วมกับพจน์ปรับค่าปกติ (Regularization) ดังสมการ

$$L(w) = \max(0, 1 - y(w \cdot x + b)) + \frac{\lambda}{2} \|w\|^2$$



รูปที่ 3.22 ระบายแบ่งประเภทและระยะขอบสูงสุดของ SVM

จากรูปที่ 3.22 เส้นทึบคือระนาบแบ่งประเภท ส่วนเส้นประคือขอบเขตของระยะขอบ (Margin) จุดข้อมูลที่อยู่ใกล้ระยะขอบมากที่สุด (วงกลมสีแดง) เรียกว่าเวกเตอร์สนับสนุน (Support Vectors) ซึ่งมีบทบาทสำคัญต่อการกำหนดตำแหน่งของระนาบแบ่งประเภท

```
# Support Vector Machine -- Pseudocode
Given training data {(x_i, y_i)}, y_i in {-1, +1}
1) หาค่า w, b ที่ทำให้ระยะขอบ (Margin) ระหว่างสองคลาสกว้างที่สุด
   โดยยอมให้มีข้อผิดพลาดได้บ้าง (Soft Margin) ผ่านการลดค่า
   Hinge Loss ร่วมกับพจน์ปรับค่าปกติ (Regularization)
2) ในระบบนี้ใช้ SGDClassifier(loss='hinge') ฝึกแบบ partial_fit
   ที่ละกลุ่มข้อมูล (online learning) แทนการแก้สมการ QP โดยตรง
3) เมื่อพบการวัดตัวอย่างใหม่ x: ทำนายตามเครื่องหมายของ w.x+b
```


ในโครงงานนี้ใช้ SGDClassifier(loss='hinge') จากไลบรารี scikit-learn ซึ่งเทียบเท่า SVM เชิงเส้นที่ฝึกด้วยวิธี Stochastic Gradient Descent รองรับการเรียนรู้แบบ partial_fit เช่นเดียวกับ Naive Bayes จึงเหมาะสำหรับการทดสอบรูปแบบการเรียนรู้แบบต่อเนื่องบน Raspberry Pi 5

3.7.6 เอ็กซ์ตรีมเกรเดียนท์บูสติงและแคทบูส (XGBoost / CatBoost)

XGBoost และ CatBoost เป็นอัลกอริทึมในกลุ่ม Gradient Boosting ที่สร้างต้นไม้ตัดสินใจต่อเนื่องกันเป็นลำดับ โดยต้นไม้แต่ละต้นเรียนรู้เพื่อแก้ไขความคลาดเคลื่อน (Residual) ที่เหลือจากต้นไม้ก่อนหน้า ดังสมการ

$$\hat{y}^{(t)}(x) = \sum_{k=1}^t f_k(x), \quad \text{Obj}^{(t)} = \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Gradient Boosting (XGBoost / CatBoost): Sequential Additive Trees



รูปที่ 3.23 การรวมต้นไม้แบบต่อเนื่อง (Additive Ensemble) ของ Gradient Boosting

จากรูปที่ 3.23 ต้นไม้แต่ละต้นไม้ได้ทำงานอิสระเหมือนป่าสุ่ม แต่ทำงานต่อเนื่องกันเป็นลำดับ โดยต้นไม้ต้นที่สองจะเรียนรู้จากความคลาดเคลื่อนที่ต้นไม้ต้นแรกยังทำนายผิดพลาดอยู่ และเป็นเช่นนี้ไปเรื่อย ๆ ผลลัพธ์สุดท้ายคือผลรวมของทุกต้นไม้ ทำให้แบบจำลองมีความแม่นยำสูงขึ้นตามลำดับการฝึก


```
# Gradient Boosting (XGBoost / CatBoost) -- Pseudocode
Given training data  $\{(x_i, y_i)\}$ , จำนวนต้นไม้  $M$ 
1) กำหนดโมเดลเริ่มต้น  $F_0(x)$  (เช่น ค่าคงที่)
2) For  $m = 1..M$ :
  a) คำนวณ gradient/hessian ของ loss ที่จุดทำนายปัจจุบัน
  b) ฝึกต้นไม้ตัดสินใจ  $T_m$  ให้ fit ค่า gradient/hessian นั้น
    ภายใต้พารามิเตอร์ปรับโทษ (regularization)
  c) อัปเดตโมเดล:  $F_m(x) := F_{m-1}(x) + \eta * T_m(x)$ 
3) ทำนายตัวอย่างใหม่:  $\hat{y} = F_M(x)$ 
```

ในโครงการนี้ใช้ XGBoost กำหนดจำนวนต้นไม้ 40 ต้น ความลึกสูงสุด 4 และอัตราการเรียนรู้ 0.3 ส่วน CatBoost กำหนด 60 รอบการวนซ้ำ ความลึกสูงสุด 4 ทั้งสองเป็นไลบรารีเสริมที่ต้องติดตั้งเพิ่มเติมนอกเหนือจาก scikit-learn และมักให้ความแม่นยำสูงที่สุดในหลายกรณี แต่ใช้ทรัพยากรในการประมวลผลมากกว่าแบบจำลองกลุ่มอื่น


3.7.7 การรวมกลุ่มแบบจำลอง: Bagging และ AdaBoost

นอกเหนือจากแบบจำลองพื้นฐานทั้ง 9 ชนิดข้างต้น ระบบยังรองรับวิธีการรวมกลุ่มแบบจำลอง (Ensemble Method) สองรูปแบบที่ทำงานร่วมกับแบบจำลองพื้นฐานได้ก็ได้แก่การรวมกลุ่มแบบแบ็กกิง (Bagging) ที่ฝึกแบบจำลองย่อยหลายตัวแบบขนานจากข้อมูลที่สุ่มต่างกัน และการรวมกลุ่มแบบปรับเพิ่มน้ำหนัก (AdaBoost) ที่ฝึกแบบจำลองย่อยตามลำดับโดยเพิ่มน้ำหนักให้ตัวอย่างที่ทำนายผิด ดังแสดงในรูปที่ 3.24

Bagging: Parallel Bootstrap Samples



AdaBoost: Sequential Weighted Learning



รูปที่ 3.24 เปรียบเทียบแนวคิดของ Bagging และ AdaBoost

จากรูปที่ 3.24 ด้านซ้าย Bagging สุ่มตัวอย่างข้อมูลแบบคืนกลับหลายชุดพร้อมกัน แล้วฝึกแบบจำลองย่อยแบบขนาน ก่อนรวมผลด้วยการลงคะแนนเสียงข้างมาก ด้านขวา AdaBoost ฝึกแบบจำลองย่อยทีละตัวตามลำดับ โดยแต่ละรอบจะเพิ่มน้ำหนักให้ตัวอย่างที่รอบก่อนหน้าทำนายผิด แล้วรวมผลแบบถ่วงน้ำหนักตามความแม่นยำของแต่ละแบบจำลองย่อย ดังสมการปรับน้ำหนักตัวอย่างของ AdaBoost

$$w_i \leftarrow w_i \cdot \exp(\alpha_t \cdot 1[y_i \neq h_t(x_i)]) , \quad \alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

```
# Bagging vs AdaBoost -- Pseudocode
[Bagging]
1) For b = 1..B: สุ่มตัวอย่างแบบคืนกลับจาก D ได้ D_b
2)          ฝึกแบบจำลองพื้นฐาน h_b บน D_b (ขนานกัน)
3) ทำนาย: Majority Voting จาก h_1..h_B


[AdaBoost]
1) กำหนดน้ำหนักตัวอย่างเริ่มต้นเท่ากันทุกตัว w_i = 1/n
2) For t = 1..T:
    a) ฝึกแบบจำลองพื้นฐาน h_t โดยถ่วงน้ำหนักตาม w_i
    b) คำนวณอัตราผิดพลาด eps_t แล้วหาค่าน้ำหนักโมเดล alpha_t
    c) เพิ่มน้ำหนัก w_i ของตัวอย่างที่ h_t ทำนายผิด
3) ทำนาย: Weighted Vote จาก sum(alpha_t * h_t(x))
```

ในโครงงานนี้ใช้ BaggingClassifier และ AdaBoostClassifier จากไลบรารี scikit-learn ห่อหุ้มแบบจำลองพื้นฐานที่ผู้ดูแลระบบเลือกไว้ โดยปรับจำนวนแบบจำลองย่อยโดยอัตโนมัติตามความหนักเบาของแบบจำลองพื้นฐาน (6 ตัวสำหรับแบบจำลองหนัก เช่น ANN, SVM, XGBoost, CatBoost และ 10–15 ตัวสำหรับแบบจำลองเบา) ทั้งนี้ระบบจำกัดไม่ให้ใช้ k-NN ร่วมกับ AdaBoost เนื่องจาก k-NN ไม่รองรับพารามิเตอร์น้ำหนักตัวอย่างที่ AdaBoost จำเป็นต้องใช้ในการปรับน้ำหนักข้อมูลระหว่างรอบการฝึก

ด้วยเหตุที่ Raspberry Pi 5 มีทรัพยากรในการประมวลผลจำกัดเมื่อเทียบกับคอมพิวเตอร์ประสิทธิภาพสูง และระบบต้องประมวลผลสัญญาณแบบเรียลไทม์อย่างต่อเนื่อง ระบบจึงกำหนดให้ป่าสุ่มเป็นแบบจำลองเริ่มต้น เนื่องจากให้ความสมดุลที่ดีระหว่างความแม่นยำ ความเร็ว และความทนทานต่อสัญญาณรบกวน อย่างไรก็ตาม ระบบไม่ได้จำกัดให้ใช้แบบจำลองใดแบบจำลองหนึ่งตายตัว แต่เปิดโอกาสให้ผู้ดูแลระบบสามารถฝึกและเปรียบเทียบแบบจำลองทั้งหมดพร้อมกันได้ในคราวเดียว ผ่านฟังก์ชันทรนทุกโมเดล แล้วพิจารณาเลือกแบบจำลองที่ให้ค่าความถูกต้อง (Accuracy) ค่า F1 (F1-score) และเมทริกซ์ความสับสน (Confusion Matrix) ที่เหมาะสมที่สุดสำหรับผู้ใช้งานแต่ละรายจากหน้าสรุปผลโมเดล อันเป็นแนวทางที่ยืดหยุ่นและสอดคล้องกับความแตกต่างของสัญญาณกล้ำเนื้อในแต่ละบุคคลมากกว่าการกำหนดแบบจำลองตายตัวเพียงชนิดเดียว

3.8 การออกแบบส่วนติดต่อผู้ใช้ (UI/UX Design)

ส่วนติดต่อผู้ใช้ของระบบถูกออกแบบให้ผู้ใช้และระบบสามารถ "เห็นสถานการณ์ปัจจุบันได้ในทันทีและเข้าใจแนวโน้มของสัญญาณได้ในพริบตาเดียว" โดยยึดหลักการจัดวางองค์ประกอบตามลำดับความสำคัญของข้อมูล และความสม่ำเสมอของภาพลักษณ์ทั้งระบบ โครงสร้างหลักประกอบด้วยแถบเมนูนำทาง (Sidebar Navigation) ทางด้านซ้ายสำหรับสลับไปยัง 6 หน้าหลัก ได้แก่ Dashboard เครื่องมือสอบเทียบ (Calibration Tool) การเรียนรู้ของเครื่อง (Machine Learning) สรุปผลโมเดล บันทึกข้อมูล (Data Log) และการตั้งค่าระบบ ร่วมกับแถบหัวเรื่อง (Header) ด้านบนที่แสดงสถานะการเชื่อมต่อ Firebase และข้อมูลผู้ใช้งานปัจจุบันตลอดเวลา



รูปที่ 3.25 หน้า Dashboard ของระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อ

จากรูปที่ 3.25 ส่วนติดต่อผู้ใช้ของระบบถูกออกแบบให้ผู้ใช้ "เห็นสถานการณ์ปัจจุบันได้ในทันทีและเข้าใจแนวโน้มของสัญญาณได้ในพริบตาเดียว" โดยแบ่งพื้นที่หน้าจอออกเป็นส่วนที่ทำงานร่วมกัน ส่วนบนซ้ายเป็นการ์ดสรุปท่าทางปัจจุบัน (FIST หรือ OPEN) แสดงด้วยตัวอักษรขนาดใหญ่พร้อมค่าความมั่นใจเพื่อให้อ่านได้รวดเร็วแม้ในระยะไกลจากหน้าจอ ถัดมาเป็นการ์ดค่า RMS ปัจจุบันพร้อมแถบวัดค่าเทียบกับค่าเกณฑ์ (Threshold) และการ์ดสถานะระบบที่แสดงชื่อแบบจำลองที่ใช้งานอยู่ จำนวนตัวอย่างที่ผ่านการฝึกแล้ว แหล่งที่มาของคำสั่งควบคุม และสถานะปัจจุบันของเซอร์โว

ส่วนกลางของหน้าจอเป็นกราฟสัญญาณไฟฟ้ากล้ามเนื้อแบบเรียลไทม์ ซึ่งมีเส้นประสีเหลืองแสดงค่าเกณฑ์ Threshold กำกับไว้เพื่อให้ผู้ใช้เห็นความสัมพันธ์ระหว่างสัญญาณจริงกับค่าเกณฑ์ที่ใช้ตัดสินใจได้โดยตรง คู่กับเมทริกซ์ความสับสนโดยย่อของแบบจำลองที่ใช้งานอยู่ทางด้านขวา ซึ่งระบายสีตามความเข้มของค่าในแต่ละช่อง (สีเข้มบนเส้นทแยงมุมหมายถึงทำนายถูกต้อง) ช่วยให้ผู้ใช้ดูและประเมินคุณภาพของแบบจำลองได้โดยไม่ต้องสลับไปหน้าอื่น ส่วนล่างสรุปรวมการควบคุมหลักที่ใช้งานบ่อย ได้แก่ ตัวเลือก

แหล่งที่มาคำสั่งควบคุมเซอร์โว ปุ่มบันทึกท่าทางสำหรับเปรียบเทียบ และสถานะการซิงค์ข้อมูลกับ Firebase

ด้านการสื่อความหมายด้วยสี ระบบใช้สีฟ้าไซแอนสำหรับเน้นค่าที่กำลังทำงานอยู่ในปัจจุบัน (เช่น ท่าทางที่ทำนายได้ และตัวเลือกที่ถูกเลือกอยู่) สีม่วงสำหรับค่าตัวเลขเชิงปริมาณ (เช่น ค่า RMS) และสีเขียวสำหรับสถานะที่ทำงานปกติหรือพร้อมใช้งาน (เช่น การเชื่อมต่อ Firebase และสถานะฮาร์ดแวร์) การเลือกใช้สีอย่างสม่ำเสมอในความหมายเดียวกันทั่วทั้งหน้าจอ ช่วยให้ผู้ใช้งานสร้างความคุ้นเคยและตีความสถานะของระบบได้รวดเร็วขึ้นเมื่อใช้งานไปสักระยะ โดยไม่ต้องอ่านข้อความประกอบทุกครั้ง

หน้า Dashboard เป็นหน้าแรกที่ปรากฏภายหลังเข้าสู่ระบบสำเร็จ ทำหน้าที่เป็นศูนย์กลางในการเฝ้าติดตามสถานะของระบบแบบเรียลไทม์ ประกอบด้วยกราฟสัญญาณไฟฟ้ากลั่นเนื้อที่อัปเดตต่อเนื่อง การ์ดแสดงท่าทางที่ทำนายได้ปัจจุบันพร้อมค่าความมั่นใจ สถานะการเชื่อมต่อกับ Firebase จำนวนตัวอย่างข้อมูลที่ผ่านการฝึกแบบจำลองแล้ว ตัวเลือกแหล่งที่มาของคำสั่งควบคุมเซอร์โวระหว่างค่าเกณฑ์ RMS Threshold กับผลลัพธ์จากแบบจำลองการเรียนรู้ของเครื่อง ตลอดจนเมตริกซ์ความสับสนโดยย่อของแบบจำลองที่ใช้งานอยู่ ส่วนหน้าเครื่องมือสอบเทียบมุ่งเน้นการปรับเทียบสัญญาณเฉพาะบุคคล ประกอบด้วยกราฟสัญญาณแบบเรียลไทม์ แถบเลื่อนสำหรับปรับค่าเกณฑ์ ปุ่มบันทึกท่าทางท่ามือและคลายมือ ตลอดจนฟังก์ชันจำลองเก็บข้อมูลอัตโนมัติที่นับถอยหลังสลับท่าทางให้โดยไม่ต้องกดบันทึกด้วยตนเองทีละครั้ง

ด้านโทนสี ระบบเลือกใช้พื้นหลังโทนกรมท่าเข้มตัดด้วยสีม่วงและสีฟ้าไซแอนสำหรับจุดเน้น ด้วยเหตุผลด้านการใช้งานสองประการ ประการแรกคือช่วยลดความล้าของสายตาเมื่อต้องเฝ้าติดตามหน้าจอเป็นระยะเวลานาน ต่อเนื่อง ซึ่งสอดคล้องกับลักษณะงานเฝ้าติดตามสัญญาณแบบเรียลไทม์ของระบบ ประการที่สองคือให้ความต่างระดับสี (Contrast) ที่เพียงพอสำหรับการอ่านค่าตัวเลขและกราฟได้อย่างชัดเจน องค์ประกอบต่าง ๆ ถูกจัดวางในรูปแบบการดมูมไค้งมนอย่างสม่ำเสมอทุกหน้า ร่วมกับการใช้สีบ่งบอกสถานะ เช่น สีเขียวสำหรับสถานะออนไลน์หรือพร้อมใช้งาน และสีแดงสำหรับสถานะออฟไลน์หรือข้อผิดพลาด เพื่อให้ผู้ใช้งานตีความสถานะของระบบได้อย่างรวดเร็วโดยไม่ต้องอ่านข้อความประกอบ

ในด้านการตอบสนอง หน้าจอทั้งหมดอัปเดตข้อมูลแบบเรียลไทม์อย่างต่อเนื่องในอัตราประมาณ 25 เฟรมต่อวินาที เพื่อให้ผู้ใช้งานรับรู้การเปลี่ยนแปลงของสัญญาณได้ทันที ทุกส่วนของหน้าจอมีปุ่มช่วยเหลือกำกับไว้ สำหรับอธิบายหลักการทำงานของส่วนนั้น ๆ เพื่อลดภาระการจดจำของผู้ใช้งานใหม่ที่ไม่มีพื้นฐานด้านเทคโนโลยี มาก่อน นอกจากนี้ระบบยังรองรับแบบอักษรภาษาไทยที่มีขนาดเหมาะสมต่อการอ่าน และมีโหมดจำลอง (Simulated Mode) ที่แสดงข้อความแจ้งเตือนอย่างชัดเจนบนแถบสถานะเมื่อไม่พบฮาร์ดแวร์เซนเซอร์หรือเซอร์โวจริง เพื่อป้องกันความสับสนของผู้ใช้งานว่าระบบกำลังทำงานในสถานะใด

3.9 แผนการทดสอบระบบ (System Testing Plan)

เพื่อให้มั่นใจว่าระบบที่พัฒนาขึ้นสามารถทำงานได้ถูกต้องและมีเสถียรภาพ จึงได้วางแผนการทดสอบอย่างเป็นระบบ โดยแบ่งการทดสอบออกเป็น 3 ระดับ ได้แก่ การทดสอบหน่วยย่อย (Unit Testing) การทดสอบการทำงานร่วมกัน (Integration Testing) และการทดสอบการยอมรับจากผู้ใช้งาน (User Acceptance Testing: UAT)

3.9.1 Unit Testing

เป็นการทดสอบฟังก์ชันย่อยของซอฟต์แวร์ เช่น ฟังก์ชันอ่านค่าจากเซนเซอร์ผ่านวงจร ADS1115 ฟังก์ชันกรองสัญญาณด้วยตัวกรองผ่านแถบความถี่และตัวกรองแบบบาค ฟังก์ชันสกัดคุณลักษณะสัญญาณทั้ง 7 ค่า และฟังก์ชันบันทึกข้อมูลลงไฟล์ .jsonl การทดสอบระดับนี้ช่วยยืนยันว่าแต่ละส่วนของโปรแกรมสามารถทำงานได้ถูกต้องตามที่ออกแบบไว้

3.9.2 Integration Testing

เป็นการทดสอบการทำงานร่วมกันระหว่างซอฟต์แวร์และฮาร์ดแวร์ เช่น การตรวจสอบว่าสัญญาณที่อ่านได้จากเซนเซอร์ผ่านกระบวนการกรองและสกัดคุณลักษณะแล้วสามารถส่งต่อไปยังแบบจำลองการเรียนรู้ของเครื่องได้อย่างถูกต้อง การควบคุมเซอร์โวมอเตอร์ตอบสนองตามผลการตัดสินใจของระบบ และการซิงค์ข้อมูลขึ้น Firebase ทำงานได้อย่างสอดคล้องกันทั้งในสถานะออนไลน์และออฟไลน์

3.9.3 User Acceptance Testing (UAT)

เป็นการทดสอบโดยผู้ใช้งานในสภาพแวดล้อมจริง โดยให้ผู้ใช้งานทดลองปรับเทียบสัญญาณเฉพาะบุคคลและควบคุมมือเทียมด้วยท่าทางกำมือและคลายมือ แล้วประเมินว่าระบบสามารถจดจำเจตนาของผู้ใช้งานได้ตามที่คาดหวังหรือไม่ การทดสอบนี้ช่วยยืนยันว่าระบบตอบสนองต่อความต้องการใช้งานจริงของผู้พิการทางร่างกายที่เป็นกลุ่มเป้าหมายของโครงการ

ตารางที่ 3.25 แผนการทดสอบระบบ

ระดับการทดสอบ	วัตถุประสงค์	ขอบเขตการทดสอบ	เครื่องมือที่ใช้	เกณฑ์การผ่าน
Unit Testing	ตรวจสอบส่วนย่อยทำงานถูกต้อง	อ่านค่าสัญญาณ EMG กรองสัญญาณ สกัดคุณลักษณะ 7 ค่า บันทึกไฟล์ .jsonl ถูกต้อง	สังเกตุ, unittest	ค่าไม่ค้าง ไฟล์บันทึกครบ คุณลักษณะคำนวณถูกต้องตามสูตร
Integration Testing	ทดสอบระบบรวม	รันต่อเนื่อง ≥ 30 นาที สลับโหมด RMS Threshold/ML Model ตรวจสอบการควบคุมเซอร์โวและซิงค์ Firebase	Manual test	เซอร์โวตอบสนองถูกต้อง ข้อมูลซิงค์ครบ ไม่มีการค้างของระบบ

UAT	ประเมินใช้งานจริง	ผู้ใช้ทดสอบการเปรียบเทียบและควบคุมมือเทียมด้วยท่าทางจริง	แบบสอบถาม	คะแนนเฉลี่ย ≥ 4.0 และจดจำท่าทางได้ถูกต้อง
-----	-------------------	--	-----------	--

จากตารางที่ 3.25 เป็นแผนทดสอบระบบที่แบ่งออกเป็น 3 ระดับ ได้แก่ Unit Testing ไปที่ Integration Testing และไปที่ UAT ครอบคลุมตั้งแต่การทดสอบฟังก์ชันย่อย การทำงานร่วมกันของฮาร์ดแวร์และซอฟต์แวร์ จนถึงการใช้งานจริงกับผู้ใช้จริง ทั้งนี้ช่วยรับประกันว่าระบบมีความถูกต้อง เสถียร และตอบโจทย์การใช้งานจริงได้

ตารางที่ 3.26 ตัวอย่างกรณีทดสอบ

Test Case ID	สถานการณ์ทดสอบ	ขั้นตอนการทดสอบ	ข้อมูลทดสอบ	ผลที่คาดหวัง
TC-01	การอ่านค่าสัญญาณ EMG สำเร็จ	เปิดระบบ รอกการอ่านค่าจากเซนเซอร์	สัญญาณกล้ามเนื้อขณะพักทั่วไป	ค่า RMS แสดงผลบนกราฟหน้า Dashboard แบบเรียลไทม์
TC-02	การเปรียบเทียบและบันทึกข้อมูล	กดปุ่มกำมือและคลายมือที่หน้าเครื่องมือสอบเทียบ แล้วกดบันทึก	สัญญาณท่าทางกำมือและคลายมือจริงจากผู้ใช้	มีข้อมูลใหม่ถูกบันทึกและซิงค์ขึ้น Firebase ครบทั้ง 7 คุณลักษณะ
TC-03	การควบคุมเซอร์โวด้วยค่าเกณฑ์ RMS	ทำท่ากำมือค้างไว้จนค่า RMS เกินค่าเกณฑ์ที่ตั้งไว้	ค่าเกณฑ์ (Threshold) ที่กำหนดไว้ในหน้าตั้งค่าระบบ	เซอร์โวมอเตอร์หมุนไปยังตำแหน่งกำมือทันที
TC-04	การทำนายท่าทางด้วยแบบจำลอง ML	ฝึกแบบจำลองให้เรียบร้อย แล้วสลับแหล่งที่มาคำสั่งควบคุมเป็น ML Model	ชุดข้อมูลที่ผ่านการฝึกแบบจำลองแล้ว	ระบบทำนายท่าทางและสั่งงานเซอร์โวได้ถูกต้องตามท่าทางจริงของผู้ใช้
TC-05	ความเสถียรของระบบ	เปิดระบบให้ทำงานต่อเนื่องเป็นระยะเวลา 2 ชั่วโมง	การทำงานของระบบตลอดช่วงทดสอบ	ระบบยังทำงานต่อเนื่องได้โดยไม่มีข้อผิดพลาดค้าง และข้อมูลซิงค์ขึ้น Firebase ครบถ้วน

โดยสรุป ตารางกรณีทดสอบ (Test Case) นี้กำหนด 5 กรณีหลักในการทดสอบระบบ ได้แก่ การอ่านค่าสัญญาณไฟฟ้ากล้ามเนื้อ การเปรียบเทียบและบันทึกข้อมูล การควบคุมเซอร์โวด้วยค่าเกณฑ์

RMS การทำนายท่าทางด้วยแบบจำลองการเรียนรู้ของเครื่อง และความเสถียรของระบบ ซึ่งช่วยให้มั่นใจได้ว่าระบบตรวจวัดและควบคุมมือเทียมมีความถูกต้อง เสถียร และตอบสนองต่อผู้ใช้งานได้จริง

บทที่ 4

ผลการดำเนินงาน (Results)

บทนี้นำเสนอผลการดำเนินงานของระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อที่พัฒนาขึ้น ครอบคลุมผลการพัฒนาระบบในแต่ละส่วนหน้าจอ ผลการทดสอบระบบตามกรณีทดสอบที่ออกแบบไว้ ความน่าเชื่อถือและความทนทานของระบบ ผลการประเมินความพึงพอใจของผู้ใช้งาน ตลอดจนการอภิปรายผลการดำเนินงานเทียบกับวัตถุประสงค์ที่ตั้งไว้ในบทที่ 1 และการปรับปรุงตารางการติดตามความต้องการให้สมบูรณ์

4.1 ผลการพัฒนาระบบ

ระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อได้รับการพัฒนาเสร็จสิ้นตามขั้นตอนที่ระบุไว้ในบทที่ 3 โดยส่วนติดต่อผู้ใช้พัฒนาด้วยไลบรารี Tkinter บน Raspberry Pi 5 ประกอบด้วยหน้าจอหลัก 7 หน้า ได้แก่ หน้าเข้าสู่ระบบ หน้า Dashboard หน้าเครื่องมือสอบเทียบ หน้าการเรียนรู้ของเครื่อง หน้าสรุปผลโมเดล หน้าบันทึกข้อมูล และหน้าตั้งค่าระบบ โดยการพัฒนาแสดงรายละเอียดของแต่ละหน้าจอดังนี้

4.1.1 หน้าเข้าสู่ระบบ (SCR-01)

เมื่อผู้ดูแลระบบเข้าสู่หน้าเข้าสู่ระบบ (SCR-01) สามารถกรอกอีเมลและรหัสผ่านเพื่อยืนยันตัวตนผ่านกระบวนการยืนยันตัวตนของ Firebase ระบบจะตรวจสอบรายชื่อผู้ได้รับอนุญาตจากฐานข้อมูลแบบเวลาจริง และอนุญาตให้เข้าสู่ระบบเมื่อผ่านการตรวจสอบ การทำงานนี้สอดคล้องกับ Use Case UC-01 "เข้าสู่ระบบ" และ UC-02 "ตรวจสอบสิทธิ์ผู้ดูแลระบบ"

[แทรกภาพหน้าจอ]

รูปที่ 4.1 หน้าจอเข้าสู่ระบบ (SCR-01)

จากรูปที่ 4.1 หน้าจอเข้าสู่ระบบ (SCR-01) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.2 หน้า Dashboard (SCR-02)

หลังเข้าสู่ระบบสำเร็จ ผู้ดูแลระบบจะถูกนำมายังหน้า Dashboard (SCR-02) ซึ่งเป็นศูนย์กลางในการเฝ้าติดตามสถานะของระบบแบบเรียลไทม์ ประกอบด้วยกราฟสัญญาณไฟฟ้ากล้ามเนื้อ การ์ดแสดงท่าทางที่ทำนายได้พร้อมค่าความมั่นใจ สถานะการเชื่อมต่อ Firebase และตัวเลือกแหล่งที่มาคำสั่งควบคุมเซอร์โว การทำงานนี้สอดคล้องกับ Use Case UC-18 "เฝ้าติดตามสัญญาณ EMG" และ UC-19 "เลือกแหล่งที่มาคำสั่งควบคุมเซอร์โว"

[แทรกภาพหน้าจอ]

รูปที่ 4.2 หน้า Dashboard (SCR-02)

จากรูปที่ 4.2 หน้า Dashboard (SCR-02) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.3 หน้าเครื่องมือสอบเทียบ (SCR-03)

ผู้ดูแลระบบใช้หน้าเครื่องมือสอบเทียบ (SCR-03) ในการปรับเทียบสัญญาณเฉพาะบุคคล โดยบันทึกตัวอย่างสัญญาณของท่าทางกำมือและคลายมือ พร้อมแถบเลื่อนปรับค่าเกณฑ์ RMS Threshold และฟังก์ชันจำลองเก็บข้อมูลอัตโนมัติ การทำงานนี้สอดคล้องกับ Use Case UC-03 "อ่าน/แสดงสัญญาณ EMG" และ UC-04 "ปรับเทียบสัญญาณ"

[แทรกภาพหน้าจอ]

รูปที่ 4.3 หน้าเครื่องมือสอบเทียบ (SCR-03)

จากรูปที่ 4.3 หน้าเครื่องมือสอบเทียบ (SCR-03) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.4 หน้าการเรียนรู้ของเครื่อง (SCR-04)

หน้าการเรียนรู้ของเครื่อง (SCR-04) ให้ผู้ดูแลระบบเลือกผู้ใช้งาน เลือกแบบจำลอง และเลือกวิธีการฝึกแบบจำลอง รวมถึงฟังก์ชันเทรนทุกโมเดลเพื่อฝึกและเปรียบเทียบแบบจำลองทั้งหมดพร้อมกัน การทำงานนี้สอดคล้องกับ Use Case UC-10 ถึง UC-12, UC-15 และ UC-16

[แทรกภาพหน้าจอ]

รูปที่ 4.4 หน้าการเรียนรู้ของเครื่อง (SCR-04)

จากรูปที่ 4.4 หน้าการเรียนรู้ของเครื่อง (SCR-04) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.5 หน้าสรุปผลโมเดล (SCR-05)

หน้าสรุปผลโมเดล (SCR-05) แสดงผลการประเมินแบบจำลองในรูปแบบตาราง ได้แก่ ค่าความถูกต้อง ค่า F1 และเมตริกซ์ความสับสนของแต่ละแบบจำลอง พร้อมทั้งสามารถส่งออกผลเปรียบเทียบเป็นไฟล์ CSV ได้ การทำงานนี้สอดคล้องกับ Use Case UC-13, UC-17 และ UC-20

[แทรกภาพหน้าจอ]

รูปที่ 4.5 หน้าสรุปผลโมเดล (SCR-05)

จากรูปที่ 4.5 หน้าสรุปผลโมเดล (SCR-05) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.6 หน้าบันทึกข้อมูล (SCR-06)

หน้าบันทึกข้อมูล (SCR-06) แสดงประวัติข้อมูลสัญญาณและเหตุการณ์ต่าง ๆ ที่ถูกบันทึกไว้ในระบบ พร้อมทั้งสามารถส่งออกชุดข้อมูลที่ใช้ฝึกแบบจำลองเป็นไฟล์ CSV ได้ การทำงานนี้สอดคล้องกับ Use Case UC-06 ถึง UC-09

[แทรกภาพหน้าจอ]

รูปที่ 4.6 หน้าบันทึกข้อมูล (SCR-06)

จากรูปที่ 4.6 หน้าบันทึกข้อมูล (SCR-06) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.1.7 หน้าตั้งค่าระบบ (SCR-07)

หน้าตั้งค่าระบบ (SCR-07) ให้ผู้ดูแลระบบกำหนดค่าเกณฑ์เริ่มต้นสำหรับตรวจจับสัญญาณตลอดจนตรวจสอบสถานะการเชื่อมต่อฮาร์ดแวร์และข้อมูลรุ่นของระบบ การทำงานนี้สอดคล้องกับ Use Case UC-14 "ตั้งค่าระบบ"

[แทรกภาพหน้าจอ]

รูปที่ 4.7 หน้าตั้งค่าระบบ (SCR-07)

จากรูปที่ 4.7 หน้าตั้งค่าระบบ (SCR-07) [อธิบายสิ่งที่ปรากฏในภาพหน้าจอจริงเพิ่มเติมโดยย่อ]

4.2 ผลการทดสอบระบบ

การทดสอบระบบดำเนินการตามแผนการทดสอบที่วางไว้ในหัวข้อ 3.9 เพื่อรับประกันคุณภาพของทั้งฮาร์ดแวร์และซอฟต์แวร์ โดยครอบคลุมการทดสอบระดับ Unit Testing, Integration Testing และ User Acceptance Testing (UAT)

4.2.1 ผลการทดสอบตามกรณีทดสอบ

ผู้วิจัยได้ทำการทดสอบระบบตามกรณีทดสอบที่ออกแบบไว้ในตารางที่ 3.25 โดยมีผลลัพธ์ที่สำคัญดังนี้

ตารางที่ 4.8 ผลการทดสอบกรณี "การอ่านค่าสัญญาณ EMG" (อ้างอิง UC-03)

Test Case ID	สถานการณ์ทดสอบ	ผลการทดสอบจริง	สถานะ
TC-01	การอ่านค่าสัญญาณ EMG สำเร็จ	ระบุผลจริง	ระบุผล จริง

จากตารางที่ 4.8 [สรุปผลการทดสอบกรณีนี้โดยย่อ 1-2 ประโยค]

[แทรกภาพหน้าจอ]

รูปที่ 4.8 ผลการทดสอบ TC-01

ตารางที่ 4.9 ผลการทดสอบกรณี "การเปรียบเทียบและบันทึกข้อมูล" (อ้างอิง UC-04)

Test Case ID	สถานการณ์ทดสอบ	ผลการทดสอบจริง	สถานะ
TC-02	การเปรียบเทียบและบันทึกข้อมูล	ระบุผลจริง	ระบุผลจริง

จากตารางที่ 4.9 [สรุปผลการทดสอบกรณีนี้โดยย่อ 1-2 ประโยค]

[แทรกภาพหน้าจอ]

รูปที่ 4.9 ผลการทดสอบ TC-02

ตารางที่ 4.10 ผลการทดสอบกรณี "การควบคุมเซอร์โว" (อ้างอิง UC-05)

Test Case ID	สถานการณ์ทดสอบ	ผลการทดสอบจริง	สถานะ
TC-03	การควบคุมเซอร์โวด้วยค่าเกนธ์ RMS	ระบุผลจริง	ระบุผลจริง

จากตารางที่ 4.10 [สรุปผลการทดสอบกรณีนี้โดยย่อ 1-2 ประโยค]

[แทรกภาพหน้าจอ]

รูปที่ 4.10 ผลการทดสอบ TC-03

ตารางที่ 4.11 ผลการทดสอบกรณี "การทำนายท่าทางด้วยแบบจำลอง ML" (อ้างอิง UC-10 ถึง UC-13)

Test Case ID	สถานการณ์ทดสอบ	ผลการทดสอบจริง	สถานะ
TC-04	การทำนายท่าทางด้วยแบบจำลอง ML	ระบุผลจริง	ระบุผลจริง

จากตารางที่ 4.11 [สรุปผลการทดสอบกรณีนี้โดยย่อ 1-2 ประโยค]

[แทรกภาพหน้าจอ]

รูปที่ 4.11 ผลการทดสอบ TC-04

ตารางที่ 4.12 ผลการทดสอบกรณี "ความเสถียรของระบบ"

Test Case ID	สถานการณ์ทดสอบ	ผลการทดสอบจริง	สถานะ
TC-05	ความเสถียรของระบบ	ระบุผลจริง	ระบุผลจริง

จากตารางที่ 4.12 [สรุปผลการทดสอบกรณีนี้โดยย่อ 1-2 ประโยค]

[แทรกภาพหน้าจอ]

รูปที่ 4.12 ผลการทดสอบ TC-05

4.2.2 ความน่าเชื่อถือและความทนทานของระบบ

นอกเหนือจากการทดสอบเชิงฟังก์ชันตามกรณีทดสอบข้างต้น ระบบยังได้รับการออกแบบให้มีความน่าเชื่อถือและความทนทานต่อสภาวะการใช้งานที่ไม่สมบูรณ์ ดังนี้

4.2.2.1 การรองรับโหมดจำลองเมื่อไม่มีฮาร์ดแวร์

ระบบตรวจจับความพร้อมของฮาร์ดแวร์โดยอัตโนมัติ หากไม่พบไลบรารีหรือไม่สามารถเปิดใช้งานบัส I²C ได้ โมดูลอ่านสัญญาณและโมดูลควบคุมเซอร์โวมอเตอร์จะสลับไปทำงานในโหมดจำลองโดยอัตโนมัติ ทำให้สามารถพัฒนาและทดสอบตรรกะของระบบได้แม้ไม่มีฮาร์ดแวร์ต่ออยู่จริง ดังที่กล่าวไว้ในหัวข้อ 3.3.5

[ระบุผลการทดสอบจริง เช่น ระบบทำงานในโหมดจำลองได้ต่อเนื่องเป็นเวลา ... โดยไม่เกิดข้อผิดพลาด]

4.2.2.2 กลไก Debounce ป้องกันเซอร์โวลั่น

ระบบใช้กลไก Debounce ที่ต้องมีค่าคงที่ต่อเนื่องกันตามจำนวนรอบที่กำหนดก่อนสั่งขับเซอร์โวจริง เพื่อป้องกันการสั่งงานที่ถี่เกินไปเมื่อสัญญาณหรือผลทำนายแกว่งใกล้จุดตัดสินใจ ดังที่กล่าวไว้ในหัวข้อ 3.6

[ระบุผลการทดสอบจริง เช่น จำนวนครั้งที่เซอร์โวลั่นก่อนและหลังเปิดใช้งาน Debounce]

4.2.2.3 การทำงานแบบออฟไลน์ก่อน (Offline-first)

ข้อมูลตัวอย่างสัญญาณและผลการปรับเทียบถูกบันทึกลงไฟล์ในเครื่องบันทึกก่อนซิงก์ขึ้นสู่ฐานข้อมูล Firebase เมื่อตรวจพบการเชื่อมต่ออินเทอร์เน็ต ทำให้ระบบยังคงทำงานต่อเนื่องได้แม้ในสถานะที่เครือข่ายไม่เสถียรหรือขาดการเชื่อมต่อชั่วคราว

[ระบุผลการทดสอบจริง เช่น ทดสอบตัดอินเทอร์เน็ตระหว่างใช้งาน แล้วข้อมูลซิงก์ก็กลับขึ้นครบถ้วนหรือไม่]

จากรูปที่ 4.13 [ระบุจำนวนผู้ให้คะแนนแต่ละระดับ ร้อยละ และค่าเฉลี่ย พร้อมสรุปผลโดยย่อ]

ตารางที่ 4.14 Requirements Traceability Matrix ฉบับสมบูรณ์

Requirement ID	รายละเอียดความต้องการ	Use Case ที่เกี่ยวข้อง	Test Case ID
FR-01	ระบบต้องให้ผู้ดูแลระบบเข้าสู่ระบบได้ด้วยอีเมลและรหัสผ่านผ่าน Firebase Authentication	UC-01, UC-02	TC-01

FR-02	ระบบต้องอ่านและแสดงผลสัญญาณไฟฟ้ากล้ามเนื้อแบบเรียลไทม์	UC-03	TC-01
FR-03	ระบบต้องรองรับการปรับเทียบสัญญาณเฉพาะบุคคลสำหรับท่าทางกำมือและคลายมือ	UC-04	TC-02
FR-04	ระบบต้องควบคุมเซอร์โวมอเตอร์ให้สอดคล้องกับค่าเกณฑ์ RMS Threshold หรือผลทำนายของแบบจำลอง	UC-05	TC-03
FR-05	ระบบต้องรองรับการจัดการผู้ใช้งานและบันทึก/ซิงค์ข้อมูลขึ้นสู่ Firebase	UC-06, UC-07, UC-08	ระบุผลจริง
FR-06	ระบบต้องส่งออกชุดข้อมูลที่ใช้ฝึกแบบจำลองเป็นไฟล์ CSV ได้	UC-09	ระบุผลจริง
FR-07	ระบบต้องฝึกและเปรียบเทียบแบบจำลองการเรียนรู้ของเครื่องได้หลายชนิด	UC-10 ถึง UC-13, UC-15, UC-16	TC-04
FR-08	ระบบต้องกำหนดค่าเกณฑ์เริ่มต้นสำหรับตรวจจับสัญญาณผ่านหน้าตั้งค่าระบบได้	UC-14	ระบุผลจริง
FR-09	ระบบต้องแสดงสถานะการทำงานแบบเรียลไทม์บนหน้า Dashboard และเลือกแหล่งที่มาคำสั่งควบคุมได้	UC-18, UC-19	ระบุผลจริง
FR-10	ระบบต้องส่งออกผลการเปรียบเทียบแบบจำลองเป็นไฟล์ CSV ได้	UC-20	ระบุผลจริง

จากตารางที่ 4.14 [สรุปว่าความต้องการทั้งหมดได้รับการทดสอบครบถ้วนหรือมีความต้องการใดที่ยังไม่ครอบคลุม]

บทที่ 5

สรุปผลและข้อเสนอแนะ

บทนี้นำเสนอบทสรุปของการดำเนินโครงการระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อ โดยประมวลผลจากการพัฒนาระบบและการทดลองใช้งานจริงกับอาสาสมัคร ปัญหาและอุปสรรคที่พบระหว่างการดำเนินงาน ตลอดจนข้อเสนอแนะสำหรับการพัฒนาต่อยอดในอนาคต

5.1 สรุปผลการดำเนินงาน

โครงการนี้พัฒนาระบบควบคุมมือเทียมด้วยสัญญาณไฟฟ้ากล้ามเนื้อที่สามารถอ่านสัญญาณเปรียบเทียบเฉพาะบุคคล ฝึกแบบจำลองการเรียนรู้ของเครื่อง และควบคุมการเคลื่อนไหวของมือเทียมให้สอดคล้องกับเจตนาของผู้ใช้งานได้สำเร็จตามวัตถุประสงค์ที่ตั้งไว้ โดยผลการดำเนินงานที่สำคัญสรุปได้ดังนี้

5.1.1 ผลการเก็บข้อมูลจากอาสาสมัคร

ผู้วิจัยเก็บข้อมูลสัญญาณไฟฟ้ากล้ามเนื้อจากอาสาสมัครที่มีร่างกายสมบูรณ์จำนวน 9 คน แบ่งเป็นกลุ่มผู้ใหญ่ทั่วไปจำนวน 7 คน และกลุ่มเด็กจำนวน 2 คน รวมตัวอย่างสัญญาณที่ผ่านการติดป้ายกำกับท่าทางทั้งสิ้น 3,821 ตัวอย่าง แบ่งเป็นท่าทางกำมือ 1,925 ตัวอย่าง และท่าทางคลายมือ 1,896 ตัวอย่าง ซึ่งมีสัดส่วนใกล้เคียงกันระหว่างสองท่าทาง โดยกลุ่มผู้ใหญ่ให้ตัวอย่างข้อมูลรวม 2,879 ตัวอย่าง และกลุ่มเด็กให้ตัวอย่างข้อมูลรวม 942 ตัวอย่าง ดังรายละเอียดในตารางที่ 5.1 ทั้งนี้ การเก็บข้อมูลดำเนินการในช่วงเดือนกรกฎาคมถึงเดือนสิงหาคม พ.ศ. 2569

ตารางที่ 5.1 จำนวนตัวอย่างสัญญาณที่เก็บได้จากอาสาสมัครแต่ละราย

รหัสอาสาสมัคร	กลุ่ม	จำนวนตัวอย่างรวม	ท่าทางกำมือ	ท่าทางคลายมือ
AJ_Ruji_01	ผู้ใหญ่	315	159	156
Bas_02	ผู้ใหญ่	398	200	198
Jirakit_01	ผู้ใหญ่	440	220	220
Old_Mithree_02	ผู้ใหญ่	423	213	210
Prem_02	ผู้ใหญ่	411	206	205
Supichaya	ผู้ใหญ่	448	224	224
Woravit_01	ผู้ใหญ่	444	221	223
Young_Mudmee_02	เด็ก	535	281	254
Young_Tisha_01	เด็ก	407	201	206
รวม	9 คน	3,821	1,925	1,896

จากตารางที่ 5.1 เมื่อพิจารณาค่าเฉลี่ยของ RMS ระหว่างท่าทางกำมือและคลายมือของอาสาสมัครแต่ละราย พบว่าทุกรายมีค่า RMS ของท่าทางกำมือสูงกว่าท่าทางคลายมืออย่างชัดเจน ซึ่งยืนยันว่ากระบวนการปรับเทียบสัญญาณเฉพาะบุคคลสามารถแยกแยะสองท่าทางออกจากกันได้อย่างมีนัยสำคัญในอาสาสมัครทุกราย อย่างไรก็ตาม ระดับค่า RMS สัมบูรณ์มีความแตกต่างกันค่อนข้างมากระหว่างบุคคล ตั้งแต่ระดับ 0.017 โวลต์ไปจนถึง 0.132 โวลต์ในท่าทางกำมือ ซึ่งสะท้อนให้เห็นถึงความจำเป็นของการปรับเทียบสัญญาณเฉพาะบุคคลและการปรับสเกล RMS ตามตำแหน่งอิเล็กโทรดของผู้ใช้งานแต่ละราย ดังที่ระบบได้ออกแบบรองรับไว้ในหัวข้อ 4.4.3

5.1.2 ผลการเปรียบเทียบแบบจำลองการเรียนรู้ของเครื่อง

จากการฝึกและเปรียบเทียบแบบจำลองการเรียนรู้ของเครื่องทั้ง 24 รูปแบบ ทั้งแบบจำลองพื้นฐานเดี่ยวและแบบจำลองที่ผ่านการรวมกลุ่มด้วยวิธี Bagging และ AdaBoost พบว่าแบบจำลองที่ให้ค่าความถูกต้องสูงที่สุดสามอันดับแรกมีค่าความถูกต้องเท่ากันที่ร้อยละ 87.79 ได้แก่ ป่าสุ่ม (Random Forest) การรวมกลุ่มแบบ AdaBoost ร่วมกับโครงข่ายประสาทเทียม (AdaBoost + ANN) และการรวมกลุ่มแบบ Bagging ร่วมกับ XGBoost (Bagging + XGBoost) ดังรายละเอียดในตารางที่ 5.2

ตารางที่ 5.2 ผลการเปรียบเทียบแบบจำลอง 5 อันดับแรกจากทั้งหมด 24 รูปแบบ

อันดับ	แบบจำลอง	Accuracy	Precision	Recall	F1-score	AUC	Kappa
1	Random Forest	0.8779	0.9003	0.8608	0.8801	0.9278	0.7557
2	AdaBoost + ANN	0.8779	0.8939	0.8686	0.8810	0.9156	0.7556
3	Bagging + XGBoost	0.8779	0.8918	0.8711	0.8814	0.9232	0.7555
4	XGBoost	0.8765	0.8915	0.8686	0.8799	0.9223	0.7529
5	ANN	0.8752	0.8933	0.8634	0.8781	0.9262	0.7503

จากตารางที่ 5.2 จะเห็นว่าป่าสุ่มซึ่งเป็นแบบจำลองเริ่มต้นของระบบให้ผลลัพธ์อยู่ในกลุ่มที่ดีที่สุด โดยมีค่าความถูกต้องเท่ากับแบบจำลองรวมกลุ่มที่มีความซับซ้อนสูงกว่า ทั้งนี้ค่าความถูกต้องของแบบจำลองทั้ง 24 รูปแบบอยู่ในช่วงร้อยละ 84.03 ถึง 87.79 ซึ่งมีความแตกต่างกันไม่มากนัก แสดงให้เห็นว่าคุณลักษณะสัญญาณทั้ง 7 ค่าที่สกัดได้มีความสามารถในการจำแนกท่าทางที่ดีในตัวเอง โดยไม่ขึ้นอยู่กับชนิดของแบบจำลองมากนัก อย่างไรก็ตาม การที่ระบบเปิดโอกาสให้ทดลองและเลือกแบบจำลองที่เหมาะสมที่สุดสำหรับผู้ใช้งานแต่ละรายยังคงมีความสำคัญ เนื่องจากความแตกต่างของสัญญาณระหว่างบุคคลดังที่กล่าวไว้ในหัวข้อ 5.1.1 อาจส่งผลต่อประสิทธิภาพของแบบจำลองแต่ละชนิดแตกต่างกันไปในแต่ละราย

5.1.3 สรุปการบรรลุมิติวัตถุประสงค์

โดยสรุป ระบบสามารถอ่านสัญญาณไฟฟ้ากล้ามเนื้อ ปรับเทียบเฉพาะบุคคล ผูกแบบจำลองการเรียนรู้ของเครื่อง และควบคุมมือเทียมได้ตามวัตถุประสงค์ที่ตั้งไว้ในบทที่ 1 ทั้งกับอาสาสมัครกลุ่มผู้ใหญ่และกลุ่มเด็ก ซึ่งมีลักษณะสัญญาณกล้ามเนื้อแตกต่างกัน อันเป็นข้อยืนยันว่าสถาปัตยกรรมของระบบที่ออกแบบให้รองรับการปรับเทียบและการเลือกแบบจำลองเฉพาะบุคคลนั้นสามารถปรับตัวเข้ากับ ความหลากหลายของผู้ใช้งานได้ในระดับหนึ่ง

5.2 ปัญหาและอุปสรรคที่พบระหว่างการดำเนินงาน

จากการพัฒนาระบบมือเทียมควบคุมด้วยสัญญาณไฟฟ้ากล้ามเนื้อและการดำเนินการทดลองเก็บข้อมูลจากอาสาสมัคร ผู้วิจัยพบปัญหาและอุปสรรคทั้งในด้านเทคนิคและด้านการทดลอง ซึ่งสามารถสรุปได้ดังต่อไปนี้

5.2.1 ปัญหาด้านเทคนิค

5.2.1.1 สัญญาณรบกวนจากแหล่งจ่ายไฟฟ้าภายนอก

ในระหว่างการเก็บข้อมูลสัญญาณไฟฟ้ากล้ามเนื้อ (EMG) พบว่าการเชื่อมต่อบนระบบเข้ากับอุปกรณ์ไฟฟ้าที่ใช้แหล่งจ่ายไฟฟ้าโดยตรงก่อให้เกิดสัญญาณรบกวนทางไฟฟ้า (Electrical Noise) ซึ่งส่งผลให้สัญญาณ EMG ที่ได้รับมีความผิดเพี้ยนและลดความแม่นยำของการประมวลผล ผู้วิจัยจึงแก้ไขปัญหาโดยใช้งานระบบผ่านแหล่งจ่ายไฟจากแบตเตอรี่ และหลีกเลี่ยงการเชื่อมต่อกับอุปกรณ์ไฟฟ้าที่ใช้ไฟบ้านในระหว่างการเก็บข้อมูล เพื่อให้ได้สัญญาณที่มีคุณภาพและลดผลกระทบจากสัญญาณรบกวน

5.2.1.2 สัญญาณรบกวนจากสายส่งกำลังของมอเตอร์

ภายในชุดควบคุม พบว่าสายสัญญาณของเซนเซอร์ตรวจจับสัญญาณไฟฟ้ากล้ามเนื้อ มีความไวต่อสัญญาณรบกวนจากสนามแม่เหล็กไฟฟ้าที่เกิดจากสายส่งกำลังของเซอร์โวมอเตอร์ หากวางสายสัญญาณอยู่ใกล้กับสายกำลัง จะทำให้เกิดสัญญาณรบกวนที่ส่งผลต่อความถูกต้องของข้อมูล ผู้วิจัยจึงจัดระเบียบการเดินสายใหม่ โดยแยกสายสัญญาณออกจากสายกำลัง และจัดวางอุปกรณ์ภายในกล่องควบคุมให้เหมาะสมเพื่อลดผลกระทบจากการเหนี่ยวนำทางแม่เหล็กไฟฟ้า

5.2.1.3 ความปลอดภัยในการเชื่อมต่อวงจรไฟฟ้า

เซนเซอร์ตรวจจับสัญญาณไฟฟ้ากล้ามเนื้อและวงจรควบคุมจำเป็นต้องได้รับแรงดันไฟฟ้าตามข้อกำหนดของอุปกรณ์ หากเชื่อมต่อสายไฟผิดขั้วหรือผิดลำดับอาจทำให้อุปกรณ์เกิดความเสียหาย และอาจก่อให้เกิดอันตรายต่อผู้ใช้งานได้ ผู้วิจัยจึงกำหนดขั้นตอนการตรวจสอบการเชื่อมต่อวงจรทุกครั้งก่อนเริ่มใช้งาน เพื่อเพิ่มความปลอดภัยและลดความเสี่ยงที่อาจเกิดขึ้นระหว่างการทดลอง

5.2.2 ปัญหาด้านการทดลอง

5.2.2.1 ข้อจำกัดของกลุ่มอาสาสมัครในการทดลอง

การทดลองในงานวิจัยนี้ดำเนินการกับอาสาสมัครที่มีร่างกายสมบูรณ์เป็นหลัก เนื่องจากข้อจำกัดด้านระยะเวลาและการเข้าถึงกลุ่มผู้พิการแขนขาด ส่งผลให้ผลการทดลองยังไม่สามารถ

สะท้อนประสิทธิภาพของระบบในกลุ่มผู้ใช้งานจริงได้อย่างครบถ้วน ทั้งนี้ ผู้วิจัยได้ออกแบบขั้นตอนการทดลองให้เป็นมาตรฐานเดียวกันสำหรับอาสาสมัครทุกคน เพื่อลดความคลาดเคลื่อนของข้อมูลและเพิ่มความน่าเชื่อถือของผลการทดลอง

5.3 ข้อเสนอแนะ

จากผลการพัฒนาระบบและการทดลองใช้งาน ผู้วิจัยมีข้อเสนอแนะเพื่อใช้เป็นแนวทางในการพัฒนาระบบในอนาคต ดังต่อไปนี้

5.3.1 ข้อเสนอแนะในการพัฒนาระบบ

5.3.1.1 การพัฒนาส่วนติดต่อผู้ใช้

ควรปรับปรุงส่วนติดต่อผู้ใช้ (User Interface: UI) และประสบการณ์การใช้งาน (User Experience: UX) ให้มีความสะดวก เข้าใจง่าย และรองรับผู้ใช้งานที่ไม่มีพื้นฐานด้านเทคนิค เพื่อเพิ่มความสามารถในการใช้งานระบบได้อย่างมีประสิทธิภาพ

5.3.1.2 การปรับปรุงการออกแบบอุปกรณ์

หากนำระบบไปประยุกต์ใช้งานจริง ควรแยกกล่องบรรจุแบตเตอรี่ออกจากกล่องบรรจุ Raspberry Pi และวงจรควบคุม เพื่อลดขนาดและน้ำหนักของอุปกรณ์แต่ละส่วน ส่งผลให้ผู้ใช้งานสามารถสวมใส่ได้สะดวกยิ่งขึ้น และเพิ่มความคล่องตัวในการเคลื่อนไหว

5.3.1.3 การพัฒนารูปลักษณ์ของมือเทียม

ควรปรับปรุงการออกแบบโครงสร้างและรูปลักษณ์ภายนอกของมือเทียมให้มีความสวยงาม มีความแข็งแรง และมีลักษณะใกล้เคียงกับมือมนุษย์มากยิ่งขึ้น เพื่อเพิ่มความมั่นใจและความพึงพอใจของผู้ใช้งานในการนำไปใช้ในชีวิตประจำวัน

5.3.1.4 การพัฒนาแบบจำลองการเรียนรู้ของเครื่อง

ควรศึกษาการประยุกต์ใช้แบบจำลองการเรียนรู้เชิงลึก (Deep Learning) หรือเทคนิคการเรียนรู้แบบออนไลน์ (Online Learning) เพื่อเพิ่มความสามารถในการจำแนกสัญญาณไฟฟ้ากล้ามเนื้อ และรองรับความแตกต่างของผู้ใช้งานแต่ละรายได้ดียิ่งขึ้น

5.3.1.5 การเพิ่มจำนวนรูปแบบการเคลื่อนไหวของมือเทียม

ควรพัฒนาระบบให้สามารถจำแนกท่าทางการเคลื่อนไหวได้หลากหลายมากขึ้น เช่น การจับวัตถุหลายรูปแบบ การหยิบจับสิ่งของที่มีขนาดแตกต่างกัน และการควบคุมการเคลื่อนไหวของนิ้วแต่ละนิ้วอย่างอิสระ เพื่อเพิ่มประสิทธิภาพการใช้งานในชีวิตประจำวัน

5.3.2 ข้อเสนอแนะในการวิจัย

5.3.2.1 การทดลองกับกลุ่มผู้ใช้งานจริง

การวิจัยในอนาคตควรขยายผลการทดลองไปยังกลุ่มผู้พิการทางแขนขา เพื่อประเมินประสิทธิภาพของระบบในสภาพแวดล้อมการใช้งานจริง รวมทั้งศึกษาปัจจัยที่ส่งผลต่อความแม่นยำของการจำแนกสัญญาณไฟฟ้ากล้ามเนื้อในผู้ใช้งานแต่ละราย

5.3.2.2 การเพิ่มจำนวนอาสาสมัครในการทดลอง

ควรเพิ่มจำนวนอาสาสมัครในการทดลองให้มากขึ้น และให้ครอบคลุมกลุ่มตัวอย่างที่มีลักษณะแตกต่างกัน เช่น อายุ เพศ และสภาพร่างกาย เพื่อให้ผลการประเมินมีความน่าเชื่อถือทางสถิติสูงขึ้น และสามารถอ้างอิงผลการวิจัยได้อย่างกว้างขวาง

บรรณานุกรม

- [1] คมสันต์ เหลี่ยมมะ และคณะ. (2561). การบาดเจ็บที่เกี่ยวข้องเนื่องจากการทำงานและพฤติกรรมการทำงานที่ปลอดภัยของพนักงานโรงงานอุตสาหกรรมผลิตชิ้นส่วนรถยนต์. *พยาบาลสาร*, 45(4), 56-70.
- [2] พุดตาน พันธุ์เณร และคณะ. (2561). การวิเคราะห์ความต้องการกำลังคนด้านสุขภาพสำหรับระบบบริการระดับทุติยภูมิของประเทศไทยในปี พ.ศ. 2569. *วารสารวิจัยระบบสาธารณสุข*, 12(2), 205-220.
- [3] มณียฉัตร มาสมภพ. (2546). ปัญหา ความต้องการ และระดับความพึงพอใจของผู้มารับบริการด้านกายอุปกรณ์. สารนิพนธ์มหาบัณฑิต, มหาวิทยาลัยหัวเฉียวเฉลิมพระเกียรติ.
- [4] Carey, S. L., et al. (2015). Differences in myoelectric and body-powered upper-limb prostheses: Systematic literature review. *JRRD*, 52(3), 247-262.
- [5] Chadwell, A., et al. (2016). The Reality of Myoelectric Prostheses: Understanding What Makes These Devices Difficult for Some Users to Control. *Frontiers in Neurorobotics*, 10, 7.
- [6] ten Kate, J., et al. (2017). 3D-printed upper limb prostheses: a review. *Disability and Rehabilitation: Assistive Technology*, 12(3), 300-314.
- [7] Edwards, A. L., et al. (2016). Application of real-time machine learning to myoelectric prosthesis control: A case series in adaptive switching. *Prosthetics and Orthotics International*, 40(5), 573-581.
- [8] Igual, C., et al. (2019). Myoelectric Control for Upper Limb Prostheses. *Electronics*, 8(11), 1244.
- [9] Segura, D., et al. (2024). Upper Limb Prostheses by the Level of Amputation: A Systematic Review. *Prosthesis*, 6(2), 277-300.
- [10] Guo, K., et al. (2024). The Latest Research Progress on Bionic Artificial Hands: A Systematic Review. *Micromachines*, 15(7), 891.